به نام خدا

دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

هوش مصنوعی قابل اعتماد

تمرین سوم

نام و نام خانوادگی	امین آقاکثیری
شماره دانشجویی	810101381
تاریخ ارسال گزارش	1405/3/22

فهرست

سوال اول: شبکه های بیزی 3

بخش اول 3

زیربخش اول 3

زیربخش دوم 3

زیربخش سوم 3

زیربخش چهارم 4

بخش دوم 5

بخش سوم 6

زیربخش اول 6

زیربخش دوم 7

زیربخش سوم 7

بخش چهارم 7

زیربخش اول 7

زیربخش دوم 8

سوال دوم: علیت 9

بخش اول: سوالات تئوری 9

زیربخش اول: نامساوی 9

زیربخش دوم: اثر علی 9

بخش دوم: سوالات پیاده سازی 10

زیربخش اول: پیاده سازی SCM 10

زیربخش دوم: تاثیر دوره آموزشی 11

زیربخش سوم: سیگار نکشیم! 12

زیربخش چهارم: قالب جدید وب سایت 14

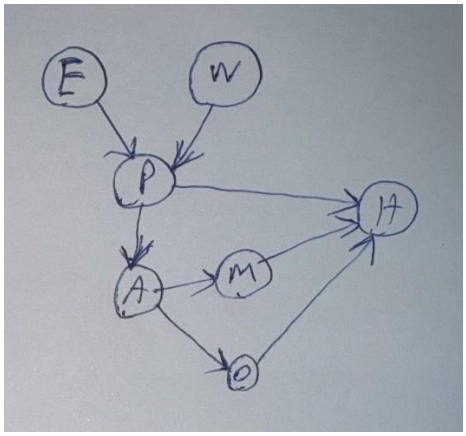
مراجع 20

سوال اول: شبکه های بیزی

بخش اول

زیربخش اول

طبق اطلاعات داده شده در صورت سوال، شبکه بیزی به صورت زیر می شود:



شکل 1. شبکه بیزی

زیربخش دوم

طبق مطالب کلاس می دانیم که احتمال توام کلی می شود ضرب احتمال تمام نود ها به شرط نود های پدرشان. پس به صورت زیر می شود:

$$P(W, E, P, A, M, O, H) = P(W)\,P(E)\,P(P \mid W, E)\,P(A \mid P)\,P(M \mid A)\,P(O \mid A)\,P(H \mid P, M, O)$$

زیربخش سوم

Markov Blanket یک متغیر در شبکه بیزی شامل والد های آن متغیر، فرزندان آن متغیر، و والد های دیگر فرزندان آن متغیر است. اهمیت Markov Blanket در این است که اگر مقدار متغیرهای موجود در این مجموعه را بدانیم، متغیر مورد نظر از بقیه متغیرهای شبکه مستقل می شود. طبق شبکه شبکه بیزی ای که در زیربخش اول رسم کردم، والد مستقیم M متغیر A است. فرزند مستقیم M متغیر H است. از طرف دیگر، متغیر H علاوه بر M، والد های دیگری نیز دارد که شامل P و O هستند. بنابراین Markov Blanket مربوط به متغیر M برابر است با {A, H, P, O}.

زیربخش چهارم

در الگوریتم d-seperation داشتیم که اگر در گراف، مسیر های بین دو متغیر block شود، آن دو از هم مستقل اند. حال این block شدن سه حالت دارد که در اسلاید های درس به آن اشاره شد. حالت اول و دوم این است که در مسیر بین دو نود، یک نود را بدانیم که به شرط آن، این دو نود از هم مستقل می شوند (که این دو حالت به صورت head-to-tail و tail-to-tail هستند که شکل های آنها در اسلاید های درس موجود است). حالت سوم هم همین است اما به صورت v-structure است و برعکس دو حالت قبل، به شرط دانستن آن نود میانی (یا هر کدام از بچه های آن)، آن دو نود به هم وابسته می شوند و اگر هیچکدام را ندانیم آنها مستقل اند. در واقع در d-separation اگر همه مسیر های بین دو متغیر بسته باشند، استقلال برقرار است. اگر حتی یک مسیر فعال وجود داشته باشد، استقلال برقرار نیست. حال به بررسی بخش های مختلف می پردازم:

الف) درست است. زیرا مسیر اصلی بین A و W که در زیربخش اول نشان دادم، با دانستن P که تنها نود بین آنها است بسته می شود و مسیر دیگری هم بین اینها وجود ندارد که از P نگذرد و بنابراین از هم مستقل اند.

ب) درست است. دو تا مسیر بین O و M وجود دارد که یکی از H میگذرد و دیگری از A. مسیری که از A می گذرد حالت tail-to-tail است و A را هم که می دانیم پس این مسیر بسته است. مسیری که از H می گذرد، v-structure است و چون H را نمی دانیم (و بچه دیگری هم ندارد که بدانیم) پس این مسیر هم بسته است. بقیه مسیر های بین این دو نود هم از این دو مسیر می گذرند. پس همه مسیر های بین این دو نود بسته اند و در نتیجه مستقل اند.

پ) نادرست است. دو مسیر $A \rightarrow M \rightarrow H$ و $A \rightarrow O \rightarrow H$ به دلیل شرط روی O و M بسته اند و درست اند. اما یک مسیر دیگر به صورت $A \leftarrow P \rightarrow H$ بین A و H وجود دارد و چون P را نمی دانیم، این مسیر بسته نیست پس یک مسیر پیدا شد که بین A و H باز است و در نتیجه به هم وابسته اند.

ت) درست است. دو تا مسیر بین آنها وجود دارد. اولین مسیر $E \rightarrow P \rightarrow A \rightarrow M$ است که چون A را می دانیم (حالت head-to-tail) پس بسته است. مسیر دوم $E \rightarrow P \rightarrow H \leftarrow M$ است که اینجا یک v-structure روی H داریم و چون روی آن شرطی نداریم و بچه ای هم ندارد، پس این هم بسته است و در نتیجه همه مسیر های بین این دو نود بسته اند و از هم مستقل اند.

ث) نادرست است. مسیر $W \rightarrow P \rightarrow H \leftarrow O$ یک v-structure روی H است و چون روی H شرط داریم، پس این مسیر بسته نیست و یک مسیر پیدا شد که بین این دو نود باز است و در نتیجه از هم مستقل نیستند.

بخش دوم

در اینجا علامت های روی یال ها جهت تاثیر کیفی را نشان می دهند. یعنی اگر روی یال $X \rightarrow Y$ علامت مثبت باشد، مقدار x1 احتمال y1 را افزایش می دهد و اگر علامت منفی باشد، مقدار x1 احتمال y1 را کاهش می دهد. حال به بررسی هر قسمت می پردازم:

الف) مسیر بین این دو نود $F \rightarrow E \rightarrow W$ است که $F \rightarrow E$ منفی و $E \rightarrow W$ مثبت است. پس وقتی فرد وقت آزاد کمی دارد، احتمال ورزش کردن کمتر می شود، و وقتی ورزش کمتر شود، احتمال وزن نرمال نیز کمتر می شود. پس اثر کلی F روی W منفی است و در نتیجه $P(w1) > P(w1 \mid f1)$.

ب) در اینجا مسیر $H \rightarrow E \leftarrow F$ را داریم که v-structure است و مسیر بین F و H باز است چون در هر دو احتمال روی E شرط داریم. حال $H \rightarrow E$ مثبت و $F \rightarrow E$ منفی است و در نتیجه h1 باعث افزایش ورزش می شود اما f1 یعنی کم بودن وقت آزاد باعث کاهش ورزش می شود. در هر دوی این احتمالات می دانیم فرد ورزش می کند. این کار می تاند دو علت داشته باشد. یکی اینکه به سلامتی اهمیت می دهد (h1) و یا اینکه زمان آزاد زیادی دارد (f0). حال در احتمال دوم یک شرط هم روی h1 داریم و می دانیم فرد به سلامتی اهمیت می دهد و در نتیجه این موضوع، ورزش کردن او را کاملا توجیح می کند و بنابراین دیگر فشار زیادی روی F نیست که حتما 0 باشد و در نتیجه وجود h1 باعث می شود احتمال f1 بیشتر از قبل شود چون حتی با وجود وقت آزاد کم، سلامت محور بودن می تواند ورزش کردن را توضیح دهد. پس

$P(f1 \mid e1) < P(f1 \mid e1, h1)$

پ) اینجا با شرطی شدن روی w1 یک v-structure به صورت $E \rightarrow W \leftarrow D$ باز می شود و همچنین چون W فرزند E است، پس $F \rightarrow E \leftarrow H$ هم باز می شود. حال اگر بدانیم فرد وقت آزاد زیادی دارد (f0) و از آنجا که $F \rightarrow E$ منفی است پس f0 احتمال e1 را افزایش می دهد و e1 هم w1 را افزایش می دهد (چون $E \rightarrow W$ مثبت است). با داشتن w1 از طریق ورزش، لزوم داشتن d1 (رژیم غذایی خوب) کاهش پیدا می کند (به دلیل وابستگی در v-structure). همچنین چون نیاز به d1 کمتر شده و $H \rightarrow D$ مثبت است پس احتمال اهمیت به سلامتی (h1) هم کاهش می یابد. پس $P(h1 \mid w1) > P(h1 \mid f0, w1)$.

ت) اینجا دو تا مسیر فعال داریم. مسیر اول $E \rightarrow W \leftarrow D \rightarrow C$ است که چون روی W شرط داریم پس باز است. در اینجا $D \rightarrow C$ منفی است و یعنی رژیم خوب باعث کاهش کلسترول بالا می شود. بنابراین مشاهده c1 باعث می شود احتمال d1 کمتر شود. از طرف دیگر D و E هر دو می توانند وزن نرمال W را توضیح دهند. وقتی d1 کمتر شود، برای توضیح w1 احتمال e1 بیشتر می شود. پس از این مسیر، c1 باعث افزایش احتمال e1 می شود.

یک مسیر دیگر به صورت $C \leftarrow D \leftarrow H \rightarrow E \rightarrow W$ وجود دارد. از قبل می دانیم مشاهده c1 باعث می شود احتمال d1 کم شود. اگر d1 کمتر محتمل شود، چون $H \rightarrow D$ مثبت است، احتمال h1 هم کمتر می شود. و چون $H \rightarrow E$ مثبت است، کم شدن احتمال h1 باعث کم شدن احتمال e1 می شود. پس از این مسیر، c1 باعث کاهش احتمال e1 می شود. پس در این قسمت دو مسیر متفاوت بررسیی شد که اثر آنها برعکس هم است و چون اثر نهایی به مقدار دقیق پارامترهای احتمالی بستگی دارد و این پارامتر ها را نداریم، نمی توانیم یکی را قطعا بزرگتر بدانیم.

ث) در اینجا W دو والد مستقیم D و E را دارد. روی هر دو e1 و d1 شرط داریم. همچنین H فقط از طریق D یا E می تواند روی W تاثیر بگذارد و چون e1 و d1 را از قبل داریم، پس اضافه شدن h1 تاثیر نمی گذارد و در واقع هر گره با داشتن والدین خود، از تمامی اجداد و متغیر های غیرفرزندش مستقل است. پس در این قسمت $P(w1 \mid d1, e1) = P(w1 \mid d1, e1, h1)$.

د) در اینجا می خواهیم ببینیم اضافه شدن f1 یعنی کم بودن وقت آزاد، چه اثری روی احتمال مثبت شدن تست کلسترول t1 دارد. در اینجا مسیر $F \rightarrow E \leftarrow H \rightarrow D \rightarrow C \rightarrow T$ را داریم. از بالا شروع می کنیم که روی E، v-structure داریم. $F \rightarrow E$ مثبت و $H \rightarrow E$ منفی است. وقتی می دانیم e1 رخ داده است، اگر f1 هم درست باشد، یعنی فرد با وجود وقت آزاد کم ورزش کرده است. در نتیجه احتمال اینکه عامل دیگری مثل سلامت محور بودن H باعث ورزش شده باشد بیشتر می شود. پس f1 باعث افزایش احتمال h1 می شود. حال در ادامه مسیر داریم $H \rightarrow D$ مثبت و $D \rightarrow C$ منفی و $C \rightarrow T$ مثبت. یعنی افزایش H باعث افزایش رژیم خوب D می شود. رژیم خوب باعث کاهش کلسترول بالا C می شود. کاهش کلسترول بالا هم احتمال مثبت شدن تست T را کم می کند. پس اثر کلی f1 روی t1 منفی است و داریم

$$P(t1 \mid w0, e1) > P(t1 \mid w0, e1, f1)$$

بخش سوم

زیربخش اول

توزیع توام کامل یعنی باید احتمال تمام حالت های ممکن برای ترکیب متغیر ها را مشخص کنیم. تعداد n تا متغیر داریم که هر کدام می توانند L حالت داشته باشند. پس کل حالت ها برای محاسبه جدول کامل احتمال توام برابر L^n حالت است که البته حالت نهایی را می توان از جمع زدن تمام حالت های دیگر و تفریق آنها از 1 به دست آورد و بنابراین باید L^n-1 پارامتر مستقل محاسبه شود.

زیربخش دوم

در شبکه بیزی، برای هر متغیر باید جدول احتمال شرطی آن نسبت به والد هایش را مشخص کنیم. اگر یک متغیر k والد داشته باشد و هر متغیر L مقدار ممکن بگیرد، تعداد حالت های ممکن برای والد ها برابر L^k است. برای هر حالت از والد ها، توزیع احتمال متغیر مورد نظر روی L مقدار ممکن تعریف می شود، اما چون مجموع احتمال ها باید برابر 1 باشد، فقط L - 1 پارامتر مستقل نیاز داریم. بنابراین تعداد پارامترهای مستقل برای یک گره با k والد برابر است با $L^k(L-1)$. چون شبکه دارای n گره است (و هر گره حداکثر n والد دارد)، یک کران بالای ساده برای تعداد کل پارامترهای مستقل برابر است با $nL^k(L-1)$.

زیربخش سوم

برای مشخص کردن کامل این شبکه بیزی، ابتدا باید توزیع متغیر C را مشخص کنیم. چون C دارای m مقدار ممکن است و والدی ندارد، برای آن به m - 1 پارامتر مستقل نیاز داریم. متغیر X1 فقط والد C را دارد. بنابراین برای هر مقدار ممکن C باید یک توزیع احتمال روی X1 مشخص شود. چون C دارای m مقدار و X1 دارای L مقدار است، تعداد پارامترهای مستقل مربوط به X1 برابر m(L - 1) می شود. برای هر متغیر Xi با $i \geq 2$، والد ها برابر C و X_{i-1} هستند. تعداد حالت های ممکن والد ها برابر mL است و برای هر حالت، چون Xi دارای L مقدار ممکن است، به L - 1 پارامتر مستقل نیاز داریم. بنابراین هر کدام از متغیرهای X2 تا Xn به mL(L - 1) پارامتر مستقل نیاز دارند. چون تعداد این متغیرها n - 1 است، تعداد پارامترهای آنها برابر (n - 1)mL(L - 1) می شود. در نتیجه تعداد کل پارامترهای مستقل برابر است با:

$$(m - 1) + m(L - 1) + (n - 1)mL(L - 1)$$

بخش چهارم

زیربخش اول

منظور از I-equivalent این است که دو شبکه دقیقا یک مجموعه استقلال های شرطی را نمایش دهند. برای شبکه های بیزی، دو گراف وقتی I-equivalent هستند که دو شرط زیر را داشته باشند:

1. اسکلت یکسان داشته باشند. یعنی اگر جهت یال ها را حذف کنیم، ارتباط های بدون جهت بین گره ها یکی باشد .
2. v-structure های یکسان داشته باشند.

شبکه سمت چپ: در اینجا چون روی B یک v-structure داریم، پس جهت یال های $A \rightarrow B$ و $A \rightarrow C$ قابل تغییر نیستند. حال یال $D \rightarrow B$ را اگر برعکس کنیم، دو تا v-structure جدید به صورت $A \rightarrow B \leftarrow$

D و $C \rightarrow B \leftarrow D$ ساخته می شوند که در گراف اولیه وجود ندارند و شرط استقلال جدید اضافه می کنند و در نتیجه این تغییر را هم نمی توانیم بدهیم. در نهایت اگر جهت $E \rightarrow D$ را تغییر دهیم، باز هم یک v-structure جدید در $B \rightarrow D \leftarrow E$ ایجاد می شود که در گراف اولیه نیست و این را هم نمی شود تغییر داد. بنابراین در این شبکه هیچ یالی را نمی توانیم طوری برعکس کنیم که اسکلت و v-structure ها ثابت بمانند. پس شبکه بیزی دیگری که با آن I-equivalent باشد وجود ندارد.

شبکه سمت راست: در اینجا یک v-structure به صورت $B \rightarrow C \leftarrow D$ داریم و در نتیجه جهت دو یال $B \rightarrow C$ و $D \rightarrow C$ قابل تغییر نیستند زیرا این v-structure از بین می رود. اما دو یال $A \rightarrow B$ و $E \rightarrow D$ را می توان جهتشان را به صورت مستقل و یا با هم برعکس کرد که یعنی در کل می شود 3 حالت دیگر که دو حالت می شود اینکه فقط یکی از آنها تغییر کند و یک حالت هم اینکه هر دو با هم تغییر کنند. تغییر جهت انها تاثیری در روابط استقلال ندارد زیرا اسکلت کلی گراف به همان صورت A - B - C - D – E باقی می ماند و هیچ v-structure ای هم اضافه یا کم نمی شود. پس سه گراف دیگر به صورت زیر می شوند:

$A \rightarrow B \rightarrow C \leftarrow D \rightarrow E$

$A \leftarrow B \rightarrow C \leftarrow D \leftarrow E$

$A \leftarrow B \rightarrow C \leftarrow D \rightarrow E$

زیربخش دوم

یک شبکه بیزی زمانی perfect map یک توزیع است که استقلال های شرطی داخل شبکه دقیقا برابر استقلال های شرطی داخل توزیع باشند. یعنی نه استقلال اضافه نشان دهد نه استقلالی را از دست بدهد حالت های مختلف گراف را بررسی می کنم. حالت اول حالت زنجیره ای است که به دو صورت $A \rightarrow C \rightarrow B$ و $A \leftarrow C \leftarrow B$ می تواند باشد. در این صورت با شرط گذاشتن روی C، A وB مستقل اند اما در حالت عادی و بدون شرط از هم مستقل نیستند و استقلال اول در I(P) را برقرار نمی کنند پس perfect map نیستند. حالت دوم $A \leftarrow C \rightarrow B$ است که باز هم استقلال اول (بدون هیچ شرطی روی C) برقرار نیست. ساختار آخر هم v-structure است که به صورت $A \rightarrow C \leftarrow B$ می شود. در این حالت بدون هیچ شرط A و B از هم مستقل اند اما به شرط C از هم مستقل نیستند و در نتیجه این هم perfect map نیست. حالت حذف یال هم وجود دارد که مثلا گراف به صورت $A \rightarrow C$ و گره تکی B باشد. در این صورت هر دو شرط استقلال داده شده در I(P) برقرارند اما شرط استقلال جدید هم مانند استقلال B از C ایجاد شده که قابل قبول نیست. پس هیچ شبکه ای وجود ندارد که perfect map برای I(P) باشد.

سوال دوم: علیت

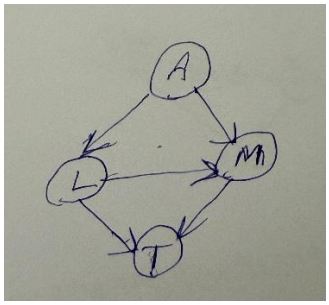
بخش اول: سوالات تئوری

زیربخش اول: نامساوی

در پرس و جو های احتمالی معمولی، رابطه $P(y) = \Sigma x\ P(y \mid x)P(x)$ برقرار است. بنابراین $P(y)$ یک میانگین وزن دار از مقادیر $P(y|x)$ است. چون وزن ها نامنفی هستند و مجموع آن ها برابر 1 است، مقدار $P(y)$ حتما بین کمترین و بیشترین مقدار $P(y|x)$ قرار می گیرد. پس نامساوی $\min_x P(y|x) \le P(y) \le \max_x P(y|x)$ برقرار است. اما در پرس و جوهای مداخله ای، $P(y|do(x))$ حاصل تغییر دادن مکانیزم طبیعی تولید X است. بنابراین معمولا رابطه $P(y) = \Sigma x\ P(y \mid do(x))P(x)$ برقرار نیست و در نتیجه $P(y)$ لزوما میانگین وزن دار مقادیر $P(y|do(x))$ نیست. مثلا این مثال را می زنم: $U \sim Bernoulli(0.5)$، $X = U$ و $Y = X\ XOR\ U$. در حالت مشاهده ای چون همیشه $X = U$ است، داریم $Y = 0$ و بنابراین $P(Y=1)=0$. اما اگر $do(X=0)$ انجام دهیم، $Y=U$ و در نتیجه $P(Y=1|do(X=0))=0.5$. همچنین اگر $do(X=1)$ انجام دهیم، $Y=1-U$ و در نتیجه $P(Y=1|do(X=1))=0.5$. پس کمینه و بیشینه مقدارهای مداخله ای هر دو برابر 0.5 هستند، اما $P(Y=1)=0$ است. بنابراین نامساوی مداخله ای برقرار نیست.

زیربخش دوم: اثر علی

گراف به صورت زیر می شود:



شکل 2. گراف متناظر با مدل علی ساختاری

در این گراف، متغیر A هم روی L اثر می گذارد و هم روی M طبق $L \leftarrow A \rightarrow M$. عبارت $E[M \mid L]$ فقط یک رابطه مشاهده ای را نشان می دهد و اثر علی خالص بار CPU روی مصرف حافظه نیست، زیرا اثر سن سرور نیز در آن دخالت دارد. اما اگر روی A شرط بگذاریم، مسیر $L \leftarrow A \rightarrow M$ بسته می شود و M و L به شرط A از هم مستقل می شوند. بنابراین بین دو عبارت داده شده، عبارت $E[M \mid L, A]$ اثر علی بار CPU روی مصرف حافظه را بهتر نشان می دهد زیرا سن سرور را می دانیم.

بخش دوم: سوالات پیاده سازی

زیربخش اول: پیاده سازی SCM

در این بخش یک کلاس عمومی برای مدل علی ساختاریی SCM پیاده سازی شد. هدف از این کلاس این است که بتوان یک مدل علی را به صورت مجموعه ای از متغیرها و معادلات ساختاری آن ها تعریف کرد و سپس از روی این مدل داده تولید کرد، مداخله انجام داد و گراف علی متناظر با مدل را نمایش داد .در این پیاده سازی، هر متغیر با نام، لیست والد ها و یک معادله ساختاری به مدل اضافه می شود. معادله ساختاری مشخص می کند که مقدار هر متغیر چگونه بر اساس مقدار والدهایش و یک نویز تصادفی تولید می شود. برای حفظ ترتیب علی، هنگام اضافه کردن متغیرها فرض شده است که والدهای هر متغیر قبلا به مدل اضافه شده باشند. این کار باعث می شود هنگام نمونه برداری، مقدار هر متغیر فقط بعد از مشخص شدن مقدار والد هایش تولید شود.

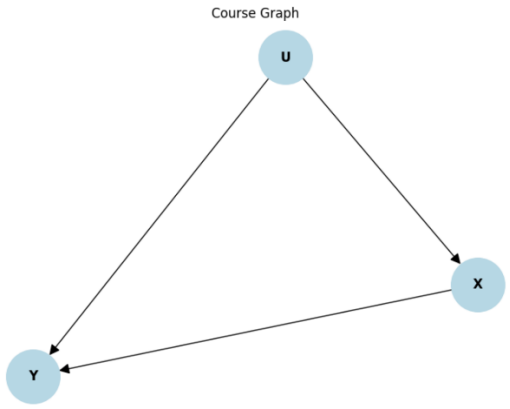
برای تولید نمونه، ابتدا گراف علی متناظر با مدل ساخته می شود و سپس متغیرها با استفاده از ترتیب توپولوژیک گراف نمونه برداری می شوند. به این ترتیب، نمونه برداری از ریشه های گراف شروع می شود و سپس به سمت فرزندان ادامه پیدا می کند. در هر نمونه، مقدار هر متغیر با اجرای معادله ساختاری خودش محاسبه می شود و در نهایت خروجی به صورت یک dataframe شامل نمونه های تولید شده برگردانده می شود.

برای پیاده سازی عملگر do ، یک نسخه جدید از مدل ساخته می شود. سپس برای هر متغیری که روی آن مداخله انجام می شود، معادله ساختاری آن متغیر با یک مقدار ثابت جایگزین می شود و والدهای آن حذف می شوند. این کار دقیقا با مفهوم مداخله در علیت سازگار است، زیرا در مداخله do ، مقدار متغیر از بیرون ثابت می شود و دیگر توسط علت های قبلی خودش تعیین نمی شود. بنابراین یال های ورودی به آن متغیر از گراف علّی حذف می شوند.

در نهایت برای نمایش گراف علی، از کتابخانه network برای ساخت گراف جهت دار و از matplotlib برای رسم آن استفاده شد. در این گراف، هر متغیر یک گره است و اگر متغیری در معادله ساختاری متغیر دیگر نقش والد داشته باشد، یک یال جهت دار از والد به فرزند رسم می شود. این قابلیت باعث می شود بتوان ساختار علی مدل را به شکل بصری بررسی کرد و مطمئن شد که روابط علی مطابق با تعریف مسئله پیاده سازی شده اند.

زیربخش دوم: تاثیر دوره آموزشی

در این بخش، مدل علی ساختاری مربوط به تاثیر دوره آموزشی روی تراز آزمون پیاده سازی شد. در این مدل، متغیر U نشان دهنده انگیزه دانش آموز است، متغیر X وضعیت ثبت نام در دوره را نشان می دهد و متغیر Y تراز آزمون است. مطابق معادلات مسئله، U از توزیع نرمال استاندارد نمونه برداری می شود. سپس X بر اساس رابطه $X = 7U + \epsilon_X > 0$ تولید می شود و در نهایت Y با رابطه $Y = 3X + 2U + \epsilon_Y$ محاسبه می شود. گراف علی این مدل به صورت زیر است:



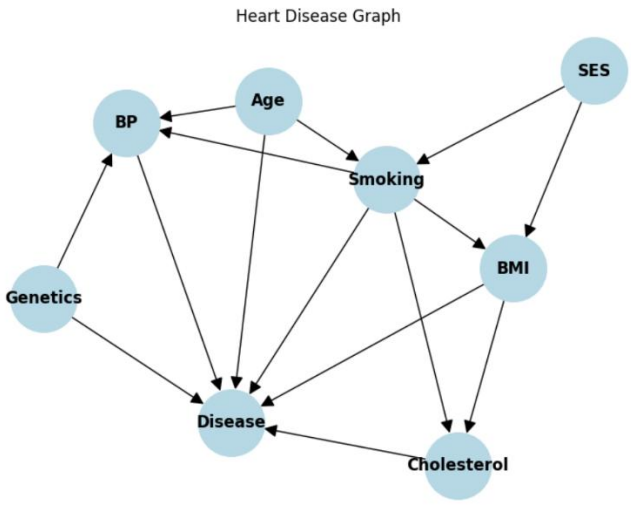
شکل 3. گراف علی دوره آموزشی

بنابراین U هم روی احتمال ثبت نام در دوره (X) اثر دارد و هم مستقیما روی تراز آزمون (Y) تاثیر می گذارد. ابتدا 10000 داده مشاهده ای از مدل تولید شد و مقدار E[Y|X=1] - E[Y|X=0] محاسبه گردید. مقدار به دست آمده تقریبا برابر 6.2 بود (زیرا چون do نزدیم، خود U هم روی X=1 یک تاثیر مضاعفی می گذارد به دلیل وجود ضریب 7 و همچنین روی Y هم به طور مستقیم با ضریب 2 تاثیر می گذارد که باعث می شود اختلاف آنها از 3 بزرگتر شود). سپس دو مدل مداخله ای با استفاده از عملگر do ساخته شد. یکی برای do(X=1) و دیگری برای do(X=0). در این حالت مقدار X از بیرون ثابت می شود و یال ورودی U → X حذف می شود. پس از تولید 10000 نمونه از هر مدل مداخله ای، مقدار E[Y|do(X=1)] - E[Y|do(X=0)] محاسبه شد که تقریبا برابر 3 به دست آمد (که اختلاف بین دو معادله سر X=1 و X=0 می شود که برابر 3 می شود به دلیل ضریب 3 روی X که دیگر مستقل از U است).

اختلاف بین مقدار مشاهده ای و مقدار مداخله ای به دلیل وجود عامل U است. دانش آموزان با انگیزه تر هم بیشتر در دوره ثبت نام می کنند و هم حتی بدون دوره تراز بالاتری می گیرند. بنابراین اختلاف مشاهده ای، اثر واقعی دوره را با اثر انگیزه مخلوط می کند و مقدار اثر را بیشتر از واقع نشان می دهد. اما در محاسبه مداخله ای، رابطه طبیعی بین U و X قطع می شود و به همین دلیل مقدار ATE اثر علی واقعی دوره آموزشی را نشان می دهد.

زیربخش سوم: سیگار نکشیم!

در این بخش، یک مدل علی ساختاری برای بررسی اثر سیگار کشیدن بر احتمال بیماری قلبی پیاده سازی شد. متغیرهای مدل شامل سن، وضعیت اجتماعی اقتصادی، ریسک ژنتیکی، سیگاری بودن، شاخص توده بدنی، فشار خون، کلسترول و احتمال بیماری قلبی هستند. مطابق معادلات ساختاری مسئله، متغیرهای Age، SES و Genetics به عنوان متغیرهای پایه و بدون والد در نظر گرفته شدند. سپس متغیر Smoking بر اساس Age و SES تولید شد. متغیر BMI تحت تاثیر Smoking و SES قرار دارد. متغیر BP تحت تاثیر Smoking، Age و Genetics است. متغیر Cholesterol نیز از Smoking و BMI تاثیر می گیرد. در نهایت، Disease با استفاده از تابع سیگموید و بر اساس Smoking ، Age، BMI، BP، Cholesterol و Genetics محاسبه شد. گراف نهایی به صورت زیر شد:



شکل 4. گراف علی بیماری قلبی

برای محاسبه اثرهای علی ATE، ATT و CATE، لازم است حالت های مداخله ای do(Smoking=1) و do(Smoking=0) با هم مقایسه شوند. در این محاسبه، برای اینکه مقایسه دقیق تر باشد، یک جمعیت ثابت تولید شد و همان جمعیت در دو حالت مداخله ای بررسی شد. دلیل این کار این است که در محاسبه اثر علی، به خصوص برای ATT و CATE، باید اثر مداخله روی همان افراد مقایسه شود نه روی دو نمونه کاملا مستقل. بنابراین ابتدا متغیرهای پایه و نویز های تصادفی یک بار تولید شدند و سپس با ثابت نگه داشتن آن ها، مقدار Disease در دو حالت do(Smoking=1) و do(Smoking=0) محاسبه شد.

گراف علی مدل نشان می دهد که سیگار کشیدن هم اثر مستقیم روی احتمال بیماری قلبی دارد و هم از طریق مسیرهای غیرمستقیم روی آن اثر می گذارد. مسیرهای غیرمستقیم شامل اثر Smoking روی BMI ، BP و Cholesterol و سپس اثر این متغیرها روی Disease هستند. بنابراین انتظار داریم مداخله روی Smoking بتواند مقدار Disease را تغییر دهد.

برای محاسبه اثر علی، ابتدا یک جمعیت ثابت با 10000 نمونه تولید شد. سپس برای همین جمعیت، سه حالت مختلف محاسبه شد: حالت مشاهده ای، حالت مداخله ای do(Smoking=1) ، و حالت مداخله ای do(Smoking=0). در حالت مشاهده ای، مقدار Smoking طبق معادله ساختاری خودش و بر اساس Age و SES تولید می شود. اما در حالت مداخله ای، مقدار Smoking از بیرون ثابت می شود و دیگر تحت تاثیر والد های خود قرار نمی گیرد. این دقیقا همان مفهوم مداخله do در مدل های علی است.

برای محاسبه ATE، میانگین Disease در حالت do(Smoking=1) از میانگین Disease در حالت do(Smoking=0) کم شد. مقدار به دست آمده تقریبا برابر 0.097 بود. این یعنی اگر کل جمعیت سیگاری شوند، احتمال بیماری قلبی به طور متوسط حدود 9.7 درصد بیشتر از حالتی می شود که هیچ کس سیگاری نباشد.

برای محاسبه ATT، ابتدا افرادی که در داده مشاهده ای واقعا سیگاری بودند شناسایی شدند. سپس اثر مداخله فقط برای همین افراد محاسبه شد. مقدار ATT تقریبا برابر 0.098 به دست آمد. این مقدار نشان می دهد که برای افرادی که واقعا سیگاری هستند، سیگار کشیدن احتمال بیماری قلبی را حدود 9.8 درصد افزایش داده است.

برای محاسبه CATE ، جمعیت بر اساس سن به دو گروه تقسیم شد: افراد با سن بیشتر از 55 سال و افراد با سن 55 سال یا کمتر. مقدار CATE برای گروه بالای 55 سال تقریبا برابر 0.121 و برای گروه 55 سال یا کمتر تقریبا برابر 0.087 به دست آمد. بنابراین اثر سیگار برای افراد مسن تر بیشتر است. این نتیجه منطقی است، زیرا سن خودش یکی از عوامل افزایش ریسک بیماری قلبی است و در مدل هم به صورت مستقیم و غیرمستقیم روی احتمال بیماری اثر دارد.

در مجموع، نتایج نشان می دهند که سیگار کشیدن اثر علّی مثبت و قابل توجهی روی احتمال بیماری قلبی دارد. همچنین این اثر برای افراد مسن تر شدیدتر است. بنابراین از دیدگاه بهداشت عمومی، ترک سیگار می تواند باعث کاهش ریسک بیماری قلبی شود و این موضوع به خصوص برای افراد بالای 55 سال اهمیت بیشتری دارد.

زیربخش چهارم: قالب جدید وب سایت

در این بخش هدف این است که بررسی کنیم آیا چیدمان جدید وب سایت واقعا باعث افزایش زمان سپری شده کاربران در سایت شده است یا خیر. در نگاه اولیه، مدیر محصول مشاهده کرده است که میانگین زمان سپری شده در چیدمان جدید کمتر از چیدمان قدیمی است و به همین دلیل قصد دارد پروژه را لغو کند. اما چون تخصیص چیدمان به کاربران تصادفی نبوده و گروه سنی کاربران در این تخصیص نقش داشته است، تحلیل خام می تواند گمراه کننده باشد. بنابراین باید با استفاده از استنباط علی بررسی کنیم که آیا چیدمان جدید واقعا بدتر است یا فقط به دلیل وجود متغیر مخدوش کننده، بدتر دیده می شود.

در این داده ها سه متغیر اصلی وجود دارد. متغیر layout نشان می دهد کاربر چیدمان قدیمی یا جدید را دریافت کرده است. متغیر age_group گروه سنی کاربر را نشان می دهد و متغیر time_spent مقدار زمان سپری شده کاربر در سایت است. برای تحلیل رگرسیون، متغیر new_layout را تعریف کردم که برای چیدمان جدید مقدار 1 و برای چیدمان قدیمی مقدار 0 می گیرد.

بخش اول: تحلیل ساده لوحانه

ابتدا میانگین زمان سپری شده برای دو چیدمان محاسبه شد. نتیجه به صورت زیر بود:

New_Layout: 9.73
Old_Layout: 12.50

بنابراین در نگاه خام، کاربران در چیدمان جدید به طور میانگین زمان کمتری نسبت به چیدمان قدیمی در سایت سپری کرده اند. اختلاف خام برابر است با:

9.73 - 12.50 = -2.77

سپس یک مدل رگرسیون خطی ساده با فرم زیر فیت شد:

time_spent ~ new_layout

در این مدل، ضریب مربوط به چیدمان جدید برابر 2.77- به دست آمد و p-value آن برابر 7.64e-23 بود. این p-value بسیار کوچک است و بنابراین در تحلیل خام این ضریب از نظر آماری معنادار است. اگر فقط همین تحلیل را در نظر بگیریم، نتیجه این است که چیدمان جدید حدود 2.77 دقیقه زمان سپری شده کاربران را کاهش داده است. بنابراین یک تحلیل گر ساده لوح ممکن است به مدیر محصول پیشنهاد کند که پروژه چیدمان جدید لغو شود.

اما این نتیجه هنوز یک نتیجه علی معتبر نیست زیرا در مدل ساده فقط رابطه بین layout و time_spent بررسی شده و متغیر age_group کنترل نشده است. اگر age_group هم روی دریافت چیدمان اثر داشته باشد و هم روی زمان سپری شده در سایت، آنگاه یک متغیر مخدوش کننده است و می تواند نتیجه خام را گمراه کند.

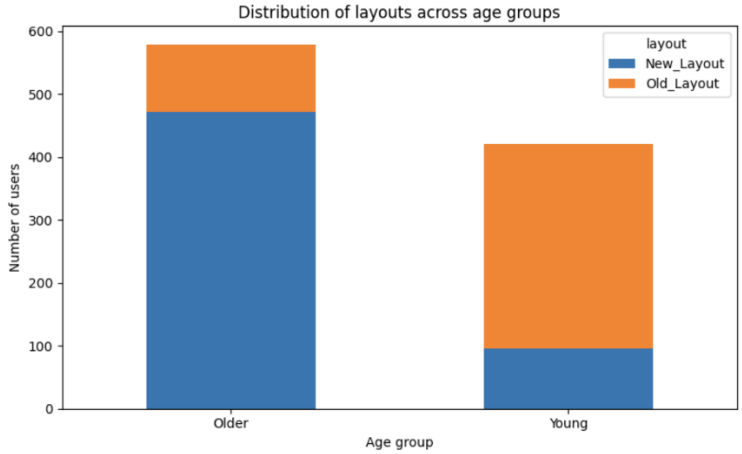
بخش دوم: تشخیص بصری

برای بررسی وجود مخدوش کنندگی، ابتدا توزیع گروه های سنی در میان دو چیدمان بررسی شد. تعداد کاربران در هر گروه به صورت زیر بود:

Older:
New_Layout = 471
Old_Layout = 108

Young:
New_Layout = 96
Old_Layout = 325

این نشان می دهد که توزیع چیدمان بین گروه های سنی متعادل نیست. بیشتر کاربران مسن تر چیدمان جدید را دریافت کرده اند، در حالی که بیشتر کاربران جوان تر چیدمان قدیمی را دریافت کرده اند. این موضوع اهمیت زیادی دارد زیرا اگر گروه های سنی مختلف به طور طبیعی زمان متفاوتی در سایت سپری کنند، مقایسه مستقیم میانگین چیدمان جدید و قدیمی گمراه کننده خواهد بود.



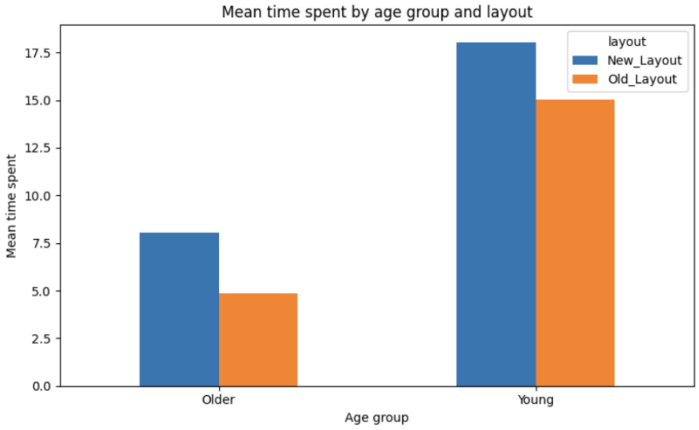
شکل ۵. نمودار توزیع چیدمان بین گروه های سنی

در ادامه، میانگین زمان سپری شده به تفکیک گروه سنی و چیدمان محاسبه شد. نتایج به صورت زیر بود:

Older, New_Layout = 8.04
Older, Old_Layout = 4.88

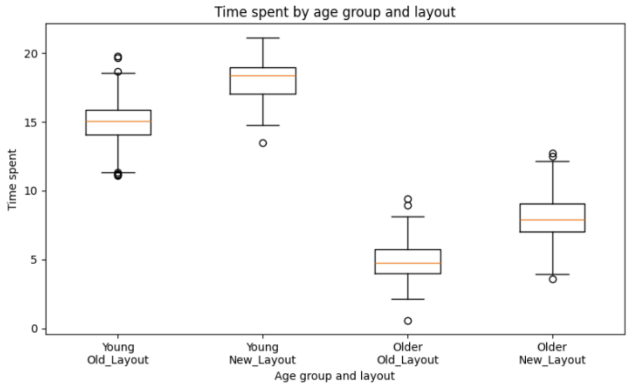
Young, New_Layout = 18.05
Young, Old_Layout = 15.03

این نتایج نشان می دهد که در هر دو گروه سنی، چیدمان جدید بهتر از چیدمان قدیمی عمل کرده است. برای کاربران Older ، چیدمان جدید میانگین زمان را از 4.88 به 8.04 افزایش داده است. برای کاربران Young هم چیدمان جدید میانگین زمان را از 15.03 به 18.05 افزایش داده است. بنابراین داخل هر گروه سنی، چیدمان جدید باعث افزایش زمان سپری شده شده است.



شکل 6. نمودار میانگین زمان سپری شده به تفکیک گروه سنی و چیدمان

برای بررسی توزیع داده ها، نمودار جعبه ای نیز رسم شد. این نمودار نشان می دهد که نه فقط میانگین ها، بلکه توزیع کلی زمان سپری شده در هر گروه سنی نیز برای چیدمان جدید بالاتر از چیدمان قدیمی قرار دارد. در گروه Young ، زمان سپری شده به طور کلی بیشتر از گروه Older است و در هر دو گروه، New_Layout بالاتر از Old_Layout دیده می شود.



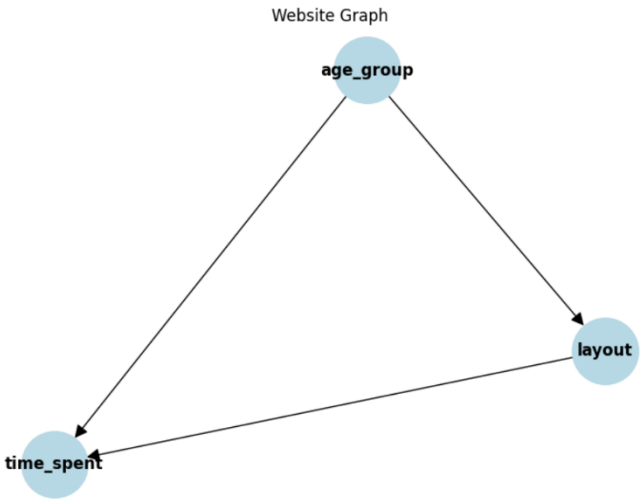
شکل 7. نمودار جعبه ای توزیع داده ها

بنابراین یک تناقض ظاهری در داده ها وجود دارد. در میانگین کل، چیدمان جدید بدتر دیده می شود، اما در هر گروه سنی، چیدمان جدید بهتر است. دلیل این اتفاق این است که چیدمان جدید بیشتر به گروه Older داده شده است که گروهی است که به طور کلی زمان کمتری در سایت سپری می کند. از طرف دیگر، چیدمان قدیمی بیشتر به گروه Young داده شده است که گروهی که به طور کلی زمان بیشتری در سایت سپری می کند. به همین دلیل، میانگین کل گمراه کننده است.

این پدیده نمونه ای از پارادوکس سیمپسون است. در پارادوکس سیمپسون، نتیجه کلی داده ها با نتیجه داخل زیرگروه ها متفاوت می شود. در اینجا اگر کل کاربران را بدون توجه به age_group بررسی کنیم، چیدمان جدید بدتر به نظر می رسد. اما وقتی داده ها را بر اساس age_group جدا می کنیم، می بینیم چیدمان جدید در هر دو گروه سنی بهتر است.

بخش سوم: حل مسئله علی

برای گراف، age_group یک متغیر مخدوش کننده است. دلیل آن این است که age_group هم روی layout اثر دارد (زیرا در فرایند عرضه تدریجی، کاربران بر اساس گروه سنی با احتمال متفاوتی چیدمان جدید یا قدیمی را دریافت کرده اند) و هم روی time_spent اثر دارد (زیرا کاربران جوان و مسن رفتار متفاوتی در سایت دارند). اگر age_group را کنترل نکنیم، اثر چیدمان با اثر گروه سنی مخلوط می شود. بنابراین برای تخمین بهتر اثر علی layout روی time_spent باید age_group را در مدل کنترل کنیم. گراف به صورت زیر شد:



شکل 8. گراف علی وب سایت

برای کنترل مخدوش کننده، رگرسیون چندمتغیره زیر اجرا شد:

time_spent ~ new_layout + age_group

در این مدل، ضریب new_layout برابر 3.09+ به دست آمد و p-value آن برابر 1.65e-199 بود. این مقدار نشان می دهد که بعد از کنترل گروه سنی، چیدمان جدید به طور متوسط حدود 3.09 دقیقه زمان سپری شده کاربران را افزایش می دهد. همچنین چون p-value بسیار کوچک است، این اثر از نظر آماری معنادار است.

نکته مهم این است که علامت ضریب تغییر کرده است. در رگرسیون ساده، ضریب new_layout برابر 2.77- بود، اما در رگرسیون کنترل شده برابر 3.09+ شد. علت این تغییر علامت، وجود متغیر مخدوش کننده age_group است. در تحلیل ساده، چون کاربران Older بیشتر چیدمان جدید گرفته بودند و این گروه به طور کلی زمان کمتری در سایت سپری می کند، اثر چیدمان جدید به اشتباه منفی دیده شد. اما بعد از کنترل age_group ، مقایسه بین کاربران هم گروه انجام می شود و اثر واقعی تر چیدمان مشخص می گردد. بنابراین توصیه نهایی به مدیر محصول این است که پروژه چیدمان جدید لغو نشود. داده خام گمراه کننده بوده است. بعد از کنترل مخدوش کننده، مشخص شد که چیدمان جدید در واقع باعث افزایش زمان سپری شده کاربران در سایت می شود و عملکرد خوبی دارد. بنابراین بهتر است عرضه چیدمان جدید ادامه پیدا کند.

بخش چهارم: تست دارونما

برای بررسی پایداری نتیجه، تست دارونما انجام شد. در این تست، ستون چیدمان به صورت تصادفی بر هم زده شد و سپس همان مدل رگرسیون کنترل شده دوباره اجرا شد:

time_spent ~ placebo_layout + age_group

اگر تحلیل و کنترل ما معتبر باشد، انتظار داریم ضریب placebo_layout نزدیک صفر باشد، زیرا این متغیر تصادفی شده دیگر نباید رابطه واقعی با زمان سپری شده داشته باشد. در خروجی تست دارونما، ضریب placebo_layout برابر 0.043- و p-value آن برابر 0.729 به دست آمد .این ضریب بسیار نزدیک به صفر است و p-value آن بزرگ تر از 0.05 است، پس از نظر آماری معنادار نیست. این نتیجه دقیقا همان چیزی است که انتظار داشتیم. وقتی چیدمان به صورت تصادفی بر هم زده می شود، اثر آن از بین می رود. بنابراین اثر مثبت مشاهده شده برای چیدمان واقعی، صرفا یک رابطه تصادفی یا مصنوعی نیست.

این تست نتیجه گیری ما را محکم تر و قابل اعتمادتر می کند، زیرا نشان می دهد که مدل کنترل شده فقط به طور تصادفی یک اثر مثبت پیدا نکرده است. وقتی متغیر layout واقعی استفاده می شود، بعد از کنترل age_group اثر مثبت و معنادار دیده می شود. اما وقتی layout تصادفی شده استفاده می شود، اثر تقریبا

صفر و غیرمعنادار می شود. بنابراین می توان با اطمینان بیشتری گفت که چیدمان جدید واقعا عملکرد بهتری دارد.

جمع بندی نهایی

در تحلیل خام، چیدمان جدید بدتر دیده شد، زیرا میانگین time_spent برای New_Layout برابر 9.73 و برای Old_Layout برابر 12.50 بود. رگرسیون ساده نیز ضریب 2.77- را برای چیدمان جدید نشان داد. اما این تحلیل خام به دلیل وجود متغیر مخدوش کننده age_group گمراه کننده بود. بررسی های بصری نشان داد که چیدمان جدید بیشتر به کاربران Older و چیدمان قدیمی بیشتر به کاربران Young داده شده است. همچنین کاربران Young به طور کلی زمان بیشتری در سایت سپری می کنند. بنابراین میانگین کل دچار پارادوکس سیمپسون شده است .بعد از کنترل age_group در رگرسیون چندمتغیره، ضریب چیدمان جدید مثبت شد و مقدار آن به 3.09+ رسید. این یعنی چیدمان جدید به طور متوسط حدود 3.09 دقیقه زمان سپری شده را افزایش می دهد. همچنین تست دارونما نشان داد که وقتی چیدمان به صورت تصادفی بر هم زده می شود، ضریب آن تقریبا صفر و غیرمعنادار می شود. بنابراین نتیجه نهایی این است که چیدمان جدید واقعا عملکرد خوبی دارد و نباید پروژه لغو شود.

مراجع