به نام خدا

دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

هوش مصنوعی قابل اعتماد

تمرین چهارم

نام و نام خانوادگی	امین آقاکثیری
شماره دانشجویی	810101381
تاریخ ارسال گزارش	1405/5/2

فهرست

سوال اول: **fairness** 4

بخش اول: مبانی و نظریه 4

پرسش 1: (سه معیار مشاهده ای) 4

پرسش 2: (استخراج یک نتیجه عدم امکان (اتحاد چولدچوا)) 7

پرسش 3: (انصاف علی و خلاف واقع) 10

بخش دوم: پرسش های مفهومی و کاربردی 13

پرسش 4: (مسئله جانشین/برچسب در سلامت) 13

پرسش 5: (انتخاب معیار، تحت قید عدم امکان (اعطای وام)) 15

پرسش 6: (داوری مناقشه COMPAS (در پیوند با بخش اول)) 17

پرسش 7: (فراتر از انصاف حاشیه ای: زیرگروه ها و زمان) 20

بخش سوم: پیاده سازی و تحلیل تجربی 22

مرحله 0 - بازتولیدپذیری 22

مرحله 1 – ممیزی سوگیری 22

مرحله 2 – مدل پایه و سنجه های دست ساز 25

مرحله 3 – آزمون <<انصاف از طریق ناآگاهی>> 28

مرحله 4 – تعدیل و مقایسه 29

مرحله 5 – عدم امکان تجربی و مرز بده بستان 32

مرحله 6 – ممیزی تقاطعی 36

سوال دوم: حریم خصوصی در یادگیری ماشین و یادگیری فدرال 39

بخش اول: سوالات توضیحی 39

زیربخش اول: (حساسیت و مکانیزم لاپلاس) 39

زیربخش دوم: (انتشار خصوصی داده ها و report noisy max) 40

زیربخش سوم: (تخصیص بودجه حریم خصوصی و ترکیب مکانیزم ها) 42

بخش دوم: سوالات مفهومی 44
زیربخش اول: (حریم خصوصی، استحکام و یادگیری فدرال) 44
زیربخش دوم: (حملات حریم خصوصی و مسموم سازی در یادگیری فدرال) 47
زیربخش سوم: (مکانیزم های دفاعی و مبادله حریم خصوصی – استحکام - سودمندی) 51
بخش سوم: سوالات پیاده سازی 55
زیربخش اول: (آماده سازی داده ها) 55
زیربخش دوم: (آموزش مدل فدرال) 60
زیربخش سوم: (ارزیابی حملات Membership Inference) 63
زیربخش چهارم: (دفاع مبتنی بر Differential Privacy) 67
اظهارنامه استفاده از هوش مصنوعی 74
مراجع 77

سوال اول: fairness

بخش اول: مبانی و نظریه

پرسش ۱: (سه معیار مشاهده ای)

الف)

معیار استقلال (Independence): این معیار (که به آن acceptance rate هم می گویند) می گوید که برچسب پیش بینی شده (یا R) توسط مدل مستقل از ویژگی حساس (A) باشد. پس گزاره زیر باید برقرار باشد:

$$R \perp A$$

معیار جداسازی (Seperation): این معیار می گوید که error rate برای گروه های مختلف یک ویژگی یکسان باشد و در واقع نتیجه طبقه بندی به شرط دانستن برچسب واقعی، مستقل از نوع گروه ها باشد. پس گزاره زیر باید برقرار باشد:

$$R \perp A \mid Y$$

معیار بسندگی (Sufficiency): این معیار می گوید که برچسب واقعی به شرط دانستن خروجی مدل از ویژگی حساس مستقل باشد. یعنی اگر دو نفر از دو گروه مختلف امتیاز یکسانی گرفته باشند، احتمال واقعی مثبت بودن آن ها باید یکسان باشد. پس گزاره زیر باید برقرار باشد

$$Y \perp A \mid R$$

ب)

معیار استقلال: برای این معیار، مثلا برای یک گروه حساس که مقادیرش می تواند a یا b باشد، احتمال یک شدن خروجی مدل برای هر دو گروه باید برابر باشد تا این معیار برقرار باشد. در حالت دو دویی، این احتمال به این معناست که نرخ پذیرش در همه گروه ها یکسان باشد و برابری جمعیتی نامیده می شود که به صورت زیر است:

$$\mathbb{P}\{\widehat{Y}=1 \mid A=a\}=\mathbb{P}\{\widehat{Y}=1 \mid A=b\}$$

معیار جداسازی: در حالت دو دویی در واقع باید TPR (که رابطه اول در پایین است و همان 1-FNR است) و FPR برای هر دو گروه یکسان باشند. معیار استانداردی که این شرط را نمونه سازی می کند برابری شانس ها است. اگر فقط شرط اول را بخواهیم، یعنی فقط TPR بین گروه ها برابر باشد، به آن فرصت برابر می گویند. احتمال ها به صورت زیر می شوند:

$$\mathbb{P}\{\widehat{Y}=1 \mid Y=1, A=a\}=\mathbb{P}\{\widehat{Y}=1 \mid Y=1, A=b\}$$
$$\mathbb{P}\{\widehat{Y}=1 \mid Y=0, A=a\}=\mathbb{P}\{\widehat{Y}=1 \mid Y=0, A=b\}$$

معیار بسندگی: در اینجا اگر دو نفر از دو گروه مختلف امتیاز یکسانی گرفته باشند، احتمال واقعی مثبت بودن آن ها باید یکسان باشد. در حالت دو دویی این معیار به برابری ارزش های پیش بینی مربوط می شود. احتمال آن به صورت زیر می شود:

precision ← $P(Y=1 \mid \hat{Y}=1, A=a) = P(Y=1 \mid \hat{Y}=1, A=b)$

negative predictive value ← $P(Y=1 \mid \hat{Y}=0, A=a) = P(Y=1 \mid \hat{Y}=0, A=b)$

این معیار ارتباط نزدیکی با کالیبراسیون دارد و یعنی یک امتیاز مشخص باید در همه گروه ها معنای احتمالاتی یکسانی داشته باشد.

ج)

معیار استقلال: شهود این معیار این است که عضویت در یک گروه حساس (مثل جنسیت یا نژاد)، نباید به خودی خود باعث کاهش دسترسی افراد به یک فرصت شود. مثلا در مرحله دعوت اولیه به مصاحبه شغلی، اگر هدف این باشد که فرصت اولیه به شکل برابر بین گروه ها توزیع شود، این معیار می تواند موجه باشد زیرا می خواهد جلوی این را بگیرد که یک گروه به طور سیستماتیک کمتر دیده شود یا دیگری بیشتر وارد فرایند انتخاب شود.

معیار جداسازی: شهود این معیار این است که افراد با وضعیت واقعی یکسان، باید نرخ خطای مشابهی داشته باشند. مثلا در تشخیص یک بیماری، اگر دو بیمار از دو گروه مختلف واقعا بیمار باشند، مدل باید با احتمال مشابهی آن ها را بیمار تشخیص دهد و اگر واقعا سالم باشند، نباید یک گروه بیشتر از گروه دیگر به اشتباه

بیمار تشخیص داده شود. در این کاربرد، برابری نرخ های خطا مهم است زیرا خطای مدل می تواند مستقیما باعث محروم شدن از درمان یا دریافت درمان غیر ضروری شود.

معیار بسندگی: شهود این معیار این است که خروجی مدل باید برای همه گروه ها معنای یکسانی داشته باشد. مثلا در یک سیستم پیش بینی ریسک تکرار جرم، اگر دو فرد از دو گروه نژادی متفاوت هر دو امتیاز ریسک بالا بگیرند، احتمال واقعی اینکه در آینده دوباره مرتکب جرم شوند باید تقریبا یکسان باشد. این معیار در چنین کاربردی موجه است زیرا قاضی، امتیاز مدل را به عنوان نشانه ای از ریسک واقعی تفسیر می کند و بنابراین نباید امتیاز بالا برای یک گروه پرخطر تر از گروه دیگر باشد.

د) چیزی که باید نشان دهیم این است که وقتی که نرخ پایه در دو گروه متفاوت باشد (مطابق صورت سوال)، استقلال و بسندگی در حالت کلی نمی توانند همزمان برقرار باشند. برای اثبات از برهان خلف استفاده می کنم. فرض کنیم هر دو معیار همزمان برقرار باشند. طبق قسمت های الف و ب، توزیع امتیاز R در همه گروه ها یکسان است (طبق معیار استقلال) و همچنین برای هر مقدار امتیاز r، احتمال مثبت واقعی بودن فقط به خود امتیاز بستگی دارد نه به گروه (طبق معیار بسندگی). حال نرخ پایه گروه A=a به صورت زیر می شود (با استفاده از قانون احتمال کل):

$$P(Y = 1 \mid A = a) = \sum_{r} P(Y = 1 \mid R = r, A = a)P(R = r \mid A = a)$$

اما طبق بسندگی، جمله اول در جمع برای همه گروه ها یکسان است. همچنین طبق استقلال، جمله دوم یعنی توزیع R برای همه گروه ها یکسان است. پس کل جمع برای همه گروه ها یکسان می شود. بنابراین باید داشته باشیم:

$$P(Y = 1 \mid A = 0) = P(Y = 1 \mid A = 1)$$

اما این دقیقا با فرض سوال تناقض دارد زیرا فرض کرده بودیم نرخ های پایه در گروه ها متفاوت اند. پس وقتی نرخ پایه بین گروه ها متفاوت است، اگر امتیاز مدل در همه گروه ها توزیع یکسانی داشته باشد و همزمان معنای هر امتیاز هم در همه گروه ها یکسان باشد، نتیجه می شود که نرخ واقعی مثبت بودن هم باید در همه گروه ها یکسان باشد. چون این درست نیست، حداقل یکی از دو معیار باید نقض شود.

پرسش ۲: (استخراج یک نتیجه عدم امکان (اتحاد چولدچوا))

الف) مقدار PPV یعنی اینکه از بین افرادی که مدل آن ها را مثبت پیش بینی کرده است، چه نسبتی واقعا مثبت بوده اند. بر اساس TP و FP، مقدار آن به صورت زیر می شود:

$$PPV = \frac{TP}{TP + FP}$$

همچنین طبق صورت سوال، نرخ پایه برابر p است و در نتیجه P(Y = 0) برابر 1- p می شود. همچنین طبق تعریف FNR داریم:

$$P\left(\hat{Y} = 1 \mid Y = 1\right) = 1 - FNR$$

حال TP و FP را بر اساس نرخ پایه و FNR و FPR می نویسم. مقدار TP به صورت زیر می شود:

$$TP = P\left(Y = 1, \hat{Y} = 1\right)$$

$$TP = P\left(\hat{Y} = 1 \mid Y = 1\right)P(Y = 1)$$

$$TP = p(1 - FNR)$$

همچنین مقدار FP برابر است با:

$$FP = P\left(Y = 0, \hat{Y} = 1\right)$$

$$FP = P\left(\hat{Y} = 1 \mid Y = 0\right)P(Y = 0)$$

و با توجه به اینکه:

$$FPR = P\left(\hat{Y} = 1 \mid Y = 0\right)$$

پس داریم:

$$FP = (1 - p)FPR$$

حال این دو مقدار به دست آمده برای TP و FP را در فرمول PPV می گذاریم:

$$PPV = \frac{p(1 - FNR)}{p(1 - FNR) + (1 - p)FPR}$$

حال معادله را باز می کنیم و بر حسب FPR می نویسیم که در نهایت به صورت زیر می شود:

$$FPR = \frac{p(1 - FNR)(1 - PPV)}{(1 - p)PPV}$$

پس عبارت بالا همان عبارتی است که در صورت سوال خواسته شده:

$$FPR = \frac{p}{1-p} \cdot \frac{1-PPV}{PPV} \cdot (1-FNR)$$

ب) نرخ پایه دو گروه متفاوت است. پس داریم:

$$P(Y=1 \mid A=0) \neq P(Y=1 \mid A=1)$$

و برای دو گروه داریم:

$$FPR_0 = \frac{p_0}{1-p_0} \cdot \frac{1-PPV_0}{PPV_0} \cdot (1-FNR_0)$$

$$FPR_1 = \frac{p_1}{1-p_1} \cdot \frac{1-PPV_1}{PPV_1} \cdot (1-FNR_1)$$

طبق سوال، PPV هر دو گروه یکسان است و هر دو را x نام گذاری می کنیم. پس:

$$FPR_0 = \frac{p_0}{1-p_0} \cdot \frac{1-x}{x} \cdot (1-FNR_0)$$

$$FPR_1 = \frac{p_1}{1-p_1} \cdot \frac{1-x}{x} \cdot (1-FNR_1)$$

حال می خواهیم ببینیم آیا ممکن است همزمان FPR و FNR هم در دو گروه برابر باشند یا نه. از برهان خلف استفاده می کنیم و فرض کنیم چنین چیزی ممکن باشد. مقدار هر دو FNR ها را برابر y می گیریم. همچنین FPR ها هم که برابر هستند طبق فرض. پس دو رابطه بالا با هم به صورت زیر برابر می شوند:

$$\frac{p_0}{1-p_0} \cdot \frac{1-x}{x} \cdot (1-y) = \frac{p_1}{1-p_1} \cdot \frac{1-x}{x} \cdot (1-y)$$

حال اگر در حالت عادی و غیر تباهیده (غیر مرزی) باشیم، یعنی اینکه:

$$0 < x < 1$$

$$y < 1$$

آنگاه عبارت زیر صفر نمی شود:

$$\frac{1-x}{x} \cdot (1-y)$$

پس می توانیم آن را از دو طرف حذف کنیم و داریم:

$$\frac{p_0}{1-p_0} = \frac{p_1}{1-p_1}$$

برای برابر بودن اینها نیاز است که $p_0 = p_1$ باشد که خلاف فرض اصلی مسئله است و در نتیجه با برهان خلف، حکم مسئله ثابت شد. حال برای حالت تباهیده یا مرزی، حالتی است که یکی از فرض های عادی بالا (که برای x و y نوشتم) از بین برود. مثلا اگر PPV=1 باشد، یعنی بین افرادی که مدل مثبت پیش بینی کرده است هیچ FP ای وجود ندارد و مدل دچار حالت مرزی بدون FP شده است. همچنین اگر FNR=1 باشد، یعنی مدل هیچ نمونه TP ای را درست مثبت تشخیص نمی دهد و عملا همه TP ها را از دست می دهد. همچنین اگر یک گروه نرخ پایه 0 یا 1 داشته باشد، یعنی در آن گروه فقط یک کلاس وجود داشته باشد، با یک حالت مرزی روبه رو هستیم. در این حالت ها رابطه ممکن است از نظر جبری به شکل خاصی برقرار شود.

ج) در مناقشه COMPAS، شرکت سازنده یعنی Northpointe بیشتر روی این نکته تاکید داشت که امتیازهای COMPAS از نظر بسندگی (sufficiency) بین گروه های نژادی مشابه عمل می کنند. یعنی اگر دو فرد از دو گروه مختلف امتیاز یکسانی بگیرند، احتمال واقعی تکرار جرم آن ها تقریبا یکسان است. در واقع Northpointe بر برابری PPV یا معنای یکسان امتیاز در گروه های مختلف تاکید می کرد. در مقابل، روزنامه نگاران نشان دادند که نرخ های خطا بین گروه ها برابر نیست. به طور خاص، افراد سیاه پوست بیشتر از افراد سفید پوست به اشتباه پرخطر پیش بینی می شدند و یعنی FPR برای آن ها بالاتر بود. همچنین افراد سفید پوست بیشتر از افراد سیاه پوست به اشتباه کم خطر پیش بینی می شدند و یعنی FNR برای آن ها بالاتر بود. پس روزنامه نگاران در واقع نقض معیار جداسازی (separation) یا همان برابری نرخ های خطا را برجسته کردند.

اتحاد چولدچوا نشان می دهد که این دو ادعا می توانند همزمان درست باشند. اگر نرخ پایه تکرار جرم در دو گروه متفاوت باشد و مدل بخواهد در هر دو گروه PPV یکسانی داشته باشد، دیگر نمی تواند در حالت غیر تباهیده به صورت همزمان FPR و FNR برابر در هر دو گروه داشته باشد. پس اختلاف ProPublica و Northpointe صرفا به این دلیل نبود که یکی از آن ها اشتباه محاسبه کرده باشد. هر دو طرف معیار متفاوتی از انصاف را در نظر گرفته بودند. Northpointe معیار بسندگی را معیار اصلی می دانست ولی ProPublica بر نابرابری نرخ های خطا تاکید داشت. با توجه به نابرابری نرخ های پایه، این تنش از نظر ریاضی اجتناب ناپذیر بود و نمی شد انتظار داشت یک مدل غیر تباهیده هر دو نوع انصاف را همزمان کامل برآورده کند.

د) این پیشنهاد فقط در صورتی درست است که مشکل از کمبود داده یا خطای نمونه گیری باشد. اما اگر در توزیع واقعی داده ها، نرخ پایه دو گروه متفاوت باشد، صرفا جمع کردن داده های بیشتر مشکل را حل نمی

کند. اگر بخواهیم در دو گروه همزمان برابری PPV و FPR و FNR وجود داشته باشد، مقادیر آنها باید دو به دو در گروه ها با هم برابر باشند. اما طبق بخش ب ثابت کردیم که اگر نرخ های پایه نابرابر باشند، برابری هر سه تای اینها به صورت همزمان در حابت غیر تباهیده ممکن نیست. پس فقط در حالت های خاصی این برابری ممکن است که یکی از آنها این است که نرخ های پایه دو گروه برابر باشند. حالت دیگر این است که مدل در یک حالت مرزی (تباهیده) باشد که در قسمت ب بررسی کردم (وجود نداشتن FP) و یا مثلا مدل هیچ نمونه مثبتی پیش بینی نکند یا یکی از گروه ها فقط شامل یک کلاس باشد.

در واقع داده های بیشتر و بهتر فقط می توانند تخمین های ما را دقیق تر کنند و نویز آماری را کاهش دهند. اگر اختلاف مشاهده شده فقط به خاطر نمونه محدود باشد، داده بیشتر ممکن است نشان دهد که نرخ های پایه واقعا برابر بوده اند یا اختلاف ها کمتر از چیزی بوده که فکر می کردیم. اما اگر در خود جامعه و توزیع واقعی، نرخ های پایه متفاوت باشند، این بده بستان از بین نمی رود. در نتیجه این مسئله صرفا یک مصنوع نمونه متناهی نیست بلکه یک محدودیت بنیادی و ریاضی است. داده بهتر می تواند اندازه گیری ما را بهتر کند اما نمی تواند ناسازگاری جبری بین این سه تا را در حالت نرخ پایه متفاوت از بین ببرد.

پرسش ۳: (انصاف علی و خلاف واقع)

الف) در انصاف خلاف واقع، برخلاف معیارهای مشاهده ای مثل برابری جمعیتی یا برابری نرخ خطا، فقط به توزیع آماری گروه ها نگاه نمی کنیم بلکه می پرسیم اگر همین فرد در یک جهان خلاف واقع، ویژگی حساس متفاوتی داشت، آیا پیش بینی مدل برای او تغییر می کرد یا نه. در مقاله هم ایده اصلی همین است که تصمیم برای یک فرد باید در جهان واقعی و در جهانی که فقط ویژگی حساس او عوض شده است، یکسان بماند. فرض کنیم یک مدل علی ساختاری به صورت (U, V, F) داریم که در آن U متغیر های پنهان یا پس زمینه ای هستند، V متغیر های مشاهده پذیر هستند و F مجموعه معادلات ساختاری است که مشخص می کند هر متغیر چگونه از والد های خود و متغیرهای پنهان به وجود می آید. همچنین A ویژگی حساس مثل جنسیت یا نژاد، X سایر ویژگی های فرد و $\hat{Y}$ خروجی یا پیش بینی مدل است. تعریف رسمی انصاف خلاف واقع این است که برای هر فرد با مشاهده های X = x و A = a، اگر مقدار ویژگی حساس را به مقدار دیگری مثل a′ تغییر دهیم، توزیع پیش بینی نباید عوض شود که آن را به صورت زیر نمایش می دهیم:

$$P\left(\widehat{Y_{A\leftarrow a}}(U) = y \mid X = x, A = a\right) = P\left(\widehat{Y_{A\leftarrow a'}}(U) = y \mid X = x, A = a\right)$$

که باید برای تمامی مقادیر y و a′ برقرار باشد. این رابطه همان تعریف Counterfactual Fairness در مقاله است.

منظور از مداخله do(A = a′) یا همان $A \leftarrow a'$ این است که معادله ساختاری مربوط به A را حذف می کنیم و به جای آن به صورت اجباری مقدار A را برابر a′ قرار می دهیم. یعنی نمی پرسیم در داده های واقعی چه کسانی A = a′ دارند بلکه می پرسیم اگر همین فرد با همان عوامل بنیادی و پس زمینه ای، ویژگی حساس دیگری داشت، خروجی مدل چه می شد. در مدل علی، مداخله دقیقا به معنی جایگزین کردن معادله یک متغیر با مقدار مداخله ای است. در این مقایسه، چیزی که ثابت نگه داشته می شود متغیرهای پنهان و زمینه ای فرد یعنی U و عوامل غیر وابسته به A است. به عبارت دیگر، همان فرد را نگه می داریم و فقط ویژگی حساس او را در جهان خلاف واقع تغییر می دهیم. اما روی خود ویژگی حساس A مداخله می کنیم و آن را از a به a′ تغییر می دهیم. سپس متغیرهایی که از نظر علی فرزند یا پیامد A هستند باید بر اساس معادلات ساختاری دوباره محاسبه شوند. پس اگر خروجی مدل به طور مستقیم یا غیر مستقیم از مسیرهای علی وابسته به A تغییر کند، مدل خلاف واقع منصف نیست. بنابراین زمانی انصاف خلاف واقع داریم که برای یک فرد خاص، تغییر دادن ویژگی حساس او در جهان خلاف واقع، در حالی که عوامل بنیادی همان فرد ثابت مانده اند، توزیع پیش بینی را تغییر ندهد و تصمیم مدل نباید به این وابسته باشد که اگر همین شخص با همان شرایط بنیادی، مثلا جنسیت یا نژاد دیگری داشت، نتیجه متفاوتی می گرفت.

ب) در این گراف دو مسیر از A به $\hat{Y}$ وجود دارد. مسیر اول که $A \rightarrow \hat{Y}$ است، یک مسیر پراکسی است. در این مسیر، جنسیت مستقیما روی امتیاز استخدام اثر می گذارد. بنابراین اگر دو فرد از نظر همه ویژگی های شغلی مشابه باشند، اما فقط جنسیت آن ها متفاوت باشد، امتیاز متفاوت می گیرند. یک پیش بین منصف باید جلوی این اثر مستقیم را بگیرد زیرا این همان استفاده تبعیض آمیز از ویژگی حساس است.

مسیر دوم که $A \rightarrow X \rightarrow \hat{Y}$ است، به سال های تجربه مربوط است. این مسیر می تواند یک مسیر تبیین کننده یا resolving باشد اما همیشه این طور نیست. اگر سال های تجربه واقعا نشان دهنده مهارت، آشنایی با کار و شایستگی شغلی باشد، می توان گفت اثر جنسیت از طریق X تا حدی مشروع است زیرا مدل در واقع دارد از تجربه کاری استفاده می کند نه از جنسیت به خودی خود. در این حالت شاید اجازه دادن به مسیر $A \rightarrow X \rightarrow \hat{Y}$ قابل دفاع باشد. اما اگر تفاوت در سال های تجربه خودش نتیجه تبعیض تاریخی، فرصت های نابرابر، مرخصی های اجباری، یا کلیشه های جنسیتی باشد، آن وقت X فقط یک متغیر خنثی و بر اساس شایستگی نیست بلکه می تواند نقش پراکسی برای جنسیت را بازی کند. در چنین حالتی، استفاده از X باعث می شود اثر تبعیض آمیز A به شکل غیر مستقیم وارد امتیاز $\hat{Y}$ شود و باید با آن هم با احتیاط برخورد کرد.

پس یک پیش بین منصف قطعا باید مسیر مستقیم $A \rightarrow \hat{Y}$ را حذف یا خنثی کند. درباره مسیر $A \rightarrow X \rightarrow \hat{Y}$ تصمیم وابسته به این است که X را یک ویژگی مشروع و مرتبط با شغل بدانیم یا نتیجه نابرابری و تبعیض گذشته. در این مواقع داده ها به تنهایی کافی نیستند. داده فقط نشان می دهد بین جنسیت، تجربه و امتیاز رابطه وجود دارد اما نمی گوید این رابطه از نظر اخلاقی یا حقوقی مجاز است یا نه. اینکه سال های تجربه در این مسئله یک معیار مشروع شایستگی است یا یک واسطه برای بازتولید تبعیض، نیازمند داوری هنجاری، حقوقی و زمینه ای است.

ج) این ادعا که «انصاف خلاف واقع عینی است و جواب را تنها مستقیما از دل ساختار علی داده ها بیرون می کشد» درست نیست. انصاف خلاف واقع از نظر فرمول بندی دقیق است اما نتیجه آن کاملا وابسته به مدل علی ای است که ما برای مسئله فرض می کنیم. خود داده های مشاهده ای به تنهایی معمولا نمی توانند یک گراف علی یکتا را تعیین کنند. حتی ممکن است چند مدل علی مختلف، توزیع مشاهده شده یکسانی روی داده ها تولید کنند اما درباره جهان خلاف واقع پاسخ های متفاوتی بدهند. در مقاله هم تاکید شده است که مدل های علی و مخصوصا فرض های خلاف واقع به فرض های قوی نیاز دارند و فقط از داده های مشاهده ای به طور کامل قابل اثبات نیستند. مثلا در همین مسئله استخدام، یک تحلیل گر ممکن است بگوید مسیر $A \rightarrow X \rightarrow \hat{Y}$ اوکی است چون X یعنی سال های تجربه واقعا نشان دهنده مهارت شغلی است. در این نگاه، اگر جنسیت روی سابقه تجربه اثر گذاشته باشد ولی تجربه یک معیار شغلی معتبر باشد، استفاده از X می تواند تا حدی قابل قبول باشد. پس این تحلیل گر ممکن است نتیجه بگیرد که مدل، اگر فقط از مسیر تجربه استفاده کند، منصف است. اما تحلیل گر دیگری با همان داده ها ممکن است گراف را طور دیگری تفسیر کند و بگوید سال های تجربه خودش نتیجه فرصت های نابرابر، تبعیض تاریخی یا کلیشه های جنسیتی است. در این صورت X دیگر یک ویژگی کاملا خنثی نیست بلکه بخشی از اثر ناعادلانه A را به مدل منتقل می کند. پس همان مدل ممکن است از نظر این تحلیل گر خلاف واقع منصف نباشد. بنابراین تفاوت نتیجه به این دلیل است که داده فقط هم بستگی ها و الگوهای آماری را نشان می دهد اما نمی گوید کدام مسیر علی از نظر اخلاقی یا حقوقی مجاز است و کدام مسیر باید مسدود شود. این تصمیم نیازمند دانش زمینه ای، قضاوت هنجاری و تفسیر حقوقی است. پس انصاف علی عینی به این معنا نیست که جواب بدون هیچ فرض یا قضاوتی مستقیما از داده بیرون می آید بلکه اگر یک مدل علی مشخص و پذیرفته شده داشته باشیم، می توانیم درون همان مدل به شکل دقیق و ریاضی درباره انصاف خلاف واقع صحبت کنیم. اما انتخاب خود مدل علی، تشخیص مسیرهای مشروع و نامشروع و تعیین اینکه چه چیزی باید ثابت بماند، کاملا به فرض های انسانی و زمینه مسئله وابسته است.

بخش دوم: پرسش های مفهومی و کاربردی

پرسش ۴: (مسئله جانشین/برچسب در سلامت)

الف) در این مسئله مهم ترین سوگیری، سوگیری اندازه گیری/ برچسب است. چون چیزی که واقعا می خواهیم پیش بینی کنیم، نیاز پزشکی یا شدت بیماری است اما سازنده مدل به جای آن از هزینه درمانی آینده به عنوان برچسب هدف استفاده کرده است. این دو یکی نیستند. هزینه درمانی فقط شدت بیماری را نشان نمی دهد بلکه به دسترسی بیمار به درمان، بیمه، توان مالی، اعتماد به سیستم درمان و سابقه استفاده از خدمات پزشکی هم وابسته است. همچنین سوگیری تاریخی هم وجود دارد. اگر یک گروه در گذشته به دلیل تبعیض، فقر، دسترسی کمتر به پزشک و یا بیمه ضعیف تر کمتر درمان گرفته باشد، هزینه درمانی ثبت شده برای آن گروه کمتر از نیاز واقعی آن خواهد بود. پس داده های گذشته نابرابری های تاریخی را در خود دارند و مدل هم همان الگو را یاد می گیرد. بنابراین مدل به جای اینکه بیمار تر بودن را یاد بگیرد، پر هزینه تر بودن را یاد می گیرد. چون در سطح بیماری برابر، بیماران گروه به حاشیه رانده شده معمولا هزینه کمتری در سیستم ثبت کرده اند، مدل آن ها را کم نیازتر تخمین می زند و در نتیجه تعداد کمتری از آن ها وارد برنامه مراقبتی می شوند. پس مسئله اصلی این نیست که مدل لزوما بد آموزش دیده بلکه این است که برچسب آموزشی از ابتدا نماینده درستی برای نیاز واقعی نبوده است.

ب) خیر. مشکل اصلی این الگوریتم فقط استفاده مستقیم از ویژگی حساس (مانند نژاد یا گروه اجتماعی) نیست. مشکل این است که متغیر هدف اشتباه انتخاب شده است. در اینجا مدل به جای نیاز واقعی پزشکی یا شدت بیماری، هزینه درمانی آینده را پیش بینی می کند. هزینه درمانی خودش تحت تاثیر نابرابری های گذشته است. مثلا اگر یک گروه در گذشته دسترسی کمتری به پزشک، بیمه یا خدمات تخصصی داشته باشد (همانطور که در بخش قبل اشاره کردم)، حتی در سطح بیماری برابر، هزینه درمانی ثبت شده برای آن گروه کمتر خواهد بود. بنابراین مدل یاد می گیرد که این گروه کم نیازتر است در حالی که واقعا ممکن است همان قدر یا حتی بیشتر نیاز پزشکی داشته باشد.

حتی اگر ویژگی حساس را حذف کنیم، بسیاری از ویژگی های دیگر می توانند مشکل ایجاد کنند. مثل محل سکونت، نوع بیمه، تعداد مراجعه های قبلی، درآمد تقریبی، بیمارستان مورد استفاده و یا سابقه هزینه های درمانی. این ویژگی ها می توانند با گروه به حاشیه رانده شده همبستگی داشته باشند و اطلاعات مربوط به آن را به طور غیر مستقیم وارد مدل کنند. پس حذف ویژگی حساس فقط جلوی تبعیض مستقیم را می گیرد

اما جلوی تبعیض غیر مستقیم و سوگیری برچسب را نمی گیرد. در این مسئله، مدل همچنان از روی هزینه های گذشته تصمیم می گیرد و چون هزینه های گذشته نشان دهنده نابرابری در دسترسی به درمان هستند، نتیجه ناعادلانه باقی می ماند. بنابراین راه حل اصلی باید اصلاح متغیر هدف و سنجش نیاز واقعی پزشکی باشد نه فقط حذف ویژگی حساس از داده ها و با حذف زیاد از حد اینها ممکن است دیگر ویژگی ای وجود نداشته باشد که مدل کلا بخواهد آموزش ببیند.

ج) معیار مناسب برای این مسئله، جداسازی یا Separation است. در اینجا نباید این معیار را نسبت به هزینه درمانی بسنجیم بلکه باید نسبت به نیاز واقعی پزشکی یا شدت بیماری واقعی بسنجیم. یعنی اگر A گروه حساس باشد و Y نشان دهد که بیمار واقعا نیازمند مراقبت فشرده است، باید بررسی کنیم آیا در میان بیمارانی که واقعا نیازمند هستند، احتمال انتخاب شدن برای برنامه در گروه های مختلف برابر است یا نه که فرمول آن به صورت زیر است:

$$\mathbb{P}\{\widehat{Y} = 1 \mid Y = 1, A = a\} = \mathbb{P}\{\widehat{Y} = 1 \mid Y = 1, A = b\}$$

در این رابطه، $Y = 1$ باید به معنای نیاز واقعی پزشکی باشد نه هزینه بالا. اگر این احتمال برای گروه به حاشیه رانده شده کمتر باشد، یعنی افراد واقعا نیازمند در آن گروه بیشتر از برنامه حذف می شوند. پس مسئله مربوط به مشکل در TPR (یا همان فرصت برابر در بخش ب پرسش اول) است .اما اگر ممیزی را در برابر هدف جانشین، یعنی هزینه درمانی آینده انجام دهیم، مشکل پنهان می ماند. زیرا مدل دقیقا برای پیش بینی هزینه آموزش دیده است و ممکن است از نظر پیش بینی هزینه، حتی دقیق به نظر برسد. ولی هزینه درمانی معیار درستی برای نیاز نیست (به همان دلایلی که در دو قسمت قبل گفتم). پس ممیزی بر اساس هزینه می گوید مدل درست کار می کند زیرا هزینه را خوب پیش بینی می کند. اما ممیزی بر اساس نیاز واقعی پزشکی نشان می دهد که مدل در حال محروم کردن یک گروه از مراقبت لازم است.

د) یک راه حل قابل پیاده سازی این است که به جای آموزش مدل با هدف هزینه درمانی آینده، متغیر هدف را به چیزی نزدیک تر به نیاز واقعی پزشکی تغییر دهیم. مثلا می توان برای هر بیمار یک شاخص ساخت که بر اساس شدت بیماری، تعداد بیماری های مزمن، نتایج آزمایش ها، وضعیت عملکردی، داروهای مورد نیاز، تعداد بستری ها، و نظر پزشک محاسبه شود. سپس مدل را برای پیش بینی همین شاخص نیاز آموزش دهیم .

برای پیاده سازی، ابتدا باید در داده های آموزشی، برای بخشی از بیماران برچسب دقیق تری از نیاز پزشکی تهیه شود. بعد می توان مدل را با این برچسب جدید آموزش داد و در مرحله ارزیابی، نرخ انتخاب بیماران واقعا نیازمند را بین گروه های مختلف مقایسه کرد. یعنی بررسی کنیم آیا در سطح بیماری برابر، احتمال ورود به برنامه مراقبتی برای گروه به حاشیه رانده شده کمتر است یا نه. اگر همچنان اختلاف وجود داشت، می توان آستانه تصمیم یا وزن نمونه ها را طوری تنظیم کرد که بیماران نیازمند از گروه های مختلف با احتمال مشابهی شناسایی شوند .محدودیت این راه حل این است که اندازه گیری نیاز واقعی پزشکی ساده نیست و ممکن است خودش با خطا یا قضاوت ذهنی پزشکان همراه باشد. همچنین جمع آوری چنین برچسب هایی پر هزینه و زمان بر است. از طرف دیگر، اگر برای کاهش نابرابری فقط آستانه گروه ها را تغییر دهیم، ممکن است دقت کلی مدل کاهش پیدا کند یا برخی بیماران از گروه های دیگر که واقعا نیازمند هستند، کمتر انتخاب شوند. ریسک انصاف تازه ای که ایجاد می شود این است که تعریف جدید نیاز پزشکی هم ممکن است بعضی نیازها را بهتر از بعضی نیازهای دیگر ببیند. مثلا اگر شاخص نیاز بیشتر بر بیماری های ثبت شده در پرونده تمرکز کند، باز هم بیمارانی که کمتر به پزشک مراجعه کرده اند ممکن است کم نیازتر دیده شوند. بنابراین راه حل باید همراه با بررسی زیرگروه ها و بازنگری مداوم در تعریف متغیر هدف باشد.

پرسش ۵: (انتخاب معیار، تحت قید عدم امکان (اعطای وام))

الف) برای پاسخ، فرض می کنم تصمیم مثبت یعنی اعطای وام و برچسب واقعی مثبت یعنی متقاضی واقعا توان بازپرداخت دارد. پس FP می شود وام دادن به کسی که در واقع بازپرداخت نمی کند و FN می شود رد کردن کسی که در واقع می توانست بازپرداخت کند. در این مسئله آسیب اصلی از نوع تخصیصی است زیرا مدل تعیین می کند چه کسی به یک منبع مهم یعنی وام دسترسی داشته باشد و چه کسی از آن محروم شود.

برای متقاضیان، مهم ترین خطا معمولا منفی کاذب (FN) است. یعنی فردی که می توانست وام را بازپرداخت کند، به اشتباه رد می شود و فرصت گرفتن وام را از دست می دهد. هزینه این خطا را مستقیم خود متقاضی می پردازد. مثبت کاذب (FP) هم می تواند برای متقاضی آسیب داشته باشد زیرا ممکن است وامی بگیرد که توان بازپرداخت آن را ندارد و بعدا گرفتار بدهی، جریمه یا خراب شدن اعتبار شود. اما در صورت سوال تاکید اصلی متقاضیان روی از دست دادن وامی است که می توانستند بازپرداخت کنند، پس از نگاه آن ها FN مهم تر است.

برای بانک، مهم ترین خطا مثبت کاذب است. یعنی بانک به فردی وام می دهد که در آینده نمی تواند بازپرداخت کند. در این حالت بانک اصل پول و سود مورد انتظار را از دست می دهد. منفی کاذب هم برای

بانک هزینه دارد چون یک مشتری خوب را رد کرده و سود احتمالی وام را از دست داده است. اما معمولا ضرر مستقیم ناشی از FP برای بانک شدیدتر از سود از دست رفته یک وام سالم است.

برای نهاد ناظر، مسئله اصلی فقط سود و زیان فردی نیست بلکه توزیع ناعادلانه خطاها و تصمیم ها بین گروه هاست. اگر یک گروه محافظت شده با نرخ بیشتری رد شود، مخصوصا اگر افراد زیادی از آن گروه واقعا توان بازپرداخت داشته باشند، با یک آسیب تخصیصی و تبعیض ساختاری روبه رو هستیم. بنابراین نهاد ناظر به FN های نامتناسب برای گروه های محروم حساس است چون باعث محرومیت ناعادلانه از اعتبار می شود. از طرف دیگر، اگر یک گروه بیش از حد وام های پر ریسک دریافت کند، ممکن است با بدهی بیشتر آسیب ببینند. اما در سناریوی داده شده، تاکید ناظر بر disparate impact و قاعده چهارپنجم است (که می گوید نرخ پذیرش گروه محروم یا محافظت شده نباید کمتر از 80 درصد نرخ پذیرش گروه دارای بیشترین نرخ پذیرش باشد) و در نتیجه نگرانی اصلی او تفاوت در نرخ پذیرش و محروم شدن نامتناسب یک گروه از وام است.

ب) معیار برابری TPR (برابری شانس ها) را انتخاب می کنم که به صورت زیر است:

$$\mathbb{P}\{\widehat{Y} = 1 \mid Y = 1, A = a\} = \mathbb{P}\{\widehat{Y} = 1 \mid Y = 1, A = b\}$$

یعنی برابری نرخ پذیرش در میان افرادی که واقعا توان بازپرداخت دارند. اگر Y = 1 یعنی متقاضی واقعا می تواند وام را بازپرداخت کند و $\hat{Y} = 1$ یعنی بانک وام را تایید می کند. یعنی در میان متقاضیانی که واقعا قادر به بازپرداخت هستند، احتمال تایید وام نباید برای یک گروه کمتر از گروه دیگر باشد.

دلیل انتخاب این معیار این است که در این مسئله مهم ترین آسیب برای متقاضیان، FP است و یعنی فردی که می توانست وام را بازپرداخت کند، به اشتباه رد شود. این خطا فرصت های زیادی را از فرد می گیرد. از طرف دیگر، نهاد ناظر هم نگران این است که یک گروه به طور نامتناسب از دسترسی به اعتبار محروم شود. بنابراین این معیار مستقیما روی همین آسیب تمرکز می کند و می گوید افراد واجد شرایط در گروه های مختلف باید شانس مشابهی برای گرفتن وام داشته باشند.

من این معیار را از برابری جمعیتی مناسب تر می دانم زیرا برابری جمعیتی فقط نرخ کلی تایید وام را بین گروه ها برابر می کند بدون اینکه توجه کند چه کسی واقعا توان بازپرداخت دارد. در وام دهی، اگر فقط نرخ پذیرش را برابر کنیم، ممکن است بانک مجبور شود به افرادی وام بدهد که ریسک عدم پرداخت بالایی دارند و یا برعکس افراد شایسته ای را فقط برای تنظیم نرخ ها رد کند. بنابراین برابری جمعیتی برای هشدار قانونی و بررسی اولیه مفید است اما به نظر من نباید معیار اصلی تصمیم باشد.

با این انتخاب، چیزی که قربانی می شود برابری جمعیتی کامل و همچنین تا حدی واسنجی کامل بین گروه ها است. یعنی ممکن است نرخ کلی تایید وام در دو گروه دقیقا برابر نشود و حتی قاعده چهار پنجم در بعضی شرایط همچنان نیاز به بررسی جداگانه داشته باشد. همچنین ممکن است امتیازهای مدل از نظر کالیبراسیون کامل بین گروه ها یکسان نباشند چون تمرکز اصلی روی این است که افراد واقعا قادر به بازپرداخت، به طور ناعادلانه رد نشوند. از نظر بانک هم این انتخاب ممکن است کمی از سود بیشینه فاصله بگیرد زیرا بانک دیگر فقط آستانه ای را انتخاب نمی کند که سود مورد انتظار را بیشینه کند بلکه باید مطمئن شود نرخ پذیرش افراد واجد شرایط در گروه ها منصفانه است. با این حال، این هزینه قابل دفاع است زیرا در این سناریو محروم کردن اشتباه افراد خوش حساب از وام، مخصوصا اگر به صورت نامتناسب روی یک گروه بیفتد، آسیب اجتماعی و اخلاقی مهم تری ایجاد می کند.

پرسش ۶: (داوری مناقشه COMPAS (در پیوند با بخش اول))

الف) ادعای اصلی ProPublica این بود که ابزار COMPAS از نظر نژادی نرخ خطا های نابرابری دارد. آن ها نشان دادند که متهمان سیاه پوست در مقایسه با متهمان سفید پوست، بیشتر به اشتباه در گروه پرخطر قرار می گیرند (یعنی نرخ FP برای آن ها بالاتر است). در مقابل، متهمان سفید پوست بیشتر به اشتباه در گروه کم خطر قرار می گیرند (یعنی نرخ FN برای آن ها بالاتر است). پس ProPublica بیشتر روی نابرابری در خطاها، مخصوصا FPR و FNR تاکید داشت. پاسخ اصلی Northpointe این بود که COMPAS از نظر کالیبراسیون یا ارزش پیش بینی، بین گروه های نژادی مشابه عمل می کند. یعنی اگر دو نفر از دو گروه نژادی مختلف امتیاز ریسک یکسانی بگیرند، احتمال واقعی تکرار جرم آن ها تقریبا یکسان است. بنابراین از دید Northpointe، مدل ناعادلانه نیست زیرا امتیازهای آن برای گروه های مختلف معنای مشابهی دارند و معیارهایی مانند PPV یا کالیبراسیون بین گروه ها تقریبا برابر است. پس اختلاف اصلی این بود که ProPublica انصاف را از زاویه برابری نرخ خطاها می دید اما Northpointe انصاف را از زاویه کالیبراسیون و برابری معنای امتیاز ریسک ارزیابی می کرد.

ب) در مسئله COMPAS ، $Y = 1$ یعنی فرد در آینده دوباره مرتکب جرم شود. نکته مهم این است که نرخ پایه تکرار جرم در گروه های نژادی مختلف برابر نیست. حالا Northpointe می گفت که COMPAS از نظر PPV یا کالیبراسیون بین گروه ها خوب عمل می کند. یعنی اگر مدل به دو نفر از دو گروه مختلف امتیاز ریسک بالا بدهد، احتمال واقعی تکرار جرم برای آن ها تقریبا مشابه است و $PPV_1 = PPV_0$. از این نظر، Northpointe حق داشت زیرا داشت معیار بسندگی را بررسی می کرد. اما ProPublica نشان داد که نرخ

های خطا برابر نیستند. به طور خاص، برای متهمان سیاه پوست FPR بالاتر بود که یعنی تعداد بیشتری از افرادی که واقعا تکرار جرم نکردند، به اشتباه پرخطر تشخیص داده شدند. از طرف دیگر، برای متهمان سفید پوست FNR بالاتر بود که یعنی تعداد بیشتری از افرادی که واقعا تکرار جرم کردند، به اشتباه کم خطر تشخیص داده شدند. پس از نظر ProPublica ، معیار جداسازی یا برابری نرخ خطاها نقض شده بود و در واقع $FPR_0 \neq FPR_1$ یا $FNR_0 \neq FNR_1$. اتحاد چولدچوا توضیح می دهد که چرا این دو حرف می توانند همزمان درست باشند. اگر PPV در دو گروه برابر باشد، اما نرخ پایه p در دو گروه فرق کند، عبارت $\frac{p}{1-p}$ در اتحاد برای دو گروه متفاوت می شود. پس برای اینکه رابطه برقرار بماند، نمی توان انتظار داشت که همزمان FPR و FNR هم در دو گروه برابر باشند. یعنی با نرخ های پایه متفاوت، اگر بخواهیم PPV را برابر نگه داریم، به ناچار یکی از نرخ های خطا یا هر دو بین گروه ها متفاوت می شوند. بنابراین Northpointe در معنای فنی خودش حق داشت چون روی برابری PPV و کالیبراسیون تاکید می کرد. ProPublica هم در معنای فنی خودش حق داشت چون نابرابری FPR و FNR را نشان می داد. اختلاف آن ها بیشتر از اینجا می آمد که هر کدام یک تعریف متفاوت از انصاف را مهم می دانستند. با وجود نرخ های پایه متفاوت، این دو نوع انصاف در حالت عادی (غیر تباهیده) نمی توانند همزمان کامل برقرار باشند.

ج) به نظر من در این زمینه باید معیار اصلی، برابری FP باشد. یعنی اگر دو گروه از افراد واقعا در آینده مرتکب جرم نمی شوند، نباید یک گروه بیشتر از گروه دیگر به اشتباه پرخطر تشخیص داده شود. دلیل انتخاب من این است که در بازداشت پیش از محاکمه، هزینه اخلاقی FP بسیار سنگین است. FP یعنی فردی که اگر آزاد می شد مرتکب جرم نمی شد، به اشتباه پرخطر شناخته می شود و آزادی خود را از دست می دهد. این فرد ممکن است شغل، خانواده و آبرو خود را از دست بدهد و حتی برای رهایی از بازداشت، به پذیرش اتهام یا توافق قضایی ناعادلانه فشار آورده شود. این آسیب مستقیم و توسط حکومت به فرد وارد می شود. آن هم پیش از اینکه جرم جدیدی رخ داده باشد یا حتی حکم نهایی صادر شده باشد. در مقابل، FN یعنی فردی کم خطر تشخیص داده شود ولی بعدا دوباره مرتکب جرم شود. این خطا هم قطعا مهم است چون ممکن است به قربانیان احتمالی و امنیت عمومی آسیب بزند. اما این آسیب احتمالی و آینده نگر است و شدت آن در همه موارد یکسان نیست. هر تکرار جرم هم لزوما جرم خشونت آمیز یا شدید نیست. بنابراین نمی توان برای کاهش هر مقدار ریسک احتمالی، به سادگی افراد بی خطر را از آزادی محروم کرد.

به همین دلیل، دولت برای بازداشت یک فرد قبل از محاکمه باید دلیل بسیار قوی داشته باشد. پس من معیار برابری FP را در اولویت می گذارم. این انتخاب به این معنا نیست که امنیت عمومی بی اهمیت است بلکه

یعنی هزینه اخلاقی بازداشت اشتباه، به خصوص وقتی به طور نامتناسب روی یک گروه نژادی بیفتد، آن قدر جدی است که باید محدودیت اصلی سیستم باشد.

د) بله یا حداقل نباید به عنوان ابزار تصمیم گیری مستقیم برای بازداشت پیش از محاکمه استفاده شود. دلیل اصلی این است که موضوع فقط انتخاب بین چند معیار انصاف نیست. حتی اگر یک مدل از نظر یک معیار قابل دفاع باشد، باز هم ممکن است استفاده از آن در عدالت کیفری خطرناک باشد. تصمیم درباره بازداشت پیش از محاکمه مستقیما با آزادی فرد ارتباط دارد. بنابراین خطای مدل در اینجا فقط یک خطای فنی نیست بلکه می تواند به محرومیت واقعی یک انسان از آزادی منجر شود. یک ملاحظه مهم بیرون از معیارهای انصاف، امکان اعتراض و فرایند دادرسی منصفانه است. اگر فرد نداند چرا پرخطر تشخیص داده شده، نتواند به امتیاز خود اعتراض کند یا دادگاه هم بیش از حد به خروجی مدل اعتماد کند، استفاده از سامانه ناعادلانه می شود حتی اگر برخی سنجه های آماری آن خوب باشند. در چنین وضعی مدل می تواند قدرت زیادی پیدا کند بدون اینکه پاسخگویی کافی داشته باشد. ملاحظه مهم دیگر، خود تعریف تکرار جرم است. در بسیاری از داده های ثبت شده، آنچه ثبت می شود لزوما ارتکاب واقعی جرم نیست بلکه بیشتر چیزهایی مثل دستگیری، اتهام یا برخورد پلیس است. این متغیرها می توانند تحت تاثیر الگوهای تاریخی پلیس، تمرکز بیشتر بر بعضی محله ها و نظارت شدیدتر بر بعضی گروه ها باشند. پس برچسب آموزشی ممکن است خودش مشکل نابرابری را داشته باشد. اگر مدل بر اساس چنین داده هایی آموزش ببیند، ممکن است همان الگوهای نابرابر را بازتولید کند. همچنین خطر حلقه بازخورد وجود دارد. اگر مدل یک گروه یا محله را پرخطرتر بداند، پلیس و دادگاه ممکن است بیشتر روی همان گروه تمرکز کنند. این تمرکز بیشتر باعث ثبت موارد بیشتر، دستگیری بیشتر و داده های ظاهرا پرخطرتر می شود. در نتیجه مدل در آینده دوباره همان گروه را پرخطرتر تشخیص می دهد و نابرابری تشدید می شود.

بنابراین من با استقرار چنین سامانه ای به عنوان ابزار اصلی تصمیم گیری موافق نیستم. اگر هم قرار باشد استفاده شود، باید فقط نقش مشورتی و محدود داشته باشد همراه با شفافیت، امکان اعتراض، ارزیابی مستقل، بررسی منظم خطا ها بین گروه ها و اطمینان از اینکه قاضی خروجی مدل را جایگزین قضاوت حقوقی و انسانی نمی کند.

پرسش ۷: (فراتر از انصاف حاشیه ای: زیرگروه ها و زمان)

الف) برای نشان دادن دستکاری زیرگروهی انصاف، یک مثال با دو ویژگی حساس جنسیت و نژاد را در نظر می گیرم. فرض می کنم جامعه 100 نفر دارد و هر زیرگروه 25 نفر است:

زیر گروه	تعداد افراد	تعداد پذیرفته شده	نرخ پذیرش
مرد سیاه پوست	25	25	100%
زن سیاه پوست	25	0	0%
مرد سفید پوست	25	0	0%
زن سفید پوست	25	25	100%

حالا اگر فقط جنسیت را جداگانه بررسی کنیم، می بینیم:

$$P(\hat{Y}=1 \mid \text{male}) = \frac{25}{50} = 50\%$$

$$P(\hat{Y}=1 \mid \text{female}) = \frac{25}{50} = 50\%$$

پس از نظر جنسیت، برابری جمعیتی برقرار به نظر می رسد. اگر فقط نژاد را جداگانه بررسی کنیم، باز هم داریم:

$$P(\hat{Y}=1 \mid \text{black}) = \frac{25}{50} = 50\%$$

$$P(\hat{Y}=1 \mid \text{white}) = \frac{25}{50} = 50\%$$

پس از نظر نژاد هم مدل منصف به نظر می رسد. اما وقتی زیرگروه های تقاطعی را بررسی می کنیم، می بینیم مدل با زن سیاه پوست و مرد سفید پوست بسیار ناعادلانه رفتار کرده است زیرا نرخ پذیرش آن ها صفر است در حالی که برای مرد سیاه پوست و زن سفید پوست نرخ پذیرش 100 درصد است. در واقع مدل می تواند روی گروه های کلی مثل جنسیت یا نژاد عادلانه به نظر برسد اما روی ترکیب های این ویژگی ها ناعادلانه باشد. پس حساب کردن گروه های حاشیه ای به تنهایی کافی نیست. تبعیض ممکن است فقط در تقاطع چند ویژگی ظاهر شود. اگر فقط میانگین های کلی را ببینیم، اثرهای مخالف در زیرگروه ها همدیگر را خنثی می کنند و مدل ظاهرا منصف دیده می شود. از طرف دیگر، نمی توان خیلی ساده گفت همه زیرگروه ها را حساب می کنیم چون تعداد زیرگروه ها با زیاد شدن ویژگی های حساس به صورت ترکیبی و بسیار سریع زیاد می

شود. مثلا اگر چندین ویژگی حساس داشته باشیم، ترکیب های مختلف آن ها می تواند تعداد بسیار زیادی زیرگروه بسازد. علاوه بر آن، بعضی زیرگروه ها بسیار کوچک هستند و محاسبه نرخ خطا یا نرخ پذیرش روی آن ها از نظر آماری قابل اعتماد نیست. برای همین راه درست این است که زیرگروه های معنادار مثل ترکیب های مهم ویژگی های محافظت شده، به صورت منظم بررسی شوند نه اینکه فقط چند گروه کلی یا همه زیرمجموعه های ممکن بدون قاعده بررسی شوند.

ب) یک سازوکار پویا این است که در اعطای وام، معیار برابری جمعیتی بانک را مجبور کند به دو گروه با نرخ برابر وام بدهد حتی اگر توزیع ریسک اعتباری آن ها متفاوت باشد. فرض کنیم گروه محروم به دلیل شرایط اقتصادی، به طور متوسط امتیاز اعتباری پایین تری دارد. اگر بانک برای برابر کردن نرخ پذیرش، آستانه وام دهی را برای این گروه خیلی پایین بیاورد، ممکن است به تعدادی از افراد وام بدهد که احتمال بازپرداخت آن ها کم است. در کوتاه مدت، این کار منصفانه به نظر می رسد زیرا نرخ دریافت وام در دو گروه برابر شده است. اما در بلند مدت، ممکن است بخشی از این افراد نتوانند وام را بازپرداخت کنند و امتیاز اعتباری آن ها کاهش یابد. در نتیجه میانگین اعتبار همان گروهی که قرار بود حمایت شود بدتر می شود.

ساز و کار بازخورد به این صورت است:

اول، سیاست برابری جمعیتی باعث افزایش نرخ وام دهی به گروه محروم می شود. دوم، بعضی وام ها به افرادی داده می شود که شانس موفقیت و بازپرداخت پایینی دارند. سوم، عدم پرداخت این افراد باعث کاهش امتیاز اعتباری و بدتر شدن وضعیت مالی آن ها می شود. چهارم، در دوره های بعدی، همین افت امتیاز باعث می شود مدل ها یا بانک ها دوباره آن گروه را پرریسک تر ببینند. بنابراین سیاستی که در ظاهر برای کمک طراحی شده بود، می تواند در طول زمان نابرابری را تثبیت یا حتی تشدید کند. این مثال نشان می دهد که ارزیابی یک مداخله منصفانه فقط در لحظه اجرا کافی نیست. اگر فقط نگاه کنیم که آیا امروز نرخ پذیرش دو گروه برابر شده یا نه، ممکن است نتیجه بگیریم سیاست منصفانه است. اما باید بپرسیم این تصمیم در آینده چه اثری روی خود گروه ها می گذارد. ممکن است یک معیار ایستا مثل برابری جمعیتی از نظر آماری خوب به نظر برسد ولی در مدل زمانی باعث کاهش رفاه همان گروه شود.

بخش سوم: پیاده سازی و تحلیل تجربی

مرحله ۰ - بازتولیدپذیری

برای بازتولیدپذیری، مقدار seed برابر 30 در نظر گرفته شد. روی داده ها پالایش استاندارد ProPublica اعمال شد و فقط رکوردهایی نگه داشته شدند که days_b_screening_arrest در بازه [-30,30] باشد، مقدار is_recid برابر -1 نباشد (زیرا در این حالت برچسب این رکورد ها قابل اعتماد نیستند)، مقدار c_charge_degree برابر O نباشد (زیرا جز دسته بندی اصلی جرم ها نیستند و Others هستند) و score_text برابر N/A نباشد (این یعنی امتیاز ریسک موجود نیست که مطلوب ما نیست). سپس داده ها با نسبت 20/80 به آموزش و آزمون تقسیم شدند. تقسیم به صورت stratified انجام شد تا توزیع برچسب هدف two_year_recid و گروه های نژادی تا حد ممکن در train و test مشابه باقی بماند.

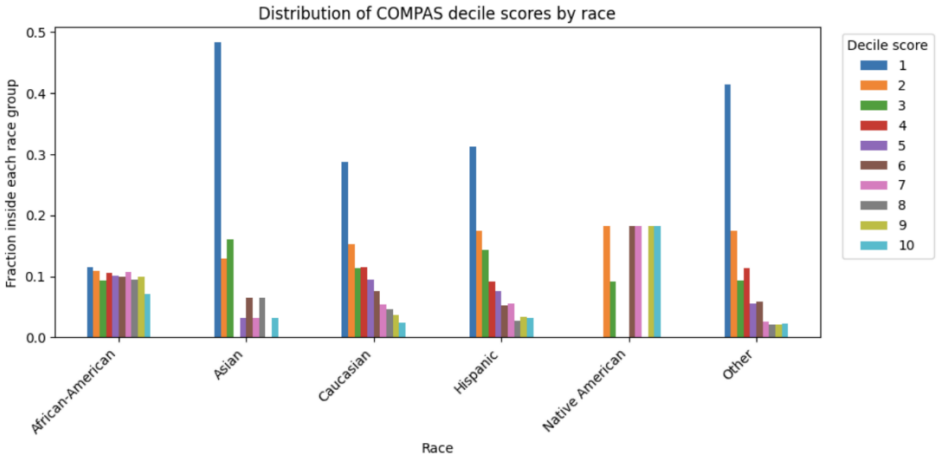
مرحله ۱ – ممیزی سوگیری

الف) در این مرحله نرخ پایه P(Y = 1) برای هر گروه نژادی محاسبه شد (که منظور از Y = 1 تکرار جرم در بازه دو ساله است). نتایج به صورت زیر شد:

race	n	base_rate
African-American	3175	0.523
Native American	11	0.455
Caucasian	2103	0.391
Hispanic	509	0.371
Other	343	0.362
Asian	31	0.258

که نشان می دهد نرخ پایه بین گروه های نژادی یکسان نیست.

ب) در این مرحله توزیع امتیاز دهکی COMPAS را به تفکیک هر نژاد با نمودار به صورت زیر نشان دادم:

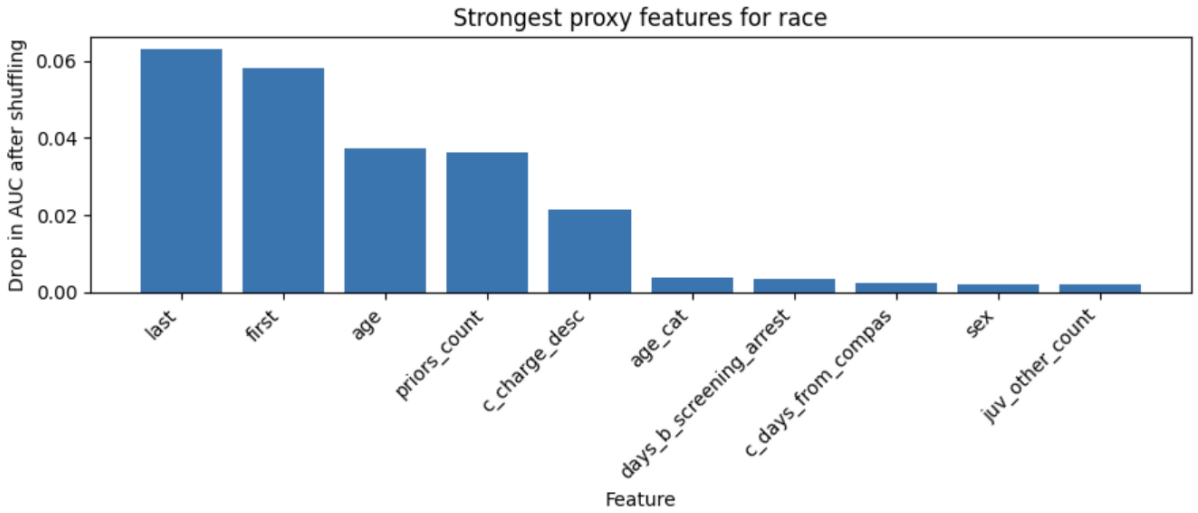


نمودار نشان می دهد که توزیع امتیازها برای گروه ها یکسان نیست. مثلا گروه African-American سهم بیشتری در امتیازهای دهکی بالاتر دارد در حالی که گروه Caucasian بیشتر در امتیازهای پایین تر دیده می شود.

ج) برای بررسی اینکه race تا چه حد به طور غیر مستقیم در سایر ویژگی ها رمزگذاری شده است، یک آزمون پراکسی انجام دادم. در این آزمون، ستون race حذف شد. همچنین همه ستون ها به صورت کورکورانه استفاده نشدند چون بعضی ستون ها شناسه ای، اداری، مربوط به تاریخ ها، خروجی COMPAS یا اطلاعات مربوط به پیامد و آینده هستند. استفاده از این ستون ها می توانست نتیجه را مصنوعی و غیر قابل تفسیر کند. بنابراین در تحلیل اصلی، race، برچسب هدف، خروجی های COMPAS و ستون های اداری یا مربوط به آینده حذف شدند و سپس بررسی شد که آیا از روی ویژگی های باقی مانده می توان گروه نژادی را پیش بینی کرد یا نه. یک مدل Logistic Regression فقط با استفاده از سایر ویژگی ها تلاش کرد تشخیص دهد فرد در گروه African-American یا Caucasian قرار دارد (این دو گروه به دلیل اینکه بیشترین جمعیت را دارند، برای این آزمایش مطمئن تر بودند و به همین دلیل روی این دو گروه انجام دادم).

مدل آموزش داده شده به Accuracy برابر 0.713 رسید. بالاتر بودن Accuracy از 0.5 نشان می دهد که مدل واقعا برای هر دو گروه تا حدی قدرت تشخیص دارد. همچنین مقدار AUC (مساحت زیر نمودار ROC) برابر 0.767 به دست آمد که به طور محسوسی از حالت تصادفی 0.5 بالاتر است (برای این معیار 0.5 یعنی عملکرد تصادفی کامل و 1 یعنی جداسازی کامل). بنابراین می توان نتیجه گرفت که اطلاعات مربوط به race به طور غیر مستقیم در سایر ویژگی ها رمزگذاری شده است. همچنین برای شناسایی قوی ترین پراکسی های race ، از روش permutation importance استفاده شد. در این روش ابتدا یک مدل گفته شده آموزش داده شد. سپس هر ویژگی در داده آزمون به صورت جداگانه به هم ریخته شد و افت AUC اندازه گیری شد.

اگر با به هم ریختن یک ویژگی، AUC مدل زیاد کاهش یابد، یعنی مدل برای پیش بینی race به آن ویژگی وابستگی بیشتری داشته است. در نتیجه مقدار importance نشان دهنده افت میانگین AUC بعد از حذف اطلاعات مفید آن ویژگی است. نمودار به دست آمده به صورت زیر شد:



این نمودار نشان می دهد که last و first قوی ترین پراکسی ها هستند. این نتیجه قابل انتظار است چون نام و نام خانوادگی می توانند به طور غیر مستقیم اطلاعات قومی یا نژادی را منتقل کنند. بعد از آن ها، ویژگی هایی مانند age، priors_count و c_charge_desc اهمیت بیشتری داشتند. این نشان می دهد که حتی بعضی ویژگی های ظاهرا معمولی و قابل استفاده نیز می توانند تا حدی اطلاعات مربوط به race را رمزگذاری کنند. بنابراین حذف مستقیم ستون race لزوما باعث حذف اثر race از مدل نمی شود. با توجه به نتایج این بخش، تصمیم گرفتم ستون name و first و last را هم یک بار حذف کنم و این تحلیل را انجام دهم که ببینم بدون اینها به چه صورت می شود زیرا این ویژگی ها می توانند به صورت مستقیم نژاد را لو بدهند به دلیل اینکه اسم افراد معمولا ارتباط مستقیمی با نژاد آنها دارد. با حذف اینها دقت به 0.629 و AUC به 0.658 کاهش یافت که افت محسوسی است و نشان می دهد این ویژگی های مربوط به اسم واقعا ارتباط مستقیمی با نژاد دارند.

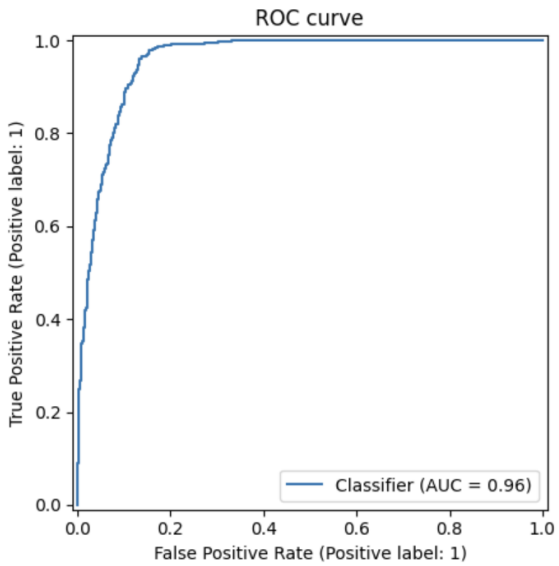
د) این ممیزی نشان می دهد که داده از ابتدا بین گروه های نژادی کاملا متوازن نیست. نرخ پایه $P(Y = 1)$ برای گروه ها متفاوت است. مثلا در خروجی ما نرخ تکرار جرم دو ساله برای African-American برابر 0.523 و برای Caucasian برابر 0.391 بود. همچنین توزیع امتیازهای دهکی COMPAS بین گروه ها یکسان نبود و بعضی گروه ها بیشتر در امتیازهای بالاتر دیده شدند. بنابراین هر مدلی که روی این داده آموزش داده شود، با داده ای روبه رو است که از قبل تفاوت های گروهی در برچسب و امتیاز ریسک دارد. این موضوع

باعث می شود معیارهای انصاف مختلف احتمالا با هم در تعارض قرار بگیرند و نتوان فقط با نگاه کردن به دقت کلی مدل درباره منصفانه بودن آن قضاوت کرد.

علاوه بر این، تحلیل پراکسی نشان داد که حتی اگر ستون race را از داده حذف کنیم، اطلاعات مربوط به race هنوز می تواند در ویژگی های دیگر باقی بماند و حذف مستقیم ویژگی حساس کافی نیست و مدل های بعدی ممکن است از طریق پراکسی هایی مثل نام، سن، سابقه قبلی یا نوع اتهام به طور غیر مستقیم از اطلاعات مرتبط با race استفاده کنند. بنابراین برای هر مدل ساخته شده روی این داده، باید معیارهای انصاف مانند FPR، FNR، PPV و نرخ پذیرش به تفکیک گروه های نژادی بررسی شوند نه اینکه فقط گفته شود چون race حذف شده، مدل منصفانه است.

مرحله ۲ – مدل پایه و سنجه های دست ساز

الف) در این بخش یک مدل پایه Logistic Regression برای پیش بینی two_year_recid آموزش داده شد. بدون اعمال هیچ مداخله ای برای افزایش. ستون های مربوط به برچسب هدف، خروجی های COMPAS، شناسه ها، نام افراد، تاریخ ها و اطلاعات مربوط به جرم یا بازداشت بعدی حذف شدند تا leakage ایجاد نشود. مقدار Accuracy مدل برابر 0.89 بدست آمد و مقدار ROC-AUC (مساحت زیر منحنی در نمودار زیر) برابر 0.958 بدست آمد که نمودار آن به صورت زیر است:



ROC-AUC توانایی مدل در رتبه بندی افراد پرریسک تر نسبت به افراد کم ریسک تر را مستقل از آستانه تصمیم نشان می دهد.

ب) در این بخش معیارهای انصاف مدل پایه بدون استفاده از کتابخانه های آماده انصاف محاسبه شدند. برای هر گروه، ابتدا مقادیر TP ، FP، TN و FN از روی برچسب واقعی two_year_recid و خروجی مدل به دست آمدند. سپس معیارهای selection_rate، TPR، FPR و PPV جداگانه برای هر گروه محاسبه شدند. در اینجا selection_rate یعنی نسبت افرادی که مدل برای آن ها خروجی مثبت داده است، TPR یعنی نرخ تشخیص درست افراد واقعا مثبت، FPR یعنی نرخ افرادی که واقعا منفی بوده اند ولی مدل آن ها را مثبت پیش بینی کرده است و PPV یعنی از بین افراد پیش بینی شده به عنوان مثبت، چه نسبتی واقعا مثبت بوده اند.

در تحلیل بر اساس جنسیت، نرخ پایه برای زنان برابر 0.349 و برای مردان برابر 0.480 بود. یعنی در داده آزمون، تکرار جرم واقعی در گروه مردان بیشتر دیده می شود. نرخ انتخاب مثبت مدل نیز برای مردان بیشتر بود: selection_rate برای زنان 0.378 و برای مردان 0.473 به دست آمد که شکاف آن برابر 0.095 است. این یعنی مدل مردان را بیشتر از زنان به عنوان مثبت یا پرریسک پیش بینی کرده است. از نظر TPR، مقدار زنان 0.916 و مقدار مردان 0.873 بود که یعنی مدل در میان افراد واقعا مثبت، زنان را کمی بهتر شناسایی کرده است. شکاف TPRبرابر 0.043 بود. از نظر FPR، مقدار زنان 0.090 و مقدار مردان 0.104 بود که یعنی نرخ مثبت کاذب برای مردان کمی بیشتر است اما شکاف آن فقط 0.014 است. مقدار PPV نیز برای زنان 0.844 و برای مردان 0.886 بود، یعنی وقتی مدل برای مردان خروجی مثبت داده، احتمال درست بودن آن کمی بیشتر از زنان بوده است.

در تحلیل بر اساس race ، تفاوت های بیشتری دیده می شود. نرخ پایه برای African-American برابر 0.523 و برای Caucasian برابر 0.390 بود. همچنین selection_rate برای African-American برابر 0.517 و برای Caucasian برابر 0.412 شد. بنابراین مدل افراد African-American را با نرخ بیشتری نسبت به Caucasian مثبت پیش بینی کرده است. در کل گروه های نژادی، شکاف selection_rate برابر 0.193 بود. برای TPR نیز شکاف کلی 0.237 به دست آمد اما باید توجه کرد که بعضی گروه ها مثل Asian و Native American تعداد نمونه بسیار کمی دارند و مقدارهای 1.000 یا 0.000 برای آن ها پایدار و قابل اتکا نیستند. برای دو گروه اصلی، TPR برای African-American برابر 0.898 و برای Caucasian برابر 0.872 بود که اختلاف زیادی ندارد. از نظر FPR، مقدار African-American برابر 0.099 و مقدار Caucasian برابر 0.117 بود که یعنی در این مدل نرخ مثبت کاذب برای Caucasian کمی بیشتر از African-American شده است. مقدار PPV برای African-American برابر 0.909 و برای Caucasian برابر 0.827 بود که یعنی پیش بینی های مثبت مدل برای گروه African-American در این اجرا دقت مثبت بالاتری داشته اند.

به طور کلی، نتایج نشان می دهد که مدل پایه از نظر دقت کلی خوب عمل می کند اما رفتار آن بین گروه ها کاملا یکسان نیست. در جنسیت، بیشترین شکاف مربوط به selection_rate بود و مدل مردان را بیشتر مثبت پیش بینی کرد. در race نیز اختلاف نرخ پایه و نرخ انتخاب بین گروه ها واضح است. با این حال، در تفسیر معیارهای مربوط به گروه های کوچک مانند Asian و Native American باید احتیاط کرد زیرا تعداد نمونه آن ها در داده آزمون بسیار کم است و معیارهایی مثل TPR، FPR و PPV برای آن ها ممکن است با تغییر چند نمونه به شدت عوض شود. بنابراین برای تحلیل اصلی، مقایسه African-American و Caucasian قابل اعتمادتر است.

ج)

Attribute	Group	Total Number	Base Rate	Selection Rate	TPR	FPR	FNR	PPV	Accuracy
race	African-American	635	0.523	0.521	0.904	0.102	0.096	0.906	0.901
race	Asian	7	0.286	0.429	1.000	0.200	0.000	0.667	0.857
race	Caucasian	420	0.390	0.410	0.866	0.117	0.134	0.826	0.876
race	Hispanic	102	0.373	0.324	0.763	0.062	0.237	0.879	0.873
race	Native American	2	0.500	0.500	1.000	0.000	0.000	1.000	1.000
race	Other	69	0.362	0.348	0.840	0.068	0.160	0.875	0.899
sex	Female	238	0.349	0.374	0.904	0.090	0.096	0.843	0.908
sex	Male	997	0.480	0.476	0.877	0.106	0.123	0.886	0.886

در اینجا همه معیارهای انصاف محاسبه شده در یک جدول واحد گزارش شدند. برای هر مقدار از ویژگی های محافظت شده race و sex، تعداد نمونه ها، نرخ پایه، نرخ انتخاب مثبت، TPR، FPR، PPV و دقت مدل گزارش شد. این جدول نشان می دهد که مدل پایه با وجود عملکرد کلی مناسب، در بعضی معیارها بین گروه ها رفتار یکسانی ندارد. برای مثال، در ویژگی sex بیشترین شکاف مربوط به selection_rate با مقدار 0.095

است، در حالی که شکاف FPR فقط 0.014 است. در ویژگی race شکاف ها بزرگ تر دیده می شوند اما در تفسیر گروه هایی مثل Asian و Native American باید احتیاط کرد چون تعداد نمونه آن ها در آزمون بسیار کم است.

مرحله ۳ – آزمون «انصاف از طریق ناآگاهی»

در این مرحله، مدل دوباره آموزش داده شد، اما این بار ویژگی های حساس race و sex از مجموعه ویژگی های ورودی حذف شدند. هدف از این آزمایش بررسی ایده انصاف از طریق ناآگاهی بود که یعنی بررسی کنیم آیا صرفا با حذف مستقیم ویژگی حساس، اختلاف های بین گروهی از بین می روند یا نه.

از نظر عملکرد کلی، حذف ویژگی های حساس تقریبا اثری روی مدل نداشت. در مرحله 2 مقدار Accuracy برابر 0.890 و ROC-AUC برابر 0.958 بود. در مرحله 3 نیز Accuracy همچنان 0.890 و ROC-AUC تا سه رقم اعشار برابر 0.958 باقی ماند. البته خروجی ها دقیقا یکسان نبودند. ماتریس درهم ریختگی از [[604, 69], [67, 495]] در مرحله 2 به [[605, 68], [68, 494]] در مرحله 3 تغییر کرد. یعنی حذف race و sex چند پیش بینی را تغییر داد، اما تعداد کل پیش بینی های درست ثابت ماند و به همین دلیل Accuracy نهایی تغییر نکرد.

از نظر معیارهای انصاف هم اختلاف ها از بین نرفتند و فقط در بعضی موارد کمی تغییر کردند. برای race، نرخ انتخاب مثبت گروه African-American از 0.521 به 0.517 کاهش پیدا کرد اما هنوز از نرخ انتخاب مثبت Caucasian یعنی 0.412 بیشتر بود. همچنین TPR برای African-American از 0.904 به 0.898 کاهش یافت، در حالی که TPR برای Caucasian از 0.866 به 0.872 افزایش پیدا کرد. بنابراین حذف ویژگی حساس باعث شد بعضی اختلاف ها کمی کوچک تر شوند اما شکاف ها حذف نشدند. برای مثال شکاف selection_rate در race تقریبا از 0.197 به 0.193 کاهش یافت اما شکاف های TPR، FPR و PPV تقریبا بدون تغییر باقی ماندند.

برای sex هم وضعیت مشابهی دیده شد. نرخ انتخاب مثبت برای زنان از 0.374 به 0.378 افزایش یافت و برای مردان از 0.476 به 0.473 کاهش پیدا کرد. بنابراین شکاف selection_rate بین زن و مرد کمی کمتر شد، یعنی از حدود 0.102 به 0.095 رسید. اما این تغییر کوچک بود و اختلاف ها کاملا حذف نشدند. همچنین TPR زنان از 0.904 به 0.916 افزایش یافت و TPR مردان از 0.877 به 0.873 کاهش پیدا کرد، بنابراین شکاف TPR حتی کمی بیشتر شد. پس حذف مستقیم sex هم تضمین نکرد که رفتار مدل بین دو گروه کاملا برابر شود.

نتیجه کلی این است که انصاف از طریق ناآگاهی کافی نیست. اگرچه مدل دیگر مستقیما به race و sex دسترسی ندارد اما اطلاعات مربوط به این ویژگی ها می تواند در سایر ویژگی ها باقی مانده باشد. این همان چیزی بود که در مرحله ممیزی اولیه هم مشاهده شد: حتی بدون استفاده مستقیم از race، یک مدل می توانست تا حدی race را از روی سایر ویژگی ها پیش بینی کند. بنابراین ویژگی هایی مثل سن، تعداد سوابق قبلی، نوع اتهام، توضیح اتهام و سایر متغیرهای موجود در داده می توانند نقش پراکسی داشته باشند. به همین دلیل، حذف ستون حساس لزوما اثر ویژگی حساس را از مدل حذف نمی کند.

در این گراف دو مسیر از A به $\hat{Y}$ وجود دارد. مسیر اول که $A \rightarrow \hat{Y}$ است، یک مسیر پراکسی است. در این مسیر، جنسیت مستقیما روی امتیاز استخدام اثر می گذارد. بنابراین اگر دو فرد از نظر همه ویژگی های شغلی مشابه باشند، اما فقط جنسیت آن ها متفاوت باشد، امتیاز متفاوت می گیرند. یک پیش بین منصف باید جلوی این اثر مستقیم را بگیرد زیرا این همان استفاده تبعیض آمیز از ویژگی حساس است.

این نتیجه با پرسش 3-(ب) هم سازگار است. در آن پرسش، مدل علی به صورت $A \rightarrow X \rightarrow \hat{Y}$ و همچنین $A \rightarrow \hat{Y}$ بود. حذف race و sex از ورودی مدل فقط مسیر مستقیم $A \rightarrow \hat{Y}$ را حذف می کند اما مسیر غیر مستقیم $A \rightarrow X \rightarrow \hat{Y}$ همچنان می تواند باقی بماند. یعنی اگر ویژگی های دیگر X تحت تاثیر ویژگی حساس باشند یا اطلاعات آن را داشته باشند، مدل همچنان می تواند از طریق این پراکسی ها رفتار متفاوتی برای گروه های مختلف داشته باشد. بنابراین برای رسیدن به انصاف واقعی، فقط حذف ویژگی حساس کافی نیست و باید بررسی شود کدام مسیرهای علی از ویژگی حساس به تصمیم مدل مشروع هستند و کدام مسیرها باید مسدود شوند.

مرحله ۴ – تعدیل و مقایسه

در این مرحله دو روش تعدیل از دو دسته متفاوت اعمال شد و سپس عملکرد کلی مدل و معیارهای انصاف دوباره محاسبه شدند. روش اول Reweighing از دسته پیش پردازش بود و روش دوم بهینه سازی آستانه گروهی از دسته پس پردازش بود. برای مقایسه، نتایج این دو روش با مدل پایه مرحله 2 و مدل مرحله 3، مقایسه شدند. جدول کلی مقایسه به صورت زیر است:

	method	accuracy	roc_auc	race_all_selection_rate_gap	race_all_TPR_gap	race_all_FPR_gap	race_all_PPV_gap	sex_selection_rate_gap	sex_TPR_gap	sex_FPR_gap	sex_PPV_gap
0	baseline_step2	0.890	0.958	0.198	0.237	0.2	0.333	0.102	0.027	0.016	0.042
1	unawareness_step3	0.890	0.958	0.193	0.237	0.2	0.333	0.095	0.043	0.014	0.041
2	reweighing_race	0.890	0.957	0.170	0.211	0.2	0.333	0.097	0.041	0.016	0.040
3	postprocess_equal_opportunity	0.896	0.958	0.283	0.237	0.2	0.333	0.101	0.042	0.018	0.059

در روش Reweighing، داده های آموزشی تغییر داده نشدند بلکه به نمونه ها وزن متفاوت داده شد. وزن هر نمونه بر اساس ترکیب گروه حساس و برچسب واقعی محاسبه شد. به طوری که ترکیب های با نماینده کمتر ،وزن بیشتر و ترکیب های با نماینده بیشتر، وزن کمتر گرفتند. این وزن ها به صورت زیر محاسبه شدند:

$$w(a,y) = \frac{P(A=a)P(Y=y)}{P(A=a,Y=y)}$$

هدف این روش این است که وابستگی بین ویژگی حساس و برچسب در فرایند آموزش کمتر شود. بنابراین این روش بیشتر به مفهوم Independence یا همان برابری جمعیتی نزدیک است. در اجرای من، وزن ها میانگین 1 داشتند، کمترین وزن حدود 0.726 و بیشترین وزن حدود 1.821 بود. یعنی وزن دهی خیلی افراطی نبود و به همین دلیل انتظار تغییر بسیار شدید در مدل هم نمی رود. نتایج نشان داد که Reweighing دقت مدل را تقریبا تغییر نداد. Accuracy برابر 0.890 باقی ماند و ROC-AUC از 0.958 به 0.957 کاهش بسیار کمی داشت. از نظر شکاف های race روی همه گروه ها، شکاف selection_rate از 0.198 در مدل پایه به 0.170 کاهش یافت و شکاف TPR از 0.237 به 0.211 رسید. بنابراین این روش تا حدی اختلاف های مربوط به نرخ انتخاب و فرصت برابر را بهتر کرد. اما شکاف FPR برابر 0.200 و شکاف PPV برابر 0.333 باقی ماندند. اگر فقط دو گروه اصلی African-American و Caucasian را نگاه کنیم، اثر روش واضح تر است: شکاف selection_rate از 0.112 در مدل پایه به 0.097 رسید و شکاف TPR از 0.038 به 0.017 کاهش یافت. با این حال، شکاف FPR از 0.015 به 0.025 و شکاف PPV از 0.081 به 0.088 کمی بدتر شد. پس Reweighing بعضی معیارهای انصاف را بهتر کرد اما همه معیارها را همزمان بهتر نکرد. عملکرد کلی پس از اعمال این روش به صورت جدول های زیر است:

	group	n	base_rate	selection_rate	TPR	FPR	PPV	accuracy	TP	FP	TN	FN
0	African-American	635	0.523	0.513	0.895	0.096	0.911	0.899	297	29	274	35
1	Asian	7	0.286	0.429	1.000	0.200	0.667	0.857	2	1	4	0
2	Caucasian	420	0.390	0.417	0.878	0.121	0.823	0.879	144	31	225	20
3	Hispanic	102	0.373	0.343	0.789	0.078	0.857	0.873	30	5	59	8
4	Native American	2	0.500	0.500	1.000	0.000	1.000	1.000	1	0	1	0
5	Other	69	0.362	0.348	0.840	0.068	0.875	0.899	21	3	41	4

	group	n	base_rate	selection_rate	TPR	FPR	PPV	accuracy	TP	FP	TN	FN
0	Female	238	0.349	0.378	0.916	0.090	0.844	0.912	76	14	141	7
1	Male	997	0.480	0.475	0.875	0.106	0.884	0.885	419	55	463	60

روش دوم، پس پردازش با بهینه سازی آستانه بود. در این روش خود مدل دوباره آموزش داده نشد بلکه روی احتمال های خروجی مدل، آستانه تصمیم جداگانه برای دو گروه اصلی (به دلیل جمعیت بیشتر که در قسمت های قبل توضیح دادم) African-American و Caucasian انتخاب شد. آستانه های انتخاب شده برابر 0.13 برای African-American و 0.17 برای Caucasian بودند. هدف این روش کم کردن شکاف TPR بین این دو گروه بود. بنابراین این روش مستقیما مفهوم فرصت برابر را هدف می گیرد. چون این روش فقط آستانه تصمیم را تغییر می دهد و خود احتمال های مدل را عوض نمی کند، ROC-AUC تقریبا بدون تغییر باقی

می ماند. در نتیجه پس پردازش، Accuracy از 0.890 به 0.896 افزایش پیدا کرد و ROC-AUC همان 0.958 باقی ماند. از نظر هدف اصلی روش، یعنی شکاف TPR بین African-American و Caucasian، نتیجه بسیار قوی بود: این شکاف از 0.038 در مدل پایه و 0.026 در مدل مرحله 3 به فقط 0.003 رسید. یعنی از نظر فرصت برابر بین این دو گروه، روش پس پردازش تقریبا موفق شد. اما این بهبود هزینه داشت. شکاف selection_rate بین این دو گروه از 0.112 در مدل پایه به 0.118 افزایش یافت و شکاف FPR هم از 0.015 به 0.023 رسید. همچنین FPR برای هر دو گروه زیاد شد. برای African-American مقدار FPR به 0.191 و برای Caucasian به 0.168 رسید. PPV نیز نسبت به قبل کاهش پیدا کرد. مثلا PPV برای African-American از 0.906 در مدل پایه به 0.849 و برای Caucasian از 0.826 به 0.790 رسید. بنابراین روش پس پردازش توانست فرصت برابر را بهتر کند اما در عوض FPR و PPV ها را بدتر کرد. عملکرد کلی پس از اعمال این روش به صورت جدول های زیر است:

	group	n	base_rate	selection_rate	TPR	FPR	PPV	accuracy	TP	FP	TN	FN
0	African-American	635	0.523	0.606	0.985	0.191	0.849	0.901	327	58	245	5
1	Asian	7	0.286	0.429	1.000	0.200	0.667	0.857	2	1	4	0
2	Caucasian	420	0.390	0.488	0.988	0.168	0.790	0.893	162	43	213	2
3	Hispanic	102	0.373	0.324	0.763	0.062	0.879	0.873	29	4	60	9
4	Native American	2	0.500	0.500	1.000	0.000	1.000	1.000	1	0	1	0
5	Other	69	0.362	0.348	0.840	0.068	0.875	0.899	21	3	41	4

	group	n	base_rate	selection_rate	TPR	FPR	PPV	accuracy	TP	FP	TN	FN
0	Female	238	0.349	0.445	1.000	0.148	0.783	0.903	83	23	132	0
1	Male	997	0.480	0.547	0.958	0.166	0.842	0.894	459	86	432	20

برای مقایسه دقیق تر، شکاف های بین دو گروه اصلی African-American و Caucasian جداگانه بررسی شدند چون گروه هایی مثل Asian و Native American نمونه های بسیار کمی دارند و معیارهایی مانند TPR یا FPR برای آن ها ناپایدار است. در این مقایسه، Reweighing بهترین کاهش را در شکاف selection_rate ایجاد کرد و آن را به 0.097 رساند. از طرف دیگر، Post-processing بهترین نتیجه را برای شکاف TPR داشت و آن را به 0.003 رساند. پس هر روش در معیار هدف خودش بهتر عمل کرد : Reweighing بیشتر نرخ انتخاب را متعادل کرد در حالی که Post-processing تقریبا فرصت برابر را بین دو گروه اصلی برقرار کرد. تصویر جدول مربوط به این مقایسه به صورت زیر است:

	method	selection_rate_gap_AfricanAmerican_Caucasian	TPR_gap_AfricanAmerican_Caucasian	FPR_gap_AfricanAmerican_Caucasian	PPV_gap_AfricanAmerican_Caucasian
0	baseline_step2	0.112	0.038	0.015	0.081
1	unawareness_step3	0.105	0.026	0.018	0.082
2	reweighing	0.097	0.017	0.025	0.088
3	postprocess_equal_opportunity	0.118	0.003	0.023	0.059

از نظر ویژگی sex، تغییرها نسبت به race کمتر بودند. در مدل پایه شکاف selection_rate برابر 0.102 بود. در مدل مرحله 3 این مقدار به 0.095 رسید، در Reweighing برابر 0.097 شد و در Post-processing دوباره به 0.101 رسید. شکاف TPR برای sex در مدل پایه 0.027 بود اما در روش های تعدیل حدود 0.041 تا 0.043 شد. بنابراین روش هایی که برای race طراحی شده بودند، لزوما باعث بهبود معیارهای sex نشدند. این نکته نشان می دهد تعدیل برای یک ویژگی حساس ممکن است برای ویژگی حساس دیگر اثر خنثی یا حتی منفی داشته باشد. تصویر جدول مربوط به این مقایسه به صورت زیر است:

	method	selection_rate_gap_sex	TPR_gap_sex	FPR_gap_sex	PPV_gap_sex
0	baseline_step2	0.102	0.027	0.016	0.042
1	unawareness_step3	0.095	0.043	0.014	0.041
2	reweighing_race	0.097	0.041	0.016	0.040
3	postprocess_equal_opportunity	0.101	0.042	0.018	0.059

پس در نهایت هیچ روشی همه معیارها را همزمان بهتر نکرد. Reweighing با هزینه تقریبا صفر از نظر Accuracy، شکاف نرخ انتخاب و تا حدی شکاف TPR را کاهش داد اما FPR و PPV را برای دو گروه اصلی کمی بدتر کرد. Post-processing با هدف فرصت برابر توانست شکاف TPR بین African-American و Caucasian را تقریبا از بین ببرد اما در عوض نرخ انتخاب، FPR و PPV بدتر شدند. بنابراین این مرحله به صورت تجربی نشان می دهد که تعدیل انصاف یک مسئله تک معیاری نیست و هر روش یک تعریف خاص از انصاف را هدف می گیرد و بهبود یک معیار می تواند باعث بدتر شدن معیارهای دیگر شود.

مرحله ۵ – عدم امکان تجربی و مرز بده بستان

الف) در این بخش هدف این بود که رابطه بین دقت مدل و انصاف مدل را به صورت تجربی بررسی کنیم. مدل به جای اینکه فقط با آستانه ثابت 0.5 تصمیم بگیرد، با چند آستانه مختلف ارزیابی شد که به این کار sweeping یا جاروب آستانه گفته می شود. یعنی آستانه تصمیم را روی یک بازه حرکت می دهیم و در هر مقدار، دوباره خروجی صفر و یک مدل، دقت و سنجه انصاف را محاسبه می کنیم.

در این آزمایش، مدل برای هر فرد یک احتمال برای two_year_recid = 1 تولید می کند. سپس با یک آستانه تصمیم می گیریم که خروجی نهایی مثبت یا منفی باشد. مثلا اگر آستانه 0.35 باشد، هر فردی که احتمال پیش بینی شده او حداقل 0.35 باشد، به عنوان مثبت پیش بینی می شود. اگر آستانه را زیاد کنیم، مدل سخت گیرتر می شود و افراد کمتری را مثبت پیش بینی می کند. اگر آستانه را کم کنیم، مدل افراد بیشتری را مثبت پیش بینی می کند.

برای سنجش انصاف، در این بخش از شکاف TPR بین دو گروه اصلی African-American و Caucasian استفاده کردم (که جمعیت بیشتری دارند و مقایسه بهتری روی اینها می توان انجام داد). اگر شکاف TPR کوچک باشد، یعنی از بین افرادی که واقعا تکرار جرم داشته اند، مدل در دو گروه تقریبا با نرخ مشابهی افراد مثبت را درست تشخیص داده است. بنابراین مقدار کمتر برای این شکاف بهتر است. از طرف دیگر، برای دقت مدل، مقدار بیشتر بهتر است. همچنین مرز پارتو یعنی مجموعه تنظیم هایی که نمی توان بدون هزینه دادن در یک هدف، هدف دیگر را بهتر کرد. مثلا اگر بخواهیم شکاف انصاف را کمتر کنیم، ممکن است مجبور شویم کمی دقت را از دست بدهیم یا اگر بخواهیم دقت را بیشتر کنیم، ممکن است شکاف انصاف بیشتر شود. جدول نتایج برای threshold های مختلف به صورت زیر است:

Threshold sweep results:

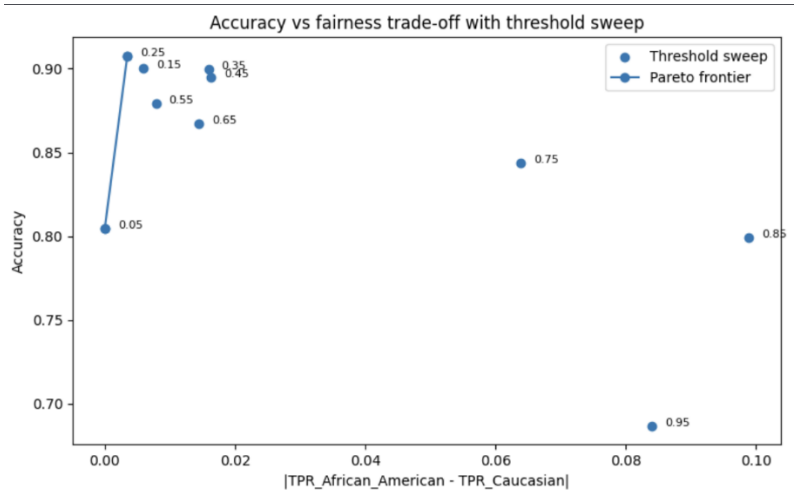
	threshold	accuracy	tpr_gap	TPR_African_American	TPR_Caucasian
0	0.05	0.805	0.000	1.000	1.000
1	0.15	0.900	0.006	0.982	0.988
2	0.25	0.908	0.003	0.967	0.963
3	0.35	0.900	0.016	0.943	0.927
4	0.45	0.895	0.016	0.913	0.896
5	0.55	0.879	0.008	0.855	0.848
6	0.65	0.867	0.014	0.819	0.805
7	0.75	0.844	0.064	0.765	0.701
8	0.85	0.799	0.099	0.642	0.543
9	0.95	0.687	0.084	0.358	0.274

Pareto frontier points:

	threshold	accuracy	tpr_gap	TPR_African_American	TPR_Caucasian
0	0.05	0.805	0.000	1.000	1.000
2	0.25	0.908	0.003	0.967	0.963

نتایج نشان می دهد که آستانه تصمیم اثر واضحی روی هم دقت و هم انصاف دارد. در آستانه بسیار پایین 0.05، مدل همه افراد واقعا مثبت را در هر دو گروه شناسایی کرده است و مقدار TPR برای هر دو گروه برابر 1.000 شده است. بنابراین شکاف TPR دقیقا 0 است. اما دقت مدل در این حالت فقط 0.805 است. دلیلش این است که آستانه خیلی پایین باعث می شود افراد زیادی مثبت پیش بینی شوند و در نتیجه تعداد مثبت های کاذب زیاد شود. در آستانه 0.25، بهترین دقت به دست آمده است. Accuracy برابر 0.908 شده و شکاف TPR هم 0.003 است. یعنی این آستانه هم از نظر دقت بهترین عملکرد را دارد و هم از نظر شکاف فرصت برابر بین دو گروه اصلی بسیار خوب است. در آستانه های 0.35 و 0.45، دقت کمی کمتر و برابر حدود 0.900 و 0.895 شده، اما شکاف TPR به 0.016 رسیده است. در آستانه های بالاتر مثل 0.75، 0.85 و 0.95، دقت کاهش زیادی پیدا کرده و شکاف TPR هم بزرگ تر شده است. مثلا در آستانه 0.85،

دقت 0.799 و شکاف TPR برابر 0.099 است. این یعنی آستانه های خیلی بالا هم از نظر دقت و هم از نظر این سنجه انصاف مناسب نیستند. منحنی بده بستان دقت در برابر انصاف به صورت زیر است:



مرز پارتو در این نمودار نشان می دهد کدام تنظیم ها از نظر دقت و انصاف بهترین هستند. در اینجا دو نقطه روی مرز پارتو قرار گرفته اند: آستانه 0.05 و آستانه 0.25. آستانه 0.05 از نظر انصاف بهترین است چون شکاف TPR آن صفر است اما دقت آن پایین تر است. آستانه 0.25 دقت بسیار بالاتری دارد و شکاف انصاف آن 0.003 است. بنابراین آستانه 0.25 در عمل گزینه مناسب تری به نظر می رسد چون با یک افزایش بسیار کوچک در شکاف انصاف، دقت را از 0.805 به 0.908 می رساند. در مقابل، سایر آستانه ها روی مرز پارتو نیستند چون یک نقطه دیگر وجود دارد که هم دقت بیشتری دارد و هم شکاف انصاف کمتری دارد. پس تغییر آستانه تصمیم می تواند رابطه بین دقت و انصاف را عوض کند.

ب) در این بخش هدف این بود که به صورت تجربی بررسی کنیم آیا می توان با تغییر آستانه های تصمیم، چند معیار انصاف را همزمان برقرار کرد یا نه. برای این کار، فقط دو گروه اصلی African-American و Caucasian را در نظر گرفتم. در این آزمایش برای هر گروه یک آستانه جداگانه در نظر گرفته شد. یعنی به جای اینکه برای همه افراد یک آستانه مشترک مثل 0.5 استفاده کنیم، آستانه African-American و آستانه Caucasian را جداگانه روی بازه ای از مقدار ها sweep کردم. برای هر جفت آستانه، خروجی مدل دوباره ساخته شد و سه شکاف اصلی محاسبه شد: شکاف برابری جمعیتی (dp_gap)، شکاف فرصت برابر (eo_gap)، و شکاف PPV. هدف این بود که ببینیم آیا می توان این سه شکاف را همزمان به صفر یا نزدیک صفر رساند یا نه. نتایج نشان داد که هیچ جفت آستانه ای نتوانست هر سه شکاف را همزمان خیلی کوچک کند. در خروجی، تعداد جفت آستانه هایی که هر سه شکافشان کمتر از 0.001، 0.005، 0.01 و حتی 0.02 باشد،

همگی صفر بود. بنابراین در این آزمایش، حتی با جست و جوی گسترده روی آستانه های گروهی، نتوانستم همزمان برابری جمعیتی، فرصت برابر و برابری PPV را برقرار کنم. جداول این بخش به صورت زیر شدند:

Demographic parity gap:

	t_AfricanAmerican	t_Caucasian	accuracy	dp_gap	eo_gap	ppv_gap	fpr_gap	fnr_gap	max_three_gaps	sum_three_gaps
0	0.16	0.06	0.8616	0.0000	0.0211	0.2038	0.1610	0.0211	0.2038	0.2249
1	0.17	0.06	0.8616	0.0000	0.0211	0.2038	0.1610	0.0211	0.2038	0.2249
2	0.80	0.57	0.8455	0.0000	0.1185	0.1229	0.0704	0.1185	0.1229	0.2414
3	0.77	0.49	0.8569	0.0001	0.1341	0.1116	0.0644	0.1341	0.1341	0.2458
4	0.91	0.81	0.7668	0.0002	0.1008	0.1029	0.0427	0.1008	0.1029	0.2038

Equal opportunity gap:

	t_AfricanAmerican	t_Caucasian	accuracy	dp_gap	eo_gap	ppv_gap	fpr_gap	fnr_gap	max_three_gaps	sum_three_gaps
0	0.05	0.06	0.8076	0.1118	0.0	0.0834	0.0502	0.0	0.1118	0.1953
1	0.05	0.05	0.8038	0.1023	0.0	0.0938	0.0346	0.0	0.1023	0.1961
2	0.05	0.04	0.7905	0.0690	0.0	0.1275	0.0201	0.0	0.1275	0.1965
3	0.04	0.06	0.7886	0.1433	0.0	0.0519	0.1162	0.0	0.1433	0.1952
4	0.04	0.05	0.7848	0.1338	0.0	0.0622	0.1006	0.0	0.1338	0.1960

PPV gap:

	t_AfricanAmerican	t_Caucasian	accuracy	dp_gap	eo_gap	ppv_gap	fpr_gap	fnr_gap	max_three_gaps	sum_three_gaps
0	0.64	0.93	0.8133	0.3391	0.5234	0.0	0.0570	0.5234	0.5234	0.8626
1	0.81	0.96	0.7754	0.2898	0.4670	0.0	0.0318	0.4670	0.4670	0.7568
2	0.99	0.97	0.5791	0.0526	0.1531	0.0	0.0000	0.1531	0.1531	0.2057
3	0.99	0.98	0.5640	0.0145	0.0555	0.0	0.0000	0.0555	0.0555	0.0700
4	0.99	0.99	0.5498	0.0212	0.0359	0.0	0.0000	0.0359	0.0359	0.0571

وقتی فقط برابری جمعیتی را هدف گرفتیم، بعضی آستانه ها توانستند dp_gap را تقریبا صفر کنند. اما صفر کردن نرخ انتخاب مثبت بین دو گروه، باعث نشد معیارهای دیگر هم برابر شوند. این نشان می دهد که برابری جمعیتی به تنهایی تضمین کننده برابری خطاها یا برابری دقت مثبت نیست. وقتی فقط فرصت برابر را هدف گرفتم، توانستم eo_gap را صفر کنم. اما برابر کردن TPR بین دو گروه باعث نشد PPV برابر شود. بنابراین حتی اگر مدل از نظر فرصت برابر خوب به نظر برسد، ممکن است از نظر معیارهای دیگر همچنان نابرابر باشد. برای PPV gap هم همین رفتار دیده شد. بعضی جفت آستانه ها توانستند شکاف PPV را صفر کنند اما هزینه آن زیاد بود و باعث اختلاف شدید در نرخ انتخاب یا TPR شد. در بهترین جفت آستانه از نظر کوچک کردن همزمان سه شکاف، هر دو آستانه برابر 0.98 انتخاب شدند. در این حالت، dp_gap = 0.0327، eo_gap = 0.0318 و PPV gap = 0.0208 شد. این نتیجه از نظر همزمانی سه معیار بهتر از بسیاری از حالت های دیگر بود اما دقت مدل فقط 0.5905 شد. دلیلش این است که آستانه بسیار بالا باعث می شود مدل فقط تعداد کمی از افراد را مثبت پیش بینی کند. در نتیجه معیارهایی مثل PPV و FPR بهتر به نظر می رسند اما بسیاری از افراد واقعا مثبت از دست می روند و FNR بسیار بالا می رود. نتیجه این قسمت به صورت زیر شد:

```
Best chosen thresholds:
African-American threshold: 0.98
Caucasian threshold: 0.98

Group metrics at best threshold pair:
```

	group	n	base_rate	selection_rate	TPR	FPR	FNR	PPV	accuracy	TP	FP	TN	FN
0	African-American	635	0.5228	0.0756	0.1416	0.0033	0.8584	0.9792	0.5496	47	1	302	285
1	Caucasian	420	0.3905	0.0429	0.1098	0.0000	0.8902	1.0000	0.6524	18	0	256	146

برای ارتباط با نتیجه پرسش 2، اتحاد چولدچوا هم بررسی شد. خروجی نشان داد که مقدار FPR مشاهده شده و مقدار FPR محاسبه شده از این اتحاد برای هر دو گروه کاملا برابر بودند و خطای مطلق صفر شد. برای African-American مقدار FPR_observed و FPR_from_identity هر دو 0.0033 بود. برای Caucasian هم هر دو مقدار برابر صفر شدند. بنابراین داده ها و خروجی های مدل دقیقا از همان رابطه نظری پیروی می کنند. به صورت زیر:

	group	base_rate_p	FPR_observed	FNR_observed	PPV_observed	FPR_from_identity	absolute_error
0	African-American	0.522835	0.0033	0.858434	0.979167	0.0033	0.0
1	Caucasian	0.390476	0.0000	0.890244	1.000000	0.0000	0.0

این نتیجه توضیح می دهد چرا همزمان برابر کردن معیارها دشوار است. وقتی نرخ پایه دو گروه متفاوت باشد، اگر بخواهیم PPV و نرخ های خطا مثل FPR و FNR را همزمان برابر کنیم، طبق این اتحاد با محدودیت ریاضی روبه رو می شویم. در داده ما نرخ پایه دو گروه برابر نیست، چون African-American نرخ پایه حدود 0.5228 و Caucasian نرخ پایه حدود 0.3905 دارد. بنابراین انتظار نداریم که با یک تنظیم ساده آستانه، همزمان برابری جمعیتی، فرصت برابر و PPV برابر برقرار شود.

مرحله ۶ – ممیزی تقاطعی

در این مرحله، بهترین مدل مرحله قبل (که مدل پس پردازش مرحله 4 بود) دوباره از نظر انصاف ممیزی شد اما این بار فقط به گروه های حاشیه ای مثل race یا sex جداگانه نگاه نکردیم. به جای آن، زیرگروه های تقاطعی race × sex ساخته شدند. یعنی برای هر فرد یک گروه جدید به صورت ترکیب race و sex تعریف شد، مثلا:

African-American | Male

African-American | Female

Caucasian | Male

Caucasian | Female

Hispanic | Male

سپس برای هر زیرگروه، همان معیارهای قبلی شامل selection_rate، TPR، FPR، FNR، PPV و accuracy محاسبه شد. هدف این بود که ببینیم آیا مدلی که در تحلیل حاشیه ای نسبتا قابل قبول به نظر می رسد، در سطح زیرگروه های تقاطعی همچنان منصفانه رفتار می کند یا نه. نتایج به صورت زیر شدند:

Marginal metrics by race:

	group	n	base_rate	selection_rate	TPR	FPR	FNR	PPV	accuracy	TP	FP	TN	FN
0	African-American	635	0.523	0.606	0.985	0.191	0.015	0.849	0.901	327	58	245	5
1	Caucasian	420	0.390	0.488	0.988	0.168	0.012	0.790	0.893	162	43	213	2
2	Hispanic	102	0.373	0.324	0.763	0.062	0.237	0.879	0.873	29	4	60	9
3	Other	69	0.362	0.348	0.840	0.068	0.160	0.875	0.899	21	3	41	4
4	Asian	7	0.286	0.429	1.000	0.200	0.000	0.667	0.857	2	1	4	0
5	Native American	2	0.500	0.500	1.000	0.000	0.000	1.000	1.000	1	0	1	0

Marginal metrics by sex:

	group	n	base_rate	selection_rate	TPR	FPR	FNR	PPV	accuracy	TP	FP	TN	FN
0	Male	997	0.480	0.547	0.958	0.166	0.042	0.842	0.894	459	86	432	20
1	Female	238	0.349	0.445	1.000	0.148	0.000	0.783	0.903	83	23	132	0

Intersectional metrics by race x sex:

	group	n	base_rate	selection_rate	TPR	FPR	FNR	PPV	accuracy	TP	FP	TN	FN
0	African-American | Male	519	0.561	0.638	0.983	0.197	0.017	0.864	0.904	286	45	183	5
1	Caucasian | Male	316	0.396	0.494	0.984	0.173	0.016	0.788	0.889	123	33	158	2
2	African-American | Female	116	0.353	0.466	1.000	0.173	0.000	0.759	0.888	41	13	62	0
3	Caucasian | Female	104	0.375	0.471	1.000	0.154	0.000	0.796	0.904	39	10	55	0
4	Hispanic | Male	92	0.402	0.348	0.757	0.073	0.243	0.875	0.859	28	4	51	9
5	Other | Male	61	0.377	0.361	0.826	0.079	0.174	0.864	0.885	19	3	35	4
6	Hispanic | Female	10	0.100	0.100	1.000	0.000	0.000	1.000	1.000	1	0	9	0
7	Other | Female	8	0.250	0.250	1.000	0.000	0.000	1.000	1.000	2	0	6	0
8	Asian | Male	7	0.286	0.429	1.000	0.200	0.000	0.667	0.857	2	1	4	0
9	Native American | Male	2	0.500	0.500	1.000	0.000	0.000	1.000	1.000	1	0	1	0

در تحلیل حاشیه ای بر اساس sex، شکاف ها نسبتا کوچک بودند. برای مثال شکاف TPR بین زن و مرد برابر 0.042، شکاف FPR برابر 0.018 و شکاف PPV برابر 0.059 بود. این یعنی اگر فقط به جنسیت نگاه کنیم، مدل خیلی نابرابر به نظر نمی رسد. البته شکاف selection_rate برابر 0.101 بود که یعنی مدل مردان را با نرخ بیشتری نسبت به زنان مثبت پیش بینی کرده است.

در تحلیل حاشیه ای بر اساس race، شکاف ها بزرگ تر بودند. برای مثال شکاف selection_rate برابر 0.283، شکاف TPR برابر 0.237 و شکاف PPV برابر 0.333 بود. بخشی از این شکاف به دلیل گروه های کوچک مثل Asian و Native American است که تعداد نمونه کمی دارند و معیارهای آن ها ناپایدار است. با این حال، همین نتیجه نشان می دهد که رفتار مدل در گروه های نژادی کاملا یکسان نیست.

اما نکته مهم تر در جدول تقاطعی دیده می شود. وقتی ترکیب race × sex را بررسی کردم، شکاف ها در بسیاری از معیارها بزرگ تر شدند. مثلا شکاف selection_rate روی همه زیرگروه های تقاطعی برابر 0.538 شد، در حالی که این مقدار برای race به تنهایی 0.283 و برای sex به تنهایی 0.101 بود. این یعنی اگر فقط race یا فقط sex را جداگانه بررسی کنیم، شدت اختلاف در بعضی زیرگروه ها پنهان می ماند.

در جدول دوم که در بالا گذاشته ام، نرخ هر زیرگروه مشاهده می شود. در سطح تقاطعی می بینیم که بعضی زیرگروه ها، از نظر TPR وضعیت بدتری دارند. این نتیجه نمونه ای از fairness gerrymandering در پرسش 7 الف است. یعنی ممکن است مدل در معیارهای حاشیه ای، مخصوصا برای یک ویژگی مثل sex، نسبتا منصفانه به نظر برسد، اما وقتی زیرگروه های دقیق تر را بررسی می کنیم، نابرابری های پنهان آشکار می شوند. در اینجا اگر فقط به sex نگاه می کردیم، شکاف ها کوچک بودند و ممکن بود نتیجه بگیریم مدل از نظر جنسیت مشکل جدی ندارد. اما با ترکیب raceوsex ، می بینیم که بعضی گروه های خاص رفتار متفاوتی از مدل دریافت می کنند.

سوال دوم: حریم خصوصی در یادگیری ماشین و یادگیری فدرال

بخش اول: سوالات توضیحی

زیربخش اول: (حساسیت و مکانیزم لاپلاس)

الف)

q_1: فرض می کنیم مقدار مصرف خانوار متفاوت در دو دیتاست به ترتیب x و x′ باشد. میانگین مصرف برابر است با:

$$q_1(D) = \frac{1}{1000}\sum_{i=1}^{1000} x_i$$

از آنجا که تنها مقدار یک خانوار تغییر می کند، اختلاف دو میانگین برابر است با:

$$|q_1(D) - q_1(D')| = \frac{|x - x'|}{1000}$$

بیشترین اختلاف ممکن میان دو مقدار مصرف برابر با 100 است که یعنی یک مقدار می تواند نزدیک صفر و مقدار دیگر نزدیک 100 باشد. پس:

$$\Delta_1(q_1) = \frac{100}{1000} = 0.1$$

که البته به دلیل باز بودن دو سر بازه دقیقا به 0.1 نمی رسد اما کران بالایش این است.

q_2: کل مصرف خانوار ها برابر است با:

$$q_2(D) = 1000\sum_{i=1}^{1000} x_i$$

با تغییر مقدار مصرف یک خانوار، اختلاف میان دو خروجی برابر است با:

$$|q_2(D) - q_2(D')| = |x - x'|$$

که بیشترین اختلاف اینها همان سر و ته بازه است که می شود 100:

$$\Delta_1(q_2) = 100$$

q_3: خروجی این درخواست یک بردار شش بعدی به صورت زیر است:

$$q_3(D) = (c_1, c_2, c_3, c_4, c_5, c_6)$$

که در آن c_j تعداد خانوار های حاضر در الگوی j است و طبق سوال هر خانوار می تواند حداکثر در دو الگو ظاهر شود. برای به دست آوردن بیشترین حساسیت، فرض می کنیم خانوار مورد نظر در دیتاست اول در دو الگو قرار داشته باشد و در دیتاست دوم به دو الگوی کاملا متفاوت منتقل شود. در این حالت شمارش دو الگوی D هر کدام یک واحد کاهش می یابد و شمارش دو الگوی D' هر کدام یک واحد افزایش می یابد. بنابراین اختلاف بردارها می تواند مثلا به شکل زیر باشد:

$$q_3(D) - q_3(D') = (1,1,-1,-1,0,0)$$

و در نتیجه $l1$ آن می شود:

$$|q_3(D) - q_3(D')|_1 = |1| + |1| + |-1| + |-1| = 4$$

پس:

$$\Delta_1(q_3) = 4$$

اینجا طبق سوال همسایگی را از نوع جایگزینی در نظر گرفتم و نه حذف یا اضافه.

ب) طبق اسلاید های درس، اثبات شد که پارامتر b برای مکانیزم لاپلاس به صورت زیر است:

$$b = \frac{\Delta_1(q)}{\epsilon}$$

همچنین مقدار اپسیلون هم برابر 0.2 است. پس با انجام این تقسیم برای هر سه کوئری، مقدار b برای q_1 برابر 0.5، برای q_2 برابر 500 و برای q_3 برابر 20 می شود.

زیربخش دوم: (انتشار خصوصی داده ها و report noisy max)

الف) میانگین واقعی مصرف برابر با 37.5 کیلووات ساعت است و نویز $1.8+$ به آن اضافه شده است. بنابراین میانگین خصوصی منتشر شده برابر با 39.3 است. همچنین کل مصرف واقعی برابر با 37500 کیلووات ساعت است و نویز $920-$ به آن اضافه شده است که کل مصرف خصوصی برابر می شود با 36580. این دو درخواست با هم ارتباط مستقیم دارند زیرا برای 1000 خانوار باید رابطه $q_2 = 1000q_1$ برقرار باشد اما بر اساس میانگین خصوصی منتشر شده، کل مصرف باید برابر با 39300 باشد در حالی که این عدد منتشر شده برابر با 36580 است و این دو با هم 2720 تا فاصله دارند. علت این ناسازگاری آن است که به هر درخواست به صورت مستقل نویز اضافه شده است. مکانیزم لاپلاس تضمین می کند که هر خروجی از نظر حریم خصوصی

مناسب باشد اما تضمین نمی کند که روابط منطقی و ریاضی میان چند خروجی مرتبط همچنان برقرار باقی بمانند. پس اضافه شدن دو نویز مستقل می تواند باعث تولید خروجی های ناسازگار شود. مقادیر واقعی و نویز های استفاده شده در صورت سوال هم به همین شکل تعریف شده اند.

یک راه حل مناسب، استفاده از post-processing و تصویر کردن خروجی ها روی مجموعه خروجی های سازگار است. ابتدا هر دو خروجی را به میانگین تبدیل می کنیم که می شوند 39.3 و 36.58. در زیربخش قبل، مقیاس نویز میانگین برابر 0.5 و مقیاس نویز کل مصرف برابر 500 بود. اگر نویز کل مصرف را بر 1000 تقسیم کنیم، مقیاس آن نیز برابر 0.5 می شود. بنابراین می توان این دو تخمین را با وزن برابر ترکیب کرد که می شود (39.3+36.58)/2 که می شود 37.94 و کل مصرف اصلاح شده برابر 37940 می شود. پس می توان دو خروجی 37.94 و 37940 را داد که رابطه بین آنها الان به درستی برقرار است.

ب) از قسمت قبل به دست آوردیم که:

$$\Delta_1(q_3) = 4$$

و در اینجا اپسیلو برابر 0.4 است و حاصل تقسیم اینها می شود b. پس b برابر 4/0.4 یا همان 10 است.

ج) در این حالت سامانه کل بردار شمارش ها را منتشر نمی کند و فقط شماره الگویی را برمی گرداند که پس از اضافه شدن نویز، بیشترین شمارش را دارد.

حساسیت هر درخواست شمارشی به تنهایی برابر با 1 است زیرا با تغییر اطلاعات یک خانوار، تعداد افراد موجود در یک الگوی مشخص حداکثر یک واحد افزایش یا کاهش پیدا می کند. طبق Report Noisy Max، به هر شمارش نویز مستقل با مقیاس $\frac{1}{\epsilon}$ اضافه می شود که در اینجا با اپسیلون 0.4 می شود 2.5 و در نتیجه نویز می شود توزیع لاپلاس با پارامتر 2.5. حال نویز های داده شده را روی بردار اعمال می کنیم و به صورت زیر می شود:

$$[306, 313, 189, 154, 111, 77]$$

بیشترین مقدار این بردار برابر با 313 است که به الگوی دوم مربوط می شود. بنابراین خروجی Report Noisy Max برابر است با الگوی دوم. در داده های واقعی، بیشترین شمارش برابر با 310 و متعلق به الگوی اول است. پس الگوی انتخاب شده با الگوی واقعا پر تکرار یکسان نیست.

حال این را از دید trade-off بین privacy و utility تحلیل می کنیم. در داده های واقعی، اختلاف تعداد الگوی اول و دوم برابر است با 15 = 295 – 310. اما اختلاف نویز الگوی دوم و اول برابر است با (-4) – 18 یا همان 22. چون اختلاف نویز ها از اختلاف واقعی دو شمارش بیشتر شده است، ترتیب الگوهای اول و دوم عوض شده و الگوریتم الگوی دوم را انتخاب کرده است. از نظر privacy، Report Noisy Max مناسب است زیرا به جای انتشار تمام شش شمارش، فقط نام یا اندیس پرتکرارترین الگو را منتشر می کند. بنابراین اطلاعات کمتری درباره توزیع کامل خانوار ها افشا می شود. همچنین مقیاس نویز آن برابر 2.5 است که از مقیاس 10 مورد نیاز برای انتشار کل بردار کمتر است. اما اضافه کردن نویز ممکن است باعث انتخاب الگویی شود که واقعا بیشترین تعداد را ندارد. این موضوع به خصوص زمانی رخ می دهد که شمارش دو الگوی اول به یکدیگر نزدیک باشند. در این مثال اختلاف واقعی دو الگوی اول فقط ۱۵ است و نویزها باعث جابه جا شدن آن ها شده اند. بنابراین کاهش ϵ و اضافه کردن نویز بیشتر، حفاظت از حریم خصوصی را افزایش می دهد، اما احتمال انتخاب پاسخ اشتباه و کاهش utility را هم بیشتر می کند. در این نمونه، حریم خصوصی بهتر حفظ شده اما utility کاهش یافته و پرتکرارترین الگو به اشتباه گزارش شده است.

زیربخش سوم: (تخصیص بودجه حریم خصوصی و ترکیب مکانیزم ها)

الف) یک تقسیم بندی مناسب می تواند به صورت زیر باشد:

$$\epsilon_{\text{mean}} = 0.3$$

$$\epsilon_{\text{Gaussian}} = 0.2$$

$$\epsilon_{\text{RNM}} = 0.1$$

این تقسیم بندی منطقی است زیرا طبق صورت سوال، دقت میانگین مصرف از دو خروجی دیگر مهم تر است. در مکانیزم های حریم خصوصی تفاضلی، هرچه مقدار اپسیلون بزرگ تر باشد، نویز کمتری به خروجی اضافه می شود و در نتیجه دقت بالاتر خواهد بود. به همین دلیل، بیشترین بودجه یعنی 0.3 به میانگین مصرف اختصاص داده شده است. برای بردار شمارش الگوها مقدار 0.2 در نظر گرفته شده است زیرا این خروجی شامل شش مقدار است و اضافه شدن نویز زیاد به آن می تواند کاربرد بردار را کاهش دهد. کمترین بودجه هم به Report Noisy Max داده شده چون این مکانیزم کل شمارش ها را منتشر نمی کند و فقط نام پرتکرارترین الگو را بر می گرداند. بنابراین نسبت به انتشار یک مقدار عددی دقیق، می تواند نویز بیشتری را تحمل کند. تقسیم بندی های دیگری نیز ممکن هستند به شرط آنکه مجموع بودجه ها برابر با 0.6 باشد و بودجه میانگین از دو مورد دیگر بیشتر در نظر گرفته شود.

ب) در زیربخش اول به دست آوردیم که حساسیت l1 میانگین مصرف برابر است با 0.1. با توجه به رابطه ای که برای بدست آوردن b در قسمت های قبل گفتم، این مقدار برابر تقسیم 0.1/0.3 می شود که می شود 1/3.

ج) طبق زیربخش اول قسمت ب، می دانیم بردار اختلاف $q_3(D) - q_3(D')$ شامل 4 مقدار با اندازه 1 است. همچنین رابطه حساسیت l2 به صورت زیر است:

$$\Delta_2(q_3) = \max_{D \sim D'} |q_3(D) - q_3(D')|_2$$

پس:

$$\Delta_2(q_3) = \sqrt{1^2 + 1^2 + (-1)^2 + (-1)^2}$$

$$\Delta_2(q_3) = \sqrt{4} = 2$$

برای مکانیزم گاوسی، با قرار دادن مقدار سیگمای داده شده در صورت سوال داریم:

$$c > \sqrt{2 \ln\left(\frac{1.25}{10^{-5}}\right)}$$

$$c > \sqrt{2 \ln(125000)}$$

و با توجه به اینکه $\ln(125000)$ تقریبا می شود 11.736، پس:

$$c > \sqrt{23.472}$$

$$c > 4.8448$$

همچنین چون اپسیلون گاوسی را 0.2 گرفتم در بخش قبل و $\Delta_2(q_3) = 2$ پس:

$$\sigma \geq \frac{4.8448 \times 2}{0.2}$$

$$\sigma \geq 48.448$$

پس حداقل مقدار آن تقریبا برابر 48.448 است.

د) طبق قانون سادهcomposition ، بودجه های حریم خصوصی مکانیزم هایی که روی داده های مرتبط اجرا می شوند با یکدیگر جمع می شوند که این می شود کران بالای مجموع آنها. بنابراین بودجه روزانه برابر است با 0.6. اگر همین سه گزارش در هفت روز متوالی منتشر شوند، کران ساده privacy loss کل هفته برابر می

شود با جمع مقدار اپسیلون هر 7 روز با هم که می شود 0.6×7 یا همان 4.2. همچنین چون فقط مکانیزم گوسی دارای گامای غیر صفر است، پس مقدار گاما برای کل هفته می شود 7×10^{-5}. پس برای کل هفته می شود $(4.2, 7 \times 10^{-5})$-DP.

اگر بخواهیم مجموع privacy loss در کل هفته حداکثر برابر با 0.6 باقی بماند، بودجه کل هر روز باید تقسیم بر 7 شود که در نتیجه اپسیلون به صورت $7 \times \frac{0.6}{7}$ برای کل هفته بشود همان 0.6. کاهش بودجه روزانه باعث افزایش نویز همه مکانیزم ها می شود. برای مثال، پارامتر لاپلاس میانگین که قبلا برابر 1/3 بود، به صورت 0.1/(0.3/7) می شود که می شود 2.3 و هر سه تای این b ها 7 برابر می شوند و بنابراین احتمال انتخاب الگوی اشتباه به مقدار قابل توجهی افزایش می یابد چون نویز توزیع لاپلاس 7 برابر می شود و به دلیل رابطه مستقیم b با واریانس توزیع لاپلاس، واریانس آن زیاد شده و خطا افزایش می یابد. برای مکانیزم گاوسی هم به همین صورت سیگما 7 برابر می شود و در نتیجه خروجی بردار شمارش ها هم نویز بسیار بیشتری خواهد داشت. پس با کاهش بودجه روزانه، حریم خصوصی کل هفته بهتر کنترل می شود، اما utility کاهش می یابد. یعنی میانگین منتشر شده خطای بیشتری خواهد داشت، احتمال انتخاب اشتباه در Report Noisy Max بیشتر می شود و مقادیر بردار شمارش گاوسی هم از مقادیر واقعی فاصله بیشتری خواهند گرفت.

بخش دوم: سوالات مفهومی

زیربخش اول: (حریم خصوصی، استحکام و یادگیری فدرال)

الف) خیر. یادگیری فدرال را نمی توان بدون استفاده از مکانیزم های تکمیلی، یک فناوری با تضمین کامل حریم خصوصی دانست. در یادگیری فدرال، داده های خام کاربران یا سازمان ها روی دستگاه خودشان باقی می مانند و به جای داده خام، پارامتر ها یا به روز رسانی های مدل برای سرور ارسال می شوند. این ویژگی در مقایسه با آموزش متمرکز، که در آن تمام داده های خام در یک سرور جمع آوری می شوند، یک بهبود عملی حریم خصوصی ایجاد می کند چون سرور مستقیما به کل داده های خام دسترسی ندارد. مقاله هم یادگیری فدرال را روشی میان آموزش کاملا متمرکز و آموزش کاملا محلی معرفی می کند که در آن شرکت کنندگان داده های خود را محلی نگه می دارند و فقط پارامترهای مدل را مبادله می کنند. با این حال، باقی ماندن داده خام روی دستگاه به این معنا نیست که هیچ اطلاعاتی از داده افشا نمی شود. گرادیان ها، پارامترهای محلی و حتی مدل تجمیع شده می توانند اطلاعاتی درباره داده های آموزشی در اختیار مهاجم قرار دهند. برای مثال، مقاله به حملات استنتاج عضویت، استنتاج ویژگی و حملات بازسازی یا افشای اطلاعات از به روز رسانی ها اشاره می کند. بنابراین اینجا دو مفهوم وجود دارد که باید بین آنها تفاوت قائل شویم. یکی بهبود عملی حریم خصوصی است و دیگری تضمین رسمی حریم خصوصی. در حالت اول سطح دسترسی

مستقیم سرور به اطلاعات کاهش می یابد. مثلا سرور به جای دریافت پرونده پزشکی کامل یک بیمارستان، فقط به روز رسانی مدل آن بیمارستان را دریافت می کند. این کار احتمال و شدت بعضی افشا ها را کمتر می کند اما یک کران دقیق و قابل اثبات برای مقدار افشای اطلاعات ارائه نمی دهد. اما در حالت دوم یک تعریف ریاضی مثل Differential Privacy وجود دارد که مقدار تاثیر یک فرد یا یک رکورد بر خروجی مکانیزم را با پارامترهای ϵ و δ محدود می کند. در نتیجه می توان به صورت رسمی کران بالایی برای privacy loss تعیین کرد. مقاله می گوید که Differential Privacy با افزودن نویز، یک کران آماری بر تاثیری که یک فرد می تواند بر خروجی الگوریتم داشته باشد ایجاد می کند. پس یادگیری فدرال پایه فقط یک معماری privacy-friendly است نه یک سیستم دارای تضمین رسمی حریم خصوصی.

ب) حریم خصوصی و استحکام به دو نوع تهدید متفاوت مربوط می شوند. حریم خصوصی به جلوگیری از استخراج اطلاعات حساس از داده های آموزشی مربوط است. مهاجم ممکن است بخواهد بفهمد یک نمونه خاص در داده های آموزش حضور داشته است یا نه و یا ویژگی هایی از داده های یک شرکت کننده را استنتاج کند. بنابراین هدف حریم خصوصی این است که اطلاعات مربوط به رکوردها یا شرکت کنندگان از طریق مدل و به روز رسانی های آن افشا نشود.

اما استحکام به حفظ عملکرد صحیح مدل در حضور شرکت کنندگان مخرب مربوط است. در این حالت مهاجم لزوما قصد استخراج اطلاعات ندارد بلکه می خواهد فرایند آموزش یا رفتار مدل نهایی را تغییر دهد. برای مثال، در حمله Backdoor یک شرکت کننده مخرب به روز رسانی دستکاری شده ای ارسال می کند تا مدل برای ورودی های خاص، خروجی مورد نظر مهاجم را تولید کند. مقاله هم حملات Backdoor را در دسته تهدیدهای استحکام و حملات Membership و Property Inference را در دسته تهدیدهای حریم خصوصی بررسی می کند .

رسیدن به یکی از این اهداف لزوما دیگری را تضمین نمی کند. برای مثال، مقاله نشان می دهد که دفاع Norm Bounding می تواند اثر حمله Backdoor را کاهش دهد اما تضمین حریم خصوصی ایجاد نمی کند زیرا به روز رسانی های شرکت کنندگان همچنان به صورت آشکار برای سرور ارسال می شوند و می توانند اطلاعات داده های آموزش را افشا کنند. همچنین Weak DP ممکن است در برابر Backdoor موثر باشد اما به دلیل محاسبه نامناسب بودجه در دورهای متوالی، مقدار ϵ بسیار بزرگی ایجاد می کند و حفاظت مناسبی از حریم خصوصی ارائه نمی دهد. از طرف دیگر، یک مکانیزم حفظ حریم خصوصی هم لزوما تمام حملات استحکام را متوقف نمی کند. برای مثال، اگر LDP فقط توسط کاربران سالم اجرا شود ولی مهاجم از افزودن

نویز خودداری کند، سهم کاربران سالم کم می شود و به روز رسانی مهاجم می تواند اثر بیشتری بر مدل تجمیع شده داشته باشد. پس حریم خصوصی و استحکام با یکدیگر ارتباط دارند، اما یکسان نیستند و یک سامانه مناسب باید هر دو نوع تهدید را جداگانه ارزیابی کند و میان حریم خصوصی، استحکام و utility تعادل برقرار کند.

ج) نمی توان الزاما این ادعا را کرد. در سامانه A، تمام داده های خام در سرور مرکزی جمع آوری می شوند. بنابراین اگر سرور مورد نفوذ قرار بگیرد، داده های خام کاربران مستقیما در معرض خطر قرار می گیرند. در سامانه B، داده خام محلی باقی می ماند و فقط به روز رسانی مدل برای سرور ارسال می شود. از این نظر، سامانه B معمولا یک بهبود عملی نسبت به سامانه A ایجاد می کند زیرا واگذاری به روز رسانی مدل به سرور، فرض اعتماد ضعیف تری نسبت به واگذاری کامل داده های خام است. خود مقاله هم می گوید که اعتماد کردن به سرور در مورد به روز رسانی های مدل، از سپردن خود داده های خام به سرور فرض ضعیف تری است. با این حال، به روز رسانی مدل کاملا بی خطر نیست. سرور می تواند با تحلیل گرادیان ها یا پارامترهای دریافتی، اطلاعاتی درباره نمونه های آموزشی، عضویت یک نمونه یا ویژگی های داده های محلی به دست آورد. همچنین مدل تجمیع شده هم ممکن است اطلاعاتی درباره داده های آموزش افشا کند. مقاله از ابتدا تاکید می کند که نگهداری محلی داده ها و فقط مبادله کردن به روز رسانی ها، سامانه را از آسیب پذیری های حریم خصوصی و استحکام حفظ نمی کند. برابر بودن دقت نهایی دو سامانه هم چیزی درباره میزان حریم خصوصی آن ها نشان نمی دهد و فقط کیفیت مدل در انجام وظیفه اصلی را اندازه گیری می کند و مشخص نمی کند که چه مقدار اطلاعات از داده های آموزش قابل استخراج است. ممکن است دو مدل دقت یکسانی داشته باشند، اما یکی از آن ها در برابر حمله استنتاج عضویت بسیار آسیب پذیرتر باشد. بنابراین نتیجه صحیح این است که سامانه B معمولا سطح تماس مستقیم با داده خام را کاهش می دهد و از نظر عملی می تواند بهتر از سامانه A باشد، اما بدون مکانیزمی مانند Differential Privacy هیچ تضمین رسمی وجود ندارد و نمی توان گفت سامانه B در همه شرایط الزاما حریم خصوصی بیشتری فراهم می کند.

زیربخش دوم: (حملات حریم خصوصی و مسموم سازی در یادگیری فدرال)

الف) حملات را می توان در دو دسته اصلی قرار داد.

1- حملات حریم خصوصی و استنتاجی

هدف این حملات تغییر عملکرد مدل نیست، بلکه مهاجم می خواهد از مدل، گرادیان ها یا به روز رسانی های اشتراکی، اطلاعاتی درباره داده های خصوصی استخراج کند.

الف) حمله Gradient Leakage:

در این حمله، مهاجم با مشاهده گرادیان ارسال شده از طرف یک کلاینت، داده های ورودی آن کلاینت را بازسازی یا تخمین می زند. مهاجم معمولا یک داده فرضی ایجاد می کند و آن را طوری بهینه می کند که گرادیان تولید شده توسط آن به گرادیان واقعی کلاینت نزدیک شود. درواقع سرور می تواند با مقایسه گرادیان داده فرضی با گرادیان دریافت شده، داده آموزش را بازسازی کند.

ب) حمله Membership Inference:

هدف این حمله تعیین این موضوع است که آیا یک نمونه مشخص در مجموعه آموزش یک کلاینت یا مدل وجود داشته است یا خیر. این حمله اطلاعات خود نمونه را لزوما بازسازی نمی کند اما حضور آن در داده های آموزش را افشا می کند.

ج) حمله Property Inference:

در این حمله مهاجم تلاش می کند یک ویژگی کلی یا پنهان از داده های یک کلاینت را استخراج کند حتی اگر آن ویژگی ارتباط مستقیمی با وظیفه اصلی مدل نداشته باشد. برای مثال، مدلی برای تشخیص جنسیت آموزش داده می شود اما مهاجم می خواهد بفهمد آیا افراد موجود در تصاویر یک کلاینت عینک دارند یا خیر. این حمله هم در دسته حملات حریم خصوصی قرار می گیرد زیرا هدف آن افشای یک ویژگی پنهان از داده های آموزش است.

حملات استنتاجی را می توان از یک دید دیگر هم به دو دسته تقسیم کرد:

الف) در حمله منفعل، مهاجم فقط گرادیان ها و به روز رسانی ها را مشاهده می کند.

ب) در حمله فعال، مهاجم عمدا مدل یا به روز رسانی ها را دستکاری می کند تا اطلاعات بیشتری از واکنش کلاینت به دست آورد.

2- حملات مسموم سازی و استحکام

هدف این حملات افشای اطلاعات نیست بلکه مهاجم می خواهد روند آموزش یا رفتار مدل نهایی را تغییر دهد. روش های زیر برای این حمله وجود دارند:

الف) حمله Data Poisoning:

مهاجم داده های محلی خود را تغییر می دهد یا نمونه های مخرب به مجموعه آموزش اضافه می کند تا مدل نهایی رفتار مورد نظر او را یاد بگیرد. برای مثال، مهاجم می تواند تصاویر دارای یک الگوی خاص را با برچسب نادرست وارد آموزش کند.

ب) حمله Model Poisoning:

در این حالت مهاجم لزوما داده های محلی را تغییر نمی دهد بلکه مستقیما پارامترها، گرادیان ها یا به روز رسانی مدل محلی را قبل از ارسال به سرور دستکاری می کند. در مسموم سازی داده، نمونه های مخرب به مجموعه آموزش اضافه می شوند اما در مسموم سازی مدل، خود مدل محلی پیش از ارسال به سرور تغییر داده می شود.

ج) حمله Untargeted Poisoning:

هدف مهاجم کاهش دقت کلی مدل یا جلوگیری از همگرایی آن است. حملات Byzantine نمونه ای از مسموم سازی تصادفی مدل هستند که در آن کلاینت خروجی دلخواه یا مخرب ارسال می کند تا مدل تجمیع شده منحرف شود.

د) حمله Targeted Poisoning:

در این حالت مهاجم می خواهد مدل فقط روی مجموعه خاصی از ورودی ها رفتار اشتباهی داشته باشد، بدون آنکه دقت کلی مدل به مقدار زیادی کاهش پیدا کند.

ه) حمله Backdoor:

backdoor یک حالت خاص از مسموم سازی هدفمند مدل است. مهاجم یک trigger مشخص تعریف می کند و تلاش می کند مدل نهایی در صورت مشاهده آن trigger، برچسب دلخواه مهاجم را تولید کند در حالی که عملکرد مدل روی نمونه های عادی تقریبا حفظ شود.

ب) در یادگیری فدرال، داده های خام کلاینت ها به سرور ارسال نمی شوند. بنابراین سرور نمی تواند بررسی کند که داده های محلی هر شرکت کننده واقعی، سالم یا مسموم هستند. به همین دلیل مسموم سازی داده امکان پذیر است زیرا مهاجم کنترل داده های محلی خود را در اختیار دارد. با این حال، مسموم سازی مدل معمولا عملی تر و خطرناک تر است. دلیل اصلی این است که مهاجم به جای آنکه منتظر بماند داده های مسموم از طریق چند مرحله آموزش روی مدل اثر بگذارند، مستقیما به روز رسانی مورد نظر خود را تولید و برای سرور ارسال می کند. بنابراین کنترل بیشتری روی جهت و شدت تغییر مدل دارد. در مسموم سازی داده، تاثیر حمله به الگوریتم آموزش، تعداد نمونه های مخرب، نرخ یادگیری و تعداد epoch ها وابسته است. ممکن است داده مخرب پس از میانگین گیری با داده های سالم اثر کمی داشته باشد. اما در مسموم سازی مدل، مهاجم می تواند مستقیما گرادیان یا اختلاف پارامترها را طوری بسازد که مدل تجمیع شده به سمت هدف او حرکت کند. همچنین مهاجم می تواند اندازه به روز رسانی را بزرگ کند یا از روش model replacement استفاده کند تا اثر میانگین گیری به روز رسانی کاربران سالم را خنثی کند. مقاله می گوید که هر اثری که با داده مسموم قابل ایجاد باشد، با مسموم سازی مدل هم امکان پذیر است چون خروجی آموزش محلی در نهایت همان به روز رسانی مدل است که به سرور ارسال می شود. تشخیص مسموم سازی مدل هم دشوارتر است. در یادگیری فدرال داده کاربران معمولا non-IID است و حتی به روز رسانی یک کاربر سالم ممکن است با به روز رسانی سایر کاربران تفاوت زیادی داشته باشد. مهاجم می تواند از این ناهمگنی استفاده کند و به روز رسانی مخرب خود را شبیه یک به روز رسانی عادی نشان دهد. در واقع به روز رسانی مهاجم می تواند توزیعی شبیه کاربران سالم داشته باشد و در نتیجه تشخیص آن دشوار شود.

ج) حمله Isolating Gradient Ascent یک حمله استنتاج عضویت فعال از سمت سرور است. بنابراین مهاجم در اینجا همان Global Attacker است. هدف سرور این است که مشخص کند آیا یک نمونه هدف مانند $z^* = (x^*, y^*)$ در مجموعه آموزش یک کلاینت مشخص وجود دارد یا نه. این حمله ترکیبی از دو حمله Gradient Ascent و Isolating است. مرحله اول این حمله، انتخاب کلاینت و نمونه هدف است. سرور یک کلاینت هدف و یک نمونه مشکوک z^* را انتخاب می کند. سرور می خواهد بررسی کند که آیا این نمونه عضو دیتاست کلاینت هست یا نه. مرحله دوم، اجرای gradient ascent روی نمونه هدف است. اگر تابع زیان نمونه هدف را به صورت $l(\theta; z^*)$ تعریف کنیم، در آموزش عادی، SGD در جهت منفی گرادیان حرکت می کند تا زیان کاهش پیدا کند:

$$\theta' = \theta - \eta \nabla_\theta (\theta; z^*)$$

اما سرور در حمله Gradient Ascent عمدا در جهت مثبت گرادیان حرکت می کند:

$$\theta_{\text{attack}} = \theta + \eta_a \nabla_\theta(\theta; z^*)$$

این کار باعث می شود زیان مدل روی نمونه هدف افزایش پیدا کند. در واقع سرور عمدا مدل را نسبت به نمونه هدف بدتر می کند. مرحله سوم حمله، ایزوله کردن کلاینت هدف است. در فرایند عادی، کلاینت مدل حاصل از تجمیع به روز رسانی تمام کاربران را دریافت می کند. اما در حمله Isolating، سرور برای کلاینت هدف یک نمای جداگانه از فرایند آموزش ایجاد می کند. سرور به جای ارسال مدل واقعی حاصل از تجمیع تمام کاربران، مدل دستکاری شده و اختصاصی را فقط برای کلاینت هدف ارسال می کند. بنابراین تاثیر به روز رسانی سایر کاربران وارد مسیر آموزش این کلاینت نمی شود و پاسخ کلاینت هدف با نویز و اطلاعات سایر شرکت کنندگان مخلوط نمی شود. در نتیجه، مدل محلی کلاینت اطلاعات بیشتری درباره مجموعه آموزش همان کلاینت نگه می دارد. در مرحله چهارم، کلاینت بدون اطلاع از حمله، مدل دستکاری شده را روی داده های محلی خود با SGD آموزش می دهد. اگر نمونه هدف عضو داده های کلاینت باشد، این نمونه هنگام آموزش محلی مشاهده می شود. چون سرور قبلا زیان آن را افزایش داده است، SGD تلاش می کند این افزایش زیان را جبران کند و در جهت مخالف Gradient Ascent حرکت کند:

$$\Delta\theta_{\text{member}} \approx -\eta\nabla_\theta(\theta; z^*) + \text{تاثیر سایر نمونه ها}$$

در نتیجه، زیان و گرادیان نمونه هدف به صورت ناگهانی کاهش پیدا می کند. اما اگر نمونه هدف عضو داده های کلاینت نباشد، کلاینت مستقیما روی آن نمونه آموزش نمی بیند. بنابراین مولفه مشخصی در جهت $-\nabla_\theta(\theta; z^*)$ در به روز رسانی محلی ایجاد نمی شود. ممکن است آموزش روی نمونه های دیگر به طور غیر مستقیم مدل را تغییر دهد اما واکنش قوی و مشخصی برای خنثی کردن دستکاری سرور دیده نمی شود. مرحله آخر هم تشخیص عضویت توسط سرور است. سرور به روز رسانی مدل کلاینت را دریافت می کند و بررسی می کند که آیا دستکاری ایجاد شده روی نمونه هدف خنثی شده است یا خیر. از نظر ریاضی، سرور می تواند شباهت جهت به روز رسانی کلاینت با جهت منفی گرادیان نمونه هدف را بررسی کند. برای نمونه عضو انتظار داریم $< \Delta\theta_{\text{client}}, \nabla_\theta(\theta; z^*) >$ یک مقدار منفی و با اندازه قابل توجه داشته باشد زیرا کلاینت در جهت مخالف Gradient Ascent حرکت کرده است. برای نمونه غیر عضو، چنین ارتباط مستقیم و قوی ای وجود ندارد و این ضرب داخلی معمولا به صفر نزدیک تر یا نامنظم تر است. پس اگر گرادیان نمونه هدف کاهش شدیدی داشته باشد، نتیجه می شود که آن نمونه عضو است اما اگر نباشد، نتیجه می شود که نیست.

زیربخش سوم: (مکانیزم های دفاعی و مبادله حریم خصوصی – استحکام - سودمندی)

سوال اول: دو مکانیزم دفاعی baseline معرفی شده عبارت اند از Norm Bounding و Weak Differential Privacy.

در روش Norm Bounding، در این روش، سرور اندازه به روز رسانی مدل هر کلاینت را با استفاده از نرم l2 بررسی می کند. اگر اندازه به روز رسانی از یک حد مشخص T بیشتر باشد، سرور آن را کوچک می کند تا نرم آن حداکثر برابر با T شود:

$$\Delta\theta'_k = \frac{\Delta\theta_k}{\max\left(1, \frac{|\Delta\theta_k|_2}{T}\right)}$$

اگر $|\Delta\theta_k|_2 \leq T$ باشد، به روز رسانی بدون تغییر باقی می ماند. اما اگر $|\Delta\theta_k|_2 > T$ باشد، اندازه آن کاهش پیدا می کند. هدف این دفاع آن است که یک کلاینت مخرب نتواند با ارسال یک به روز رسانی بسیار بزرگ، تاثیر کاربران سالم را در میانگین گیری از بین ببرد و مدل سراسری را به سمت مدل مسموم هدایت کند. با این حال، اگر مهاجم مقدار آستانه را بداند، می تواند به روز رسانی مخرب خود را طوری تولید کند که نرم آن از آستانه بیشتر نباشد و همچنان بر مدل اثر بگذارد. این روش در درجه اول یک دفاع استحکامی است و تضمین رسمی حریم خصوصی ایجاد نمی کند چون به روز رسانی های کلاینت ها همچنان بدون نویز در اختیار سرور قرار می گیرند.

در روش Weak DP، ابتدا همان محدود کردن نرم روی به روز رسانی کلاینت ها انجام می شود و سپس سرور نویز گاوسی به به روز رسانی های تجمیع شده اضافه می کند. به صورت کلی می توان آن را چنین نشان داد:

$$\widetilde{\Delta\theta} = \text{Aggregate}\big(\text{Clip}(\Delta\theta_1), \dots, \text{Clip}(\Delta\theta_K)\big) + \mathcal{N}(0, \sigma^2 I)$$

محدود کردن نرم، قدرت به روز رسانی های مخرب را کاهش می دهد و نویز گاوسی هم اثر دقیق آن ها را در مدل تجمیع شده مختل می کند. به همین دلیل این روش معمولا نسبت به استفاده تنها از Norm Bounding، حمله backdoor را بهتر کاهش می دهد. با این حال، مقاله این روش را ضعیف می نامد زیرا نویز در هر دور به صورت جداگانه اضافه می شود اما بودجه حریم خصوصی مصرف شده در تمام دورهای آموزش به شکل صحیح محاسبه نمی شود. بر اساس قانون ترکیب، اگر در هر دور بودجه ϵ مصرف شود، پس از r دور بودجه کل تقریبا برابر است با $r\epsilon$. در نتیجه پس از تعداد زیادی دور، مقدار ϵ بسیار بزرگ می شود و تضمین حریم خصوصی عملا ضعیف خواهد بود. بنابراین Weak DP با وجود داشتن نویز، یک مکانیزم کامل و رسمی برای حفاظت از حریم خصوصی محسوب نمی شود.

سوال دوم:

در LDP، عملیات حریم خصوصی در سمت هر کلاینت و پیش از ارسال اطلاعات به سرور انجام می شود. در روش مقاله، هر کلاینت مدل محلی خود را با الگوریتم DP-SGD آموزش می دهد. در هر مرحله آموزش، ابتدا گرادیان هر نمونه محاسبه می شود به صورت $g_i = \nabla_\theta L(\theta; (x_i, y_i))$. سپس نرم گرادیان هر نمونه با یک حد مشخص S محدود می شود:

$$\overline{g_i} = g_i \min\left(1, \frac{S}{|g_i|_2}\right)$$

بعد از محدود کردن گرادیان ها، نویز گاوسی اضافه می شود و مدل با استفاده از گرادیان نویزی به روز می شود. بنابراین اطلاعاتی که در نهایت از کلاینت خارج می شود، از قبل تحت مکانیزم حریم خصوصی قرار گرفته است. در LDP هر شرکت کننده عملیات تصادفی سازی و افزودن نویز را به صورت محلی انجام می دهد و سپس نتیجه دستکاری شده را برای سرور می فرستد. در پیاده سازی مقاله، LDP عمدتا حریم خصوصی در سطح رکورد فراهم می کند. یعنی تلاش می کند حضور یا عدم حضور یک نمونه مشخص در داده های محلی کلاینت قابل تشخیص نباشد. از آنجا که نویز قبل از ارسال به سرور اضافه می شود، برای حفظ حریم خصوصی لازم نیست کلاینت به سرور اعتماد کامل داشته باشد. برای محاسبه بودجه حریم خصوصی مصرف شده در دورها و مراحل مختلف آموزش هم از روش Moments Accountant استفاده می شود.

در CDP، کلاینت ها آموزش محلی را انجام می دهند و به روز رسانی مدل خود را برای سرور می فرستند. در این روش، اعمال مکانیزم حریم خصوصی بر عهده سرور مرکزی است. سرور ابتدا نرم l2 به روز رسانی هر کلاینت را محدود می کند:

$$\overline{\Delta\theta_k} = \Delta\theta_k \min\left(1, \frac{S}{|\Delta\theta_k|_2}\right)$$

سپس به روز رسانی های محدود شده را تجمیع می کند و به نتیجه تجمیع نویز گاوسی اضافه می کند:

$$\theta_{r+1} = \theta_r + \frac{1}{|C_r|} \sum_{k \in C_r} \overline{\Delta\theta_k} + \mathcal{N}(0, \sigma^2 I)$$

در نتیجه، برخلاف LDP که هر گرادیان نمونه در سمت کلاینت محدود و نویزی می شود، در CDP کل به روز رسانی هر شرکت کننده محدود می شود و نویز پس از تجمیع در سمت سرور اضافه می شود. سرور ابتدا نرم به روز رسانی شرکت کنندگان را محدود کرده، سپس آن ها را تجمیع می کند و در نهایت نویز گاوسی را به مقدار تجمیع شده می افزاید. CDP حریم خصوصی در سطح شرکت کننده فراهم می کند. یعنی خروجی مدل باید از نظر آماری تقریبا مشابه باشد، چه یک کلاینت مشخص در فرایند آموزش حضور داشته باشد و

چه حضور نداشته باشد. با این حال، در CDP کلاینت ها باید به سرور اعتماد کنند، زیرا سرور ابتدا به روز رسانی های بدون نویز را دریافت می کند و مسئول محدود کردن آن ها، افزودن نویز و محاسبه درست بودجه حریم خصوصی است.

سوال سوم:

تفاوت اصلی این دو مکانیزم در واحدی است که حریم خصوصی آن تضمین می شود: در LDP حفاظت در سطح رکورد است. یعنی حضور یا حذف یک نمونه مشخص از داده های محلی یک کلاینت نباید تاثیر قابل تشخیصی بر خروجی داشته باشد. هر کلاینت پیش از ارسال اطلاعات به سرور، گرادیان های نمونه ها را محدود کرده و نویز اضافه می کند. بنابراین حتی سرور هم به به روز رسانی بدون نویز دسترسی ندارد. در CDP حفاظت در سطح شرکت کننده یا کلاینت است. یعنی خروجی مدل تجمیع شده باید تقریبا یکسان باشد، چه تمام مشارکت یک کلاینت مشخص در آموزش وجود داشته باشد و چه حذف شود. سرور به روز رسانی هر کلاینت را محدود می کند و پس از تجمیع، نویز گاوسی اضافه می کند.

سوال چهارم:

LDP فقط حریم خصوصی در سطح رکورد را فراهم می کند. یعنی تاثیر یک نمونه منفرد را پنهان می کند. اما در حمله استنتاج ویژگی، مهاجم معمولا به دنبال ویژگی مشترکی است که در تعداد زیادی از رکورد های یک کلاینت وجود دارد. بنابراین حتی اگر تاثیر هر رکورد جداگانه محدود شود، اثر تجمعی آن ویژگی همچنان می تواند در به روز رسانی مدل دیده شود. به همین دلیل مقاله بیان می کند که LDP در برابر Property Inference موثر نیست، مخصوصا زمانی که تعداد زیادی از نمونه های کلاینت دارای آن ویژگی باشند. در مقابل، CDP در سطح کل شرکت کننده حفاظت ایجاد می کند. یعنی خروجی تجمیع باید تقریبا مستقل از حضور یا عدم حضور تمام داده های یک کلاینت باشد. از آنجا که ویژگی مورد نظر مهاجم متعلق به مجموعه داده همان شرکت کننده است، CDP از نظر تئوری می تواند اطلاعات مربوط به آن ویژگی را پنهان کند. اما در عمل، مخصوصا وقتی تعداد شرکت کنندگان کم است، سهم هر کلاینت در مدل تجمیع شده زیاد است. در نتیجه برای پنهان کردن کامل اثر یک شرکت کننده باید به روز رسانی او به شدت clip شود یا نویز گاوسی زیادی به مدل تجمیع شده اضافه شود. این نویز بزرگ نه تنها سیگنال مربوط به ویژگی خصوصی، بلکه اطلاعات مفید مورد نیاز برای یادگیری تسک اصلی را هم از بین می برد. بنابراین مدل یا همگرا نمی شود یا main-task utility آن به شدت کاهش پیدا می کند.

سوال پنجم:

من LDP را انتخاب می کنم. البته با این محدودیت که LDP در برابر حملات استنتاج ویژگی در سطح کل بیمارستان حفاظت کاملی ایجاد نمی کند.

دلیل اول این است که تعداد شرکت کنندگان فقط N=10 است. در CDP باید اثر کامل هر بیمارستان در مدل تجمیع شده پنهان شود. وقتی تعداد بیمارستان ها کم باشد، سهم هر بیمارستان در مدل سراسری زیاد است. بنابراین برای ایجاد حریم خصوصی در سطح شرکت کننده باید clipping شدیدتر یا نویز گاوسی زیادی اعمال شود. مقاله نشان می دهد که در چنین شرایطی CDP معمولا میان حریم خصوصی و utility با یک trade-off شدید مواجه می شود. برای نمونه، در آزمایش دارای 10 شرکت کننده، CDP با $\epsilon = 4.7$ دقت وظیفه اصلی را فقط به 57 درصد رساند. با افزایش ϵ و کاهش حفاظت، utility به 83 درصد رسید اما حمله استنتاج ویژگی تقریبا همچنان موفق باقی ماند.

دلیل دوم این است که در کاربرد پزشکی، معمولا هدف اصلی حفاظت از اطلاعات هر بیمار یا هر رکورد پزشکی است. LDP در مقاله حریم خصوصی را در سطح رکورد فراهم می کند و با اجرای DP-SGD در داخل هر بیمارستان، گرادیان ها پیش از ارسال به سرور محدود و نویزی می شوند. بنابراین سرور مرکزی هم به به روز رسانی بدون نویز دسترسی ندارد و نیاز به اعتماد به سرور کمتر است. مقاله همچنین نشان می دهد که LDP می تواند موفقیت حملات استنتاج عضویت و backdoor را کاهش دهد، هرچند مقداری افت utility ایجاد می کند.

در مقابل، CDP از نظر استحکام معمولا عملکرد بهتری دارد و در آزمایش های مقاله حمله backdoor را بیشتر کاهش داده و utility بالاتری نسبت به LDP حفظ کرده است. با این حال، این نتیجه بیشتر در محیط هایی با تعداد زیاد شرکت کننده مناسب است. در محیط های کوچک پزشکی، CDP ممکن است فقط یکی از دو مورد حریم خصوصی مناسب یا utility قابل قبول را فراهم کند.

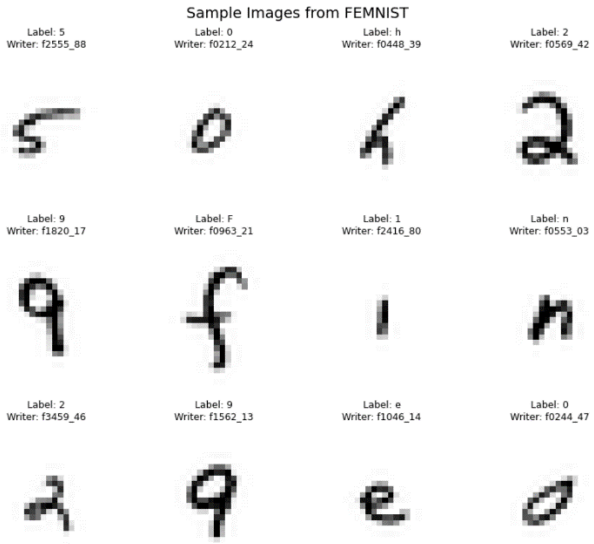
بخش سوم: سوالات پیاده سازی

زیربخش اول: (آماده سازی داده ها)

بارگذاری و بررسی اولیه داده

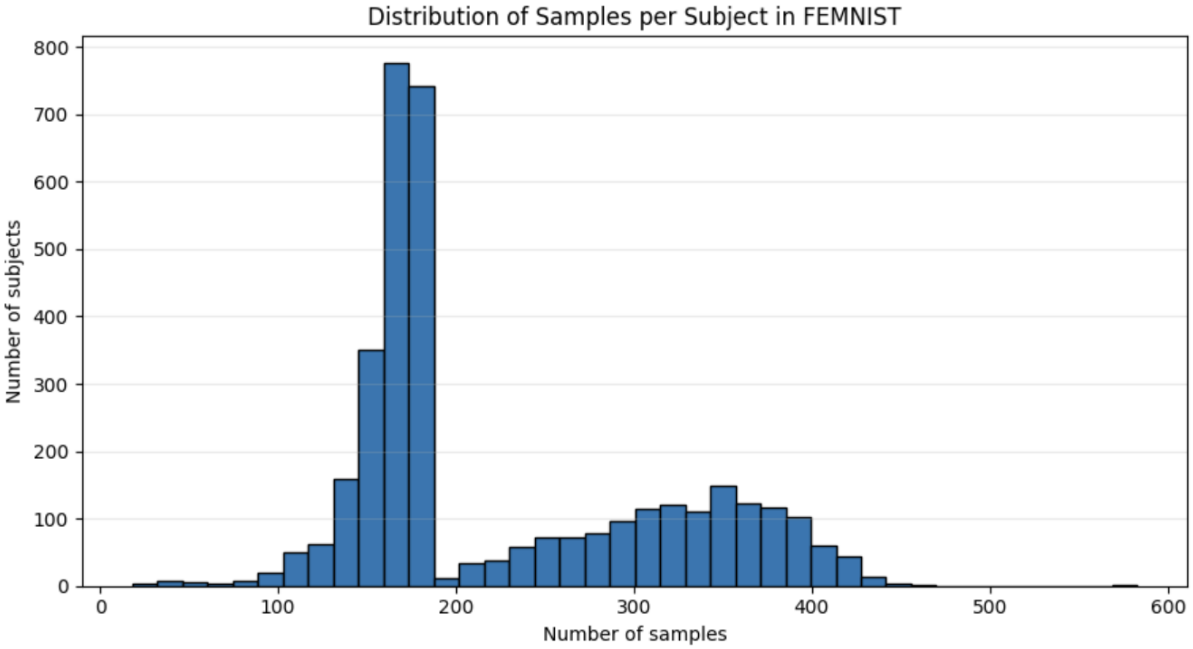
در این بخش، دیتاست FEMNIST بارگذاری و بررسی شد. این دیتاست شامل تصاویر خاکستری دست نویس با ابعاد 28×28 پیکسل است و نمونه های آن به 62 کلاس شامل ارقام، حروف بزرگ و حروف کوچک انگلیسی تعلق دارند. هر تصویر علاوه بر برچسب واقعی، دارای شناسه نویسنده یا writer_id است. در این پروژه، هر نویسنده به عنوان یک Subject در نظر گرفته شد.

دیتاست مورد استفاده در مجموع شامل 814,277 تصویر، 62 کلاس و 3,597 نویسنده است. تعداد تصاویر متعلق به هر نویسنده یکسان نیست. میانگین تعداد تصاویر هر Subject برابر با 226.38 و میانه آن برابر با 178 است. کمترین تعداد نمونه برای یک نویسنده 18 و بیشترین تعداد 583 تصویر بود. انحراف معیار تعداد نمونه ها نیز 88.86 به دست آمد. این مقادیر نشان می دهند که میان نویسندگان از نظر تعداد تصاویر ناهمگنی قابل توجهی وجود دارد.



نمونه تصاویر نشان می دهند که داده ها شامل ارقام و حروف دست نویس هستند و شیوه نوشتن یک کاراکتر میان نویسندگان مختلف تفاوت دارد. این تفاوت ها شامل اندازه کاراکتر، زاویه نوشتن، ضخامت خطوط و

شکل کلی آن هستند. بنابراین هر نویسنده دارای الگوی نوشتاری خاصی است که ممکن است مدل در طول آموزش بخشی از آن را یاد بگیرد.



نمودار توزیع تعداد نمونه ها نشان می دهد که تعداد زیادی از Subjectها حدود 150 تا 190 تصویر دارند، در حالی که گروه دیگری دارای حدود 250 تا 420 تصویر هستند. این ناهمگنی می تواند روی میزان تاثیر Subject ها بر مدل تاثیر بگذارد. Subjectهایی که داده بیشتری دارند، احتمالا سهم بیشتری در آموزش مدل خواهند داشت و ممکن است اثر عضویت آن ها در خروجی مدل آشکارتر باشد.

تعریف مجموعه های Member و Non-Member

نویسندگان موجود در دیتاست با استفاده از یک تقسیم بندی تصادفی و Seed ثابت برابر با 30 به دو مجموعه مجزا تقسیم شدند. مجموعه Member شامل 1,798 Subject با مجموع 408,589 تصویر و مجموعه Non-Member شامل 1,799 Subject با مجموع 405,688 تصویر است. بنابراین دو مجموعه از نظر تعداد نویسندگان و تعداد تصاویر تقریبا متوازن هستند. برای هر Subject عضو، حدود نیمی از تصاویر برای آموزش مدل فدرال و نیم دیگر به عنوان مجموعه Holdout نگه داشته شد. در نتیجه، 203,849 تصویر Member برای آموزش فدرال استفاده شدند و 204,740 تصویر Member در مجموعه Holdout قرار گرفتند.

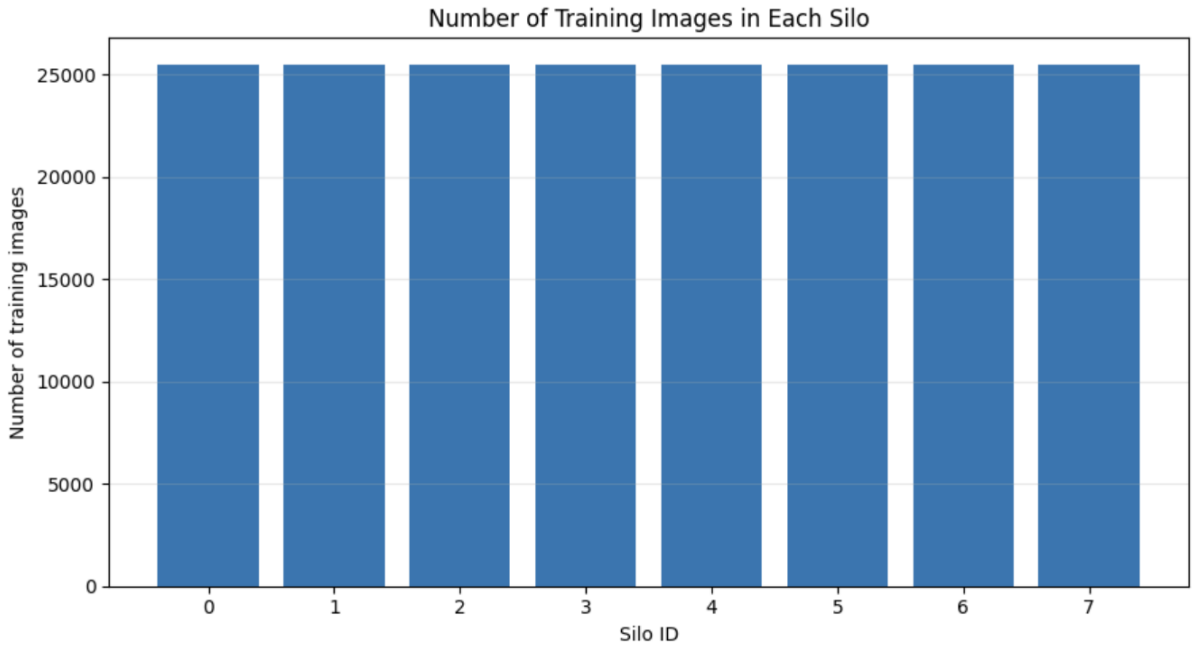
تمام 405,688 تصویر متعلق به Non-Member ها خارج از فرایند آموزش باقی ماندند. در کد نیز بررسی شد که مجموعه Member و Non-Member هیچ Subject مشترکی ندارند و میان تصاویر آموزشی Member ها، تصاویر Holdout و تصاویر Non-Member هیچ هم پوشانی وجود ندارد. همچنین تایید شد که تمام نویسندگان حاضر در داده های آموزشی عضو مجموعه Member هستند.

ایجاد ساختار Cross-Silo

سیستم فدرال شامل 8 سازمان مستقل یا Silo در نظر گرفته شد. تنها داده های آموزشی Member ها میان این سازمان ها توزیع شدند. برای هر Subject، تعداد Silo های محل حضور آن به صورت تصادفی از میان مقادیر 1 تا 4 انتخاب شد. سپس تصاویر Subject میان Siloهای انتخاب شده تقریبا به صورت مساوی تقسیم شدند. در انتخاب Siloها، سازمان هایی که در آن لحظه تعداد تصاویر کمتری داشتند در اولویت قرار گرفتند. این روش باعث شد تعداد کل تصاویر میان سازمان ها بسیار متوازن باشد. همچنین هر تصویر فقط به یک Silo اختصاص داده شد و هیچ تصویر تکراری میان سازمان ها وجود ندارد. با این حال، داده های یک Subject می توانند در یک یا چند Silo حضور داشته باشند.

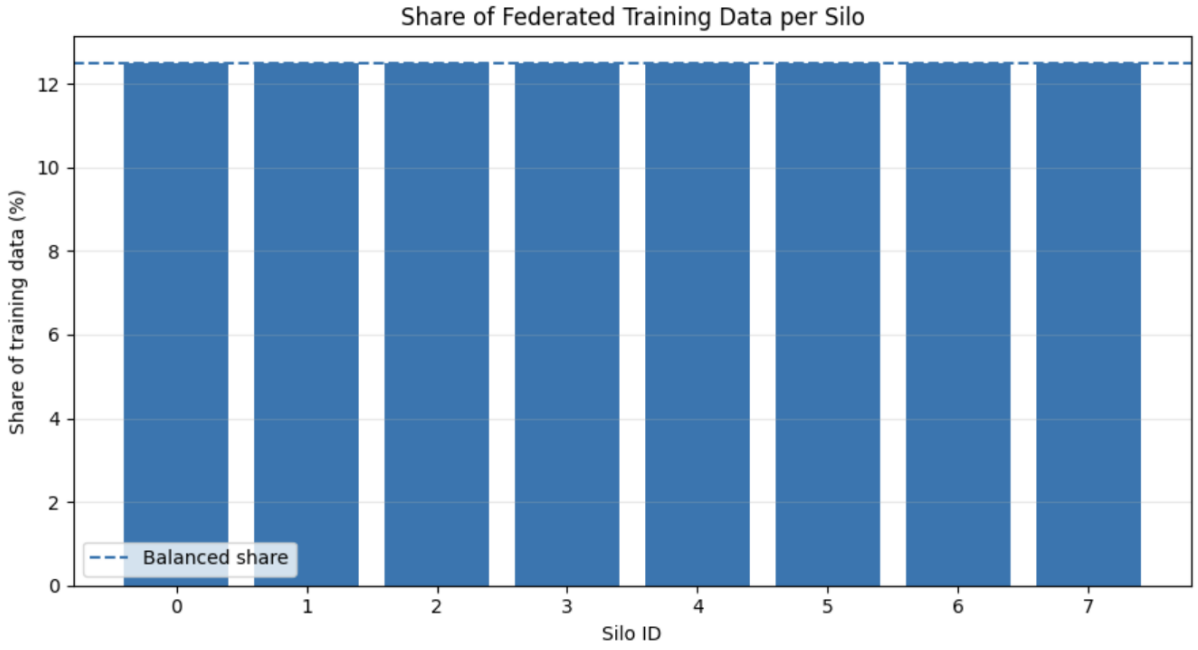
تحلیل آماری و مصورسازی

تعداد تصاویر موجود در Siloهای 0 تا 7 به ترتیب برابر با 25,492، 25,489، 25,462، 25,469، 25,482، 25,468، 25,496 و 25,491 بود. میانگین تعداد تصاویر هر سازمان برابر با 25,481.12 و انحراف معیار آن فقط 13.01 به دست آمد. ضریب تغییرات نیز برابر با 0.0005 و نسبت اندازه بزرگ ترین Silo به کوچک ترین Silo برابر با 1.0013 بود.

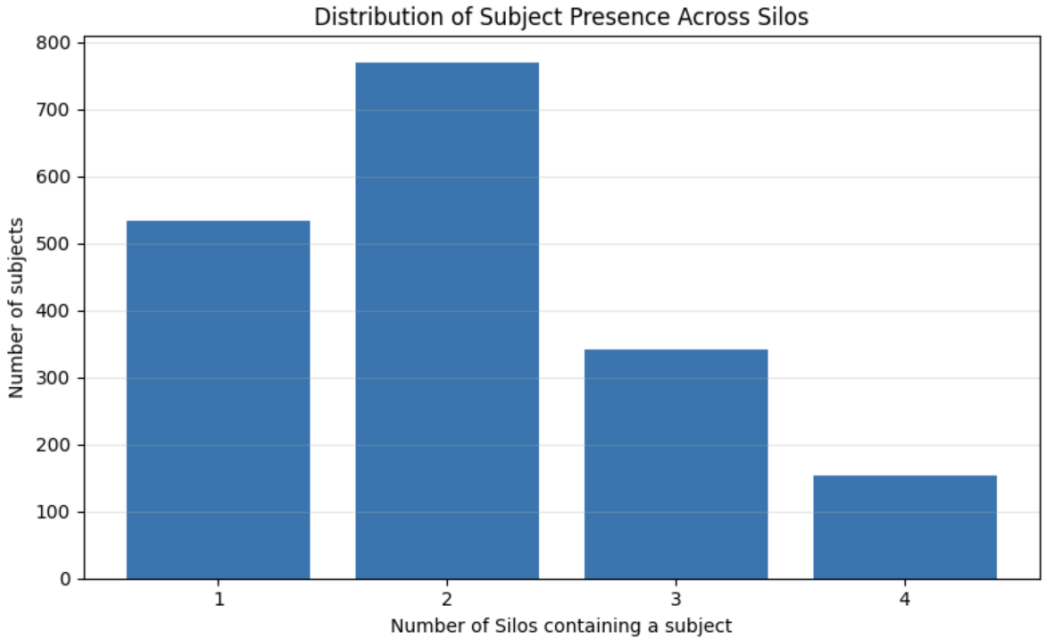


این نتایج نشان می دهند که توزیع داده ها میان 8 سازمان کاملا متوازن است. در یک تقسیم بندی کاملا متوازن، سهم هر سازمان از کل داده های آموزشی باید 12.5 درصد باشد. در نتایج به دست آمده، سهم

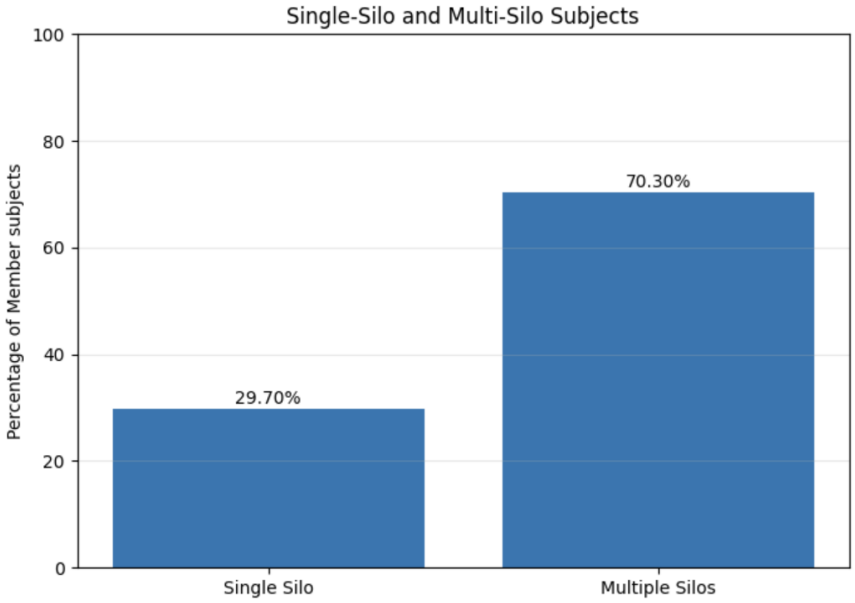
Siloها بین 12.49 تا 12.51 درصد قرار داشت. بنابراین هیچ سازمانی سهم بسیار بزرگ تر یا کوچک تری نسبت به سایر سازمان ها ندارد.



همچنین هر 8 سازمان دارای نمونه هایی از تمام 62 کلاس هستند. بنابراین هیچ سازمانی به طور کامل فاقد یک کلاس خاص نیست، هرچند ممکن است تعداد نمونه های هر کلاس میان سازمان ها دقیقا یکسان نباشد. از میان 1,798 Subject عضو، 534 Subject فقط در یک Silo، 770 Subject در دو Silo، 341 Subject در سه Silo و 153 Subject در چهار Silo حضور دارند.



بیشترین تعداد مربوط به Subjectهایی است که داده های آن ها میان دو سازمان توزیع شده است. به طور کلی، 29.70 درصد Subjectها فقط در یک Silo حضور دارند و 70.30 درصد آن ها در بیش از یک Silo قرار گرفته اند.



بنابراین بیشتر Subjectها در یک سازمان متمرکز نیستند و داده های آن ها میان چند سازمان پراکنده شده است. این نتیجه نشان می دهد که ساختار ایجاد شده با تعریف Cross-Silo Federated Learning سازگار است.

بحث و نتیجه گیری

در این پروژه، عضویت یک Subject بر اساس حضور داده های او در کل Federation تعریف می شود، نه حضور او در یک Silo مشخص. بنابراین اگر داده های یک Subject در هر یک از سازمان ها برای آموزش استفاده شده باشند، آن Subject عضو محسوب می شود. پراکنده شدن داده های یک Subject میان چند Silo می تواند تشخیص عضویت را برای یک مهاجم محلی دشوارتر کند زیرا هر سازمان فقط بخشی از داده های آن Subject را مشاهده می کند. در مقابل، مهاجمی که به مدل جهانی دسترسی دارد، اثر تجمیع شده تمام سازمان ها را مشاهده می کند. حضور یک Subject در چند سازمان همچنین می تواند احتمال مشارکت داده های او در دورهای مختلف آموزش را افزایش دهد و در نتیجه تغییرات زیان مربوط به آن Subject در چند Round مشاهده شود.

توازن بسیار بالای اندازه Silo ها نیز باعث می شود نتایج حمله تحت تاثیر تفاوت شدید حجم داده سازمان ها قرار نگیرند. در نتیجه، تفاوت های مشاهده شده در موفقیت حمله بیشتر به عضویت Subject، تعداد نمونه های او و نحوه پراکندگی داده هایش مربوط خواهند بود.

در مجموع، داده های FEMNIST به صورت صحیح آماده شدند، مرز Member و Non-Member به طور کامل حفظ شد و یک ساختار 8 سازمانی متوازن ایجاد شد. با توجه به اینکه 70.30 درصد Subjectهای عضو در چند Silo حضور دارند، این ساختار محیط مناسبی برای بررسی حملات Subject Membership Inference در یادگیری فدرال میان سازمانی فراهم می کند.

زیربخش دوم: (آموزش مدل فدرال)

در این بخش، با استفاده از داده های آماده شده در بخش قبل، یک سیستم یادگیری فدرال مبتنی بر الگوریتم FedAvg برای طبقه بندی تصاویر FEMNIST پیاده سازی کردم. سیستم شامل 8 سازمان مستقل بود و در تمام دورهای آموزش، هر 8 سازمان در فرایند یادگیری مشارکت داشتند. مدل مورد استفاده یک شبکه عصبی کانولوشنی است. این مدل شامل دو لایه کانولوشن با 32 و 64 فیلتر، دو لایه Max Pooling و دو لایه تمام متصل است. لایه خروجی دارای 62 نورون است که با تعداد کلاس های دیتاست FEMNIST برابر است. تعداد کل پارامترهای قابل آموزش مدل برابر با 1,690,046 است.

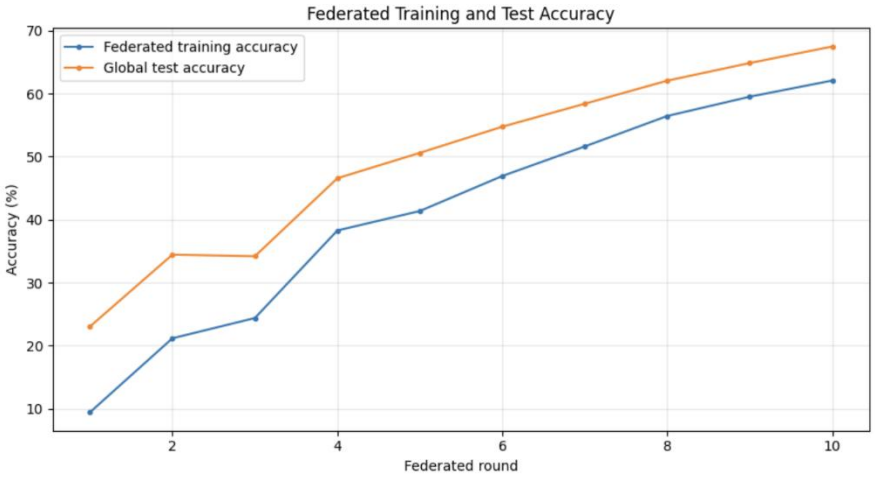
```
FEMNISTCNN(
  (conv1): Conv2d(1, 32, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
  (conv2): Conv2d(32, 64, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
  (pool): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (fc1): Linear(in_features=3136, out_features=512, bias=True)
  (fc2): Linear(in_features=512, out_features=62, bias=True)
)
Number of model parameters: 1,690,046
```

آموزش فدرال را ابتدا در 10 دور انجام دادم اما دیدم که هنوز به همگرایی نرسیده و 10 دور دیگر آموزش دادم. در هر دور، هر سازمان مدل فعلی را از سرور دریافت کرده و آن را به مدت یک epoch محلی روی داده های خود آموزش داد. برای آموزش محلی از بهینه ساز Adam با نرخ یادگیری 0.001، تابع هزینه Cross-Entropy و اندازه Batch برابر با 2048 استفاده کردم. مجموعه آزمون شامل 10,000 تصویر است که نیمی از آن ها از داده های Holdout مربوط به Subject های Member و نیم دیگر از داده های Subject های Non-Member انتخاب شدند. هیچ یک از تصاویر مجموعه آزمون در فرایند آموزش استفاده نشدند.

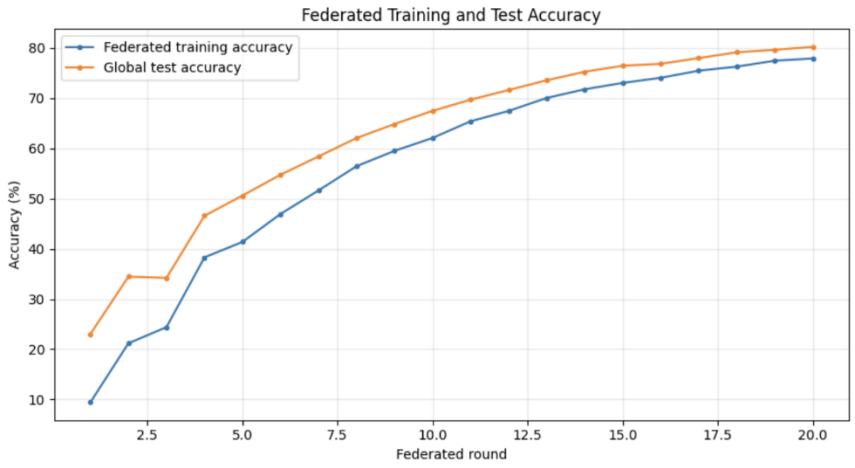
در ابتدای هر دور، سرور پارامترهای مدل جهانی را برای تمام سازمان ها ارسال کرد. هر سازمان یک نسخه محلی از مدل را دریافت کرده و آن را فقط با استفاده از تصاویر آموزشی موجود در همان سازمان به روز رسانی کرد. پس از پایان آموزش محلی، پارامترهای مدل محلی برای سرور ارسال شدند. سرور مدل های دریافت

شده را با الگوریتم FedAvg تجمیع کرد. در این روش، سهم هر مدل محلی در میانگین گیری متناسب با تعداد نمونه های آموزشی آن سازمان بود. بنابراین اگر سازمان k دارای n_k نمونه باشد، وزن آن در تجمیع برابر با نسبت n_k به تعداد کل نمونه های شرکت کننده در همان دور است. پس از تجمیع، مدل حاصل به عنوان مدل جهانی دور بعد در نظر گرفته شد. از آنجا که تعداد تصاویر سازمان ها در بخش قبل تقریبا برابر بود، وزن تمام سازمان ها در FedAvg نیز بسیار نزدیک به یکدیگر بود. این موضوع مانع از آن شد که یک سازمان به دلیل داشتن داده بسیار بیشتر، تاثیر نامتناسبی بر مدل جهانی داشته باشد.

در دور اول، دقت آموزش برابر با 9.43 درصد و دقت آزمون برابر با 23.04 درصد بود. با ادامه آموزش، دقت مدل به صورت کلی افزایش یافت. در 10 دور اول که آموزش دادم نمودار ها به صورت زیر شدند:



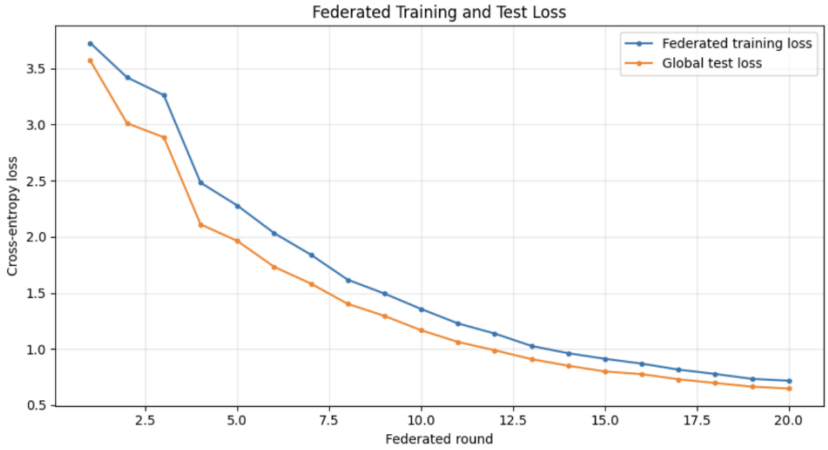
که نشان می دهد هنوز به همگرایی نرسیده و می توان بیشتر آموزش داد. به همین دلیل 10 راند دیگر آموزش دادم و نمودار آن به صورت زیر شد:



در بیشتر دورها، دقت آزمون کمی بیشتر از دقت آموزش گزارش شده است. دلیل این موضوع آن است که دقت آموزش در کد، میانگین عملکرد مدل های محلی در حین یک epoch آموزش است. هر مدل محلی

آموزش را از پارامترهای ابتدای همان دور شروع می کند، در حالی که دقت آزمون پس از پایان آموزش تمام سازمان ها و تجمیع مدل های محلی اندازه گیری می شود.

تابع loss هم بعد از 20 راند به صورت زیر شد:



دقت نهایی مدل جهانی روی کل مجموعه آزمون برابر با 80.22 درصد و مقدار تابع هزینه آن برابر با 0.6467 بود. دقت مدل روی تصاویر Holdout مربوط به Subject های Member برابر با 80.34 درصد و دقت آن روی تصاویر Non-Member برابر با 80.10 درصد به دست آمد.

عوامل مختلفی در کیفیت همگرایی اثر داشتند. توازن مناسب تعداد تصاویر سازمان ها تاثیر مثبتی بر آموزش داشت چون هیچ سازمانی بر فرایند تجمیع تسلط نداشت. مشارکت تمام 8 سازمان در هر دور هم نوسانات حاصل از انتخاب تصادفی سازمان ها را کاهش داد. استفاده از تنها یک epoch محلی باعث شد مدل های محلی بیش از حد از مدل جهانی دور نشوند و FedAvg عملکرد پایداری داشته باشد. از طرف دیگر، این تنظیم سرعت یادگیری در هر دور را محدود کرد و برای رسیدن به دقت مناسب به تعداد راند بیشتری نیاز بود. ناهمگنی داده ها در سطح نویسندگان هم بر همگرایی اثر دارد. تصاویر نوشته شده توسط Subject های مختلف دارای سبک های نوشتاری متفاوتی هستند و داده های هر Silo کاملا مستقل و هم توزیع نیستند. با وجود این ناهمگنی، کاهش پیوسته تابع هزینه نشان می دهد که FedAvg توانسته است مدل جهانی قابل قبولی تولید کند.

در تمام مراحل آموزش، فقط داده های آموزشی متعلق به Subject های Member در Silo ها استفاده شدند. داده های Holdout Member ها و تمام داده های Non-Member ها خارج از فرایند آموزش باقی ماندند. اگر حتی بخشی از داده های Non-Member وارد آموزش شود، برچسب واقعی عضویت آن Subject دیگر صحیح نخواهد بود. در این حالت، ممکن است Subject ای که به عنوان Non-Member ارزیابی می شود، در واقع

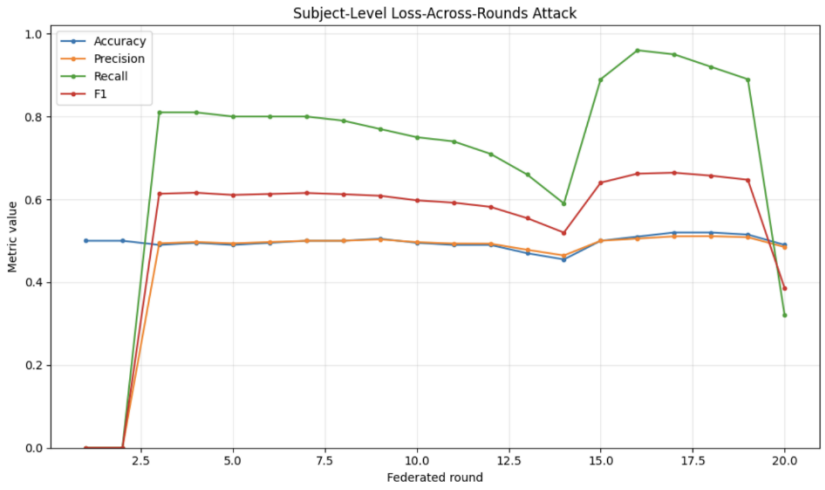
روی مدل تاثیر گذاشته باشد. این موضوع باعث ایجاد خطا در محاسبه Accuracy، Precision، Recall و F1-score حمله شده و اعتبار مقایسه حملات و دفاع های حریم خصوصی را از بین می برد.

زیربخش سوم: (ارزیابی حملات Membership Inference)

در این بخش دو حمله استنتاج عضویت در سطح Subject و Record روی مدل فدرال آموزش دیده اجرا شدند. برای جلوگیری از انتخاب آستانه روی داده های آزمون، داده های هر حمله به دو مجموعه Validation و Evaluation تقسیم شدند.

حمله Subject-Level Loss-Across-Rounds

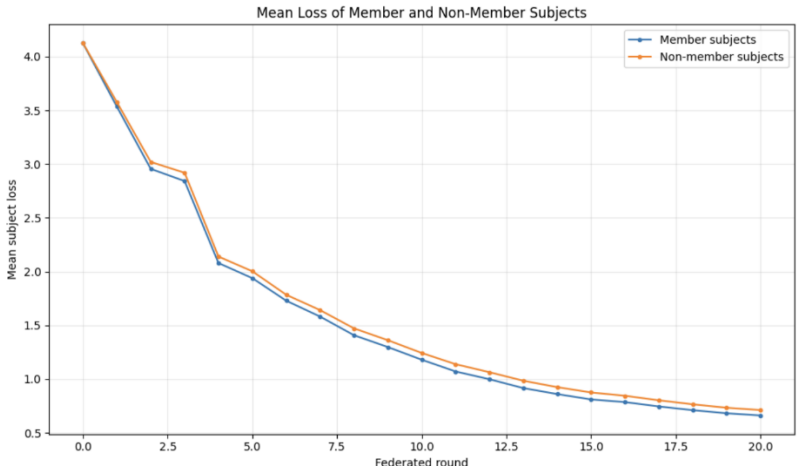
برای حمله سطح Subject، تعداد 200 Subject عضو و 200 Subject غیر عضو انتخاب شدند. از هر گروه، 100 Subject برای تعیین آستانه و 100 Subject برای ارزیابی نهایی استفاده شدند. برای محاسبه زیان هر Subject حداکثر 50 تصویر در نظر گرفته شد و در مجموع 19,953 تصویر در این حمله استفاده شد. برای هر Subject، میانگین زیان تصاویر او در مدل اولیه و مدل پایان هر Round محاسبه شد. سپس تعداد Round هایی که در آن زیان Subject نسبت به Round قبل کاهش یافته بود به عنوان امتیاز عضویت در نظر گرفته شد. فرض حمله این بود که زیان Subject های عضو در Round های بیشتری کاهش پیدا می کند، زیرا داده های آن ها در فرایند آموزش مدل مشارکت داشته اند.



در دو Round ابتدایی، امتیاز تمام Subjectها تقریبا یکسان بود و حمله هیچ سیگنال قابل استفاده ای برای استنتاج عضویت نداشت. به همین دلیل آستانه برابر بی نهایت انتخاب شد و تمام نمونه ها غیر عضو تشخیص داده شدند. از Round سوم به بعد، Recall حمله در بسیاری از Roundها بالا بود، اما Accuracy و Precision تقریبا در محدوده 0.5 باقی ماندند. این موضوع نشان می دهد که حمله تعداد زیادی از Subjectها را عضو تشخیص داده است، ولی قادر به تفکیک دقیق Member ها و Non-Member ها نبوده است. بالاترین

F1-score حمله Subject-Level تقریبا در Round هفدهم و برابر با 66.43 درصد مشاهده شد. با این حال، Accuracy در همان Round فقط 52 درصد و Precision حدود 51 درصد بود. بنابراین مقدار نسبتا بالای F1 بیشتر ناشی از Recall بسیار زیاد بود و به معنای جداسازی قوی دو گروه نیست.

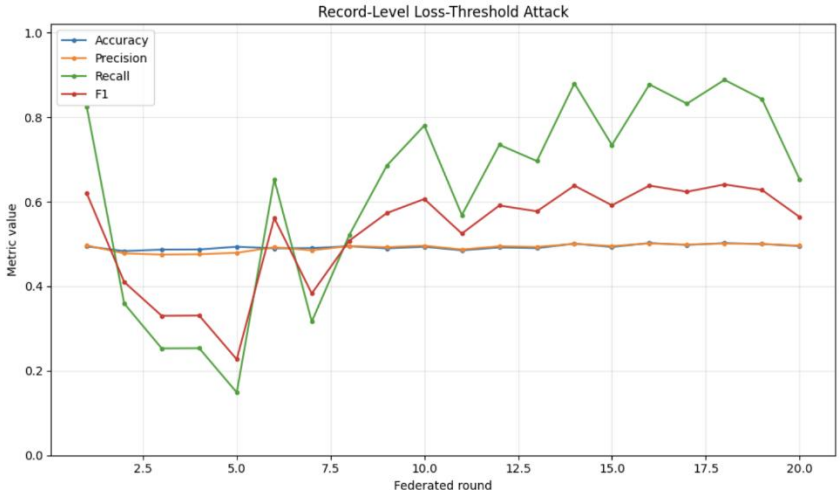
در Round بیستم، آستانه برابر با 20 انتخاب شد. این آستانه به این معنا است که تنها Subjectهایی عضو تشخیص داده شدند که زیان آن ها در تمام 20 Round کاهش یافته بود. نتایج نهایی حمله در این Round شامل Accuracy برابر با 49 درصد، Precision برابر با 48.48 درصد، Recall برابر با 32 درصد و F1-score برابر با 38.55 درصد بود.



نمودار میانگین زیان نشان می دهد که زیان Subject های عضو و غیر عضو در طول آموزش تقریبا با روند مشابهی کاهش یافته است. اگرچه در بیشتر Round های پایانی زیان Member ها کمی کمتر از Non-Member ها بود، فاصله میان دو گروه بسیار کم باقی ماند. علاوه بر این، میانگین امتیاز Loss-Across-Rounds در Round بیستم برای Member ها برابر با 18.71 و برای Non-Memberها برابر با 18.76 بود. نزدیک بودن این دو مقدار نشان می دهد که شمارش تعداد دفعات کاهش زیان، سیگنال مناسبی برای تفکیک عضویت در این آزمایش ایجاد نکرده است.

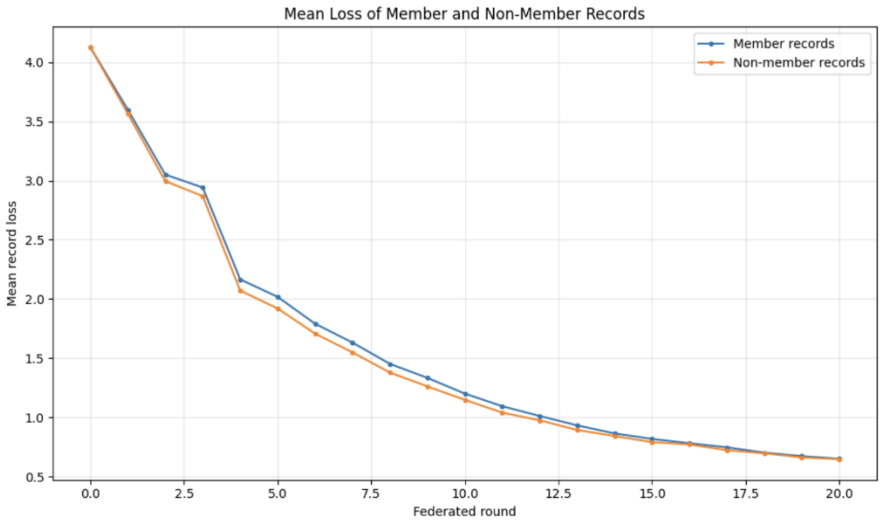
حمله Record-Level Loss-Threshold

برای حمله سطح Record، تعداد 4000 تصویر عضو و 4000 تصویر غیر عضو انتخاب شدند. تصاویر عضو دقیقا از داده های استفاده شده در آموزش فدرال انتخاب شدند. تصاویر غیر عضو از داده های Holdout همان Subject های عضو گرفته شدند و خود این تصاویر در فرایند آموزش حضور نداشتند. در مجموع، 3200 تصویر برای تعیین آستانه و 4800 تصویر برای ارزیابی نهایی استفاده شدند. در این حمله، زیان هر تصویر در مدل هر Round محاسبه شد و منفی زیان به عنوان امتیاز عضویت در نظر گرفته شد. بنابراین تصویری که زیان کمتری داشت، با احتمال بیشتری به عنوان رکورد عضو پیش بینی شد.

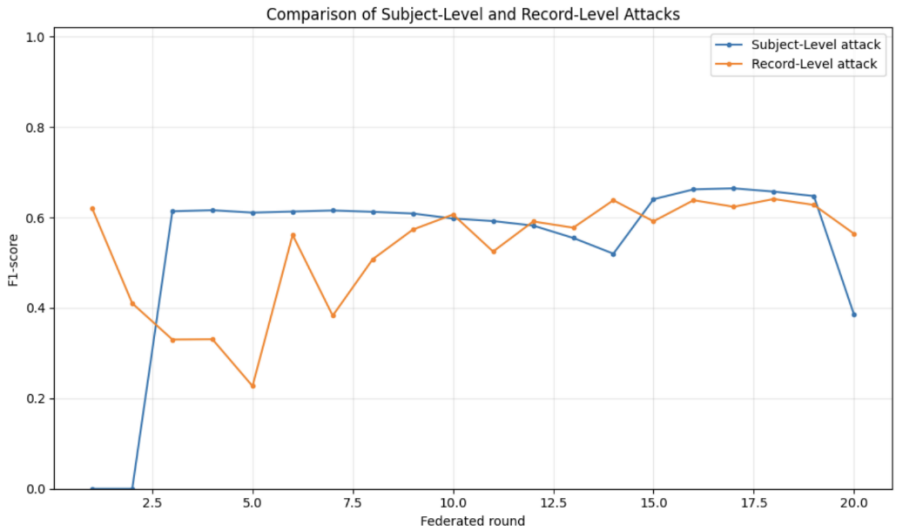


Accuracy و Precision این حمله در بیشتر Round ها نزدیک 50 درصد باقی ماندند، در حالی که Recall نوسان زیادی داشت. این نوسان به دلیل تغییر آستانه در شرایطی ایجاد شد که توزیع زیان رکورد های عضو و غیر عضو هم پوشانی زیادی داشت.

در Round بیستم، آستانه امتیاز برابر با منفی 0.5007 بود. از آنجا که امتیاز برابر منفی زیان بود، رکوردهایی که زیان آن ها کمتر یا مساوی حدود 0.5007 بود عضو در نظر گرفته شدند. نتایج نهایی شامل Accuracy برابر با 49.50 درصد، Precision برابر با 49.62 درصد، Recall برابر با 65.33 درصد و F1-score برابر با 56.40 درصد بود.



مقایسه دو حمله



اگر فقط نتایج Round نهایی در نظر گرفته شوند، حمله Record-Level با F1-score برابر با 56.40 درصد نسبت به حمله Subject-Level با F1-score برابر با 38.55 درصد موفق تر بوده است. Recall حمله Record-Level نیز 65.33 درصد بود، در حالی که Recall حمله Subject-Level فقط 32 درصد به دست آمد.

با این حال، Accuracy و Precision هر دو حمله تقریبا برابر با 50 درصد هستند. از آنجا که مجموعه های ارزیابی به صورت متوازن شامل تعداد مساوی عضو و غیر عضو بودند، Accuracy نزدیک 50 درصد نشان می دهد که قدرت تشخیص حملات تقریبا در سطح حدس تصادفی بوده است.

در طول Round ها، حمله Subject-Level در بهترین حالت F1 حدود 66.43 درصد و حمله Record-Level در بهترین حالت F1 حدود 64.08 درصد داشت. با وجود این، در Round های دارای F1 بالا نیز Accuracy و Precision نزدیک 50 درصد باقی مانده بودند. بنابراین نباید فقط بر اساس F1 نتیجه گرفت که حمله موفق بوده است زیرا پیش بینی تعداد زیادی از نمونه ها به عنوان Member می تواند Recall و در نتیجه F1 را افزایش دهد، بدون اینکه تفکیک واقعی میان دو گروه ایجاد شود.

تحلیل ریسک حریم خصوصی در سطح Subject و Record

حمله Record-Level بررسی می کند که آیا یک تصویر مشخص مستقیما در آموزش استفاده شده است یا خیر. در مقابل، حمله Subject-Level به دنبال تشخیص حضور کل یک فرد در Federation است حتی اگر تصاویر مورد استفاده برای حمله دقیقا همان تصاویر آموزشی نباشند. بنابراین نشت اطلاعات در سطح Subject می تواند حساس تر باشد زیرا عضویت کلی یک فرد در یک سامانه را مشخص می کند. در نتایج این آزمایش،

مدل روی داده های Member و Non-Member رفتار بسیار مشابهی داشت. در حمله Subject-Level، زیان هر دو گروه تقریبا با یک روند کاهش یافت و تعداد دفعات کاهش زیان نیز بسیار نزدیک بود. در حمله Record-Level هم اختلاف زیان رکوردهای عضو و غیر عضو کم بود. در نتیجه، هیچ یک از دو حمله نتوانستند نشت عضویت قوی و قابل اتکایی را نشان دهند.

یکی از عوامل احتمالی این نتیجه، توانایی تعمیم مناسب مدل است. دقت نهایی مدل روی Holdout مربوط به Member ها و داده های Non-Member تقریبا یکسان بود. همچنین تعداد زیاد داده های آموزشی و استفاده از تنها یک epoch محلی باعث شده است مدل کمتر روی نمونه های خاص حفظ شود و بیشتر الگوهای عمومی FEMNIST را یاد بگیرد. با این حال، ناموفق بودن این دو حمله به معنی وجود تضمین رسمی حریم خصوصی نیست. نتایج این بخش فقط نشان می دهند که حملات Loss-Across-Rounds و Loss-Threshold در اینجا نتوانستند عضویت را با دقت معناداری استنتاج کنند.

زیربخش چهارم: (دفاع مبتنی بر Differential Privacy)

دفاع پایه (DP-SGD / Record-Level DP)

در دفاع Record-Level DP، هدف این است که حضور یا عدم حضور یک نمونه تکی در داده های آموزشی تاثیر محدودی بر مدل نهایی داشته باشد. برای این منظور از DP-SGD و کتابخانه Opacus استفاده کردم. در هر مرحله آموزشی، گرادیان هر نمونه به صورت جداگانه محاسبه شد. سپس نرم گرادیان هر نمونه با مقدار clipping norm مقایسه شد و اگر از حد تعیین شده بیشتر بود، اندازه آن کاهش یافت:

$$\bar{g}_i = \frac{g_i}{\max\left(1, \frac{|g_i|_2}{C}\right)}$$

در این رابطه C همان clipping norm است. پس از clipping، نویز گاوسی با انحراف معیار متناسب با σC به مجموع گرادیان ها اضافه شد. این کار مانع می شود یک نمونه خاص تاثیر بسیار زیادی بر به روز رسانی مدل داشته باشد.

در اینجا، پارامتر ها به صورت زیر تنظیم شدند:

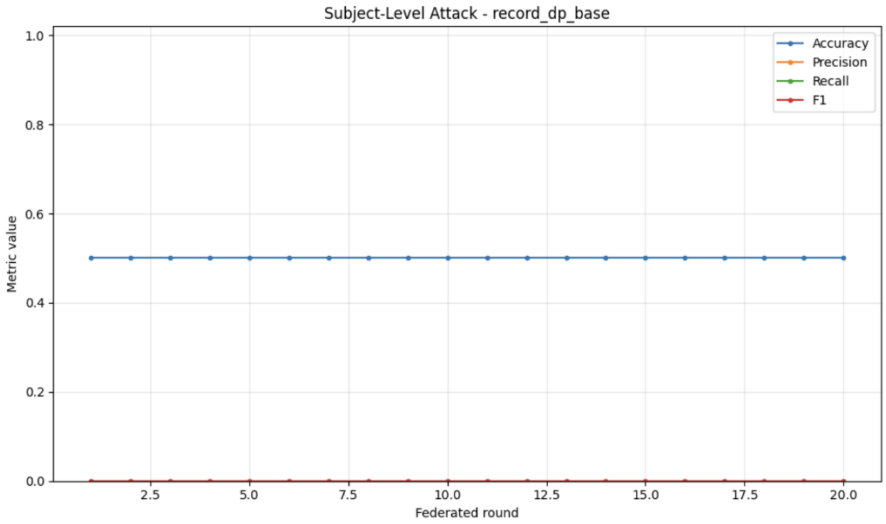
- مقدار $\delta = 10^{-5}$
- بودجه حریم خصوصی نهایی: $\epsilon = 3.9908$
- ضریب نویز: $\sigma = 1.6895$
- clipping norm برابر با 1
- انحراف معیار مطلق نویز برابر با 1.6895

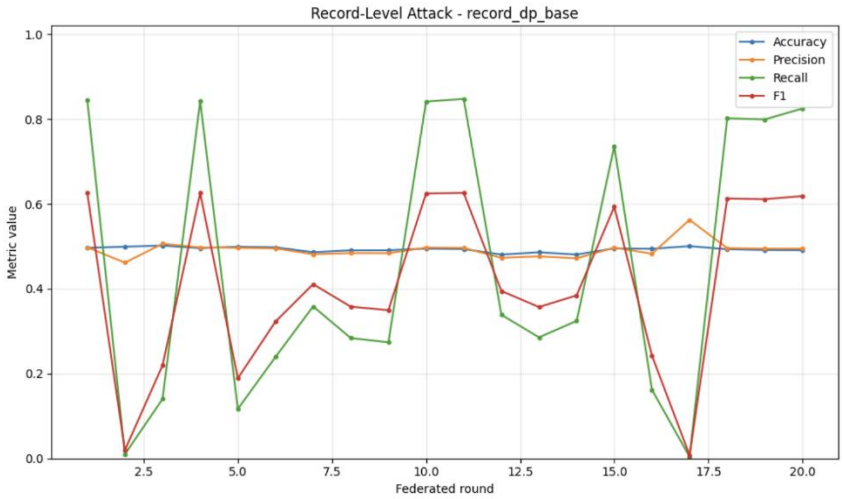
- تعداد Round ها برابر با 20

دقت نهایی مدل Record-Level DP روی مجموعه آزمون برابر با 42.28 درصد و loss نهایی آن برابر با 2.4065 شد. در مقایسه با دقت 80.22 درصدی مدل بدون DP، اعمال DP-SGD باعث افت قابل توجه Utility شده است. با این حال، مدل همچنان روند یادگیری مشخصی داشت و دقت آزمون آن از حدود 5 درصد در Round اول به بیش از 42 درصد در Round بیستم رسید.

پس از آموزش، هر دو حمله بخش قبل دوباره اجرا شدند. حمله Subject-Level دارای Accuracy برابر با 50 درصد، F1 برابر با صفر و ROC-AUC برابر با 0.4995 بود. ماتریس درهم ریختگی نشان داد که حمله تمام Subjectها را Non-Member در نظر گرفته است. بنابراین صفر شدن Precision، Recall و F1 در نمودار نشان می دهد حمله هیچ آستانه مفیدی برای تشخیص عضویت پیدا نکرده است.

حمله Record-Level هم دارای Accuracy برابر با 49.10 درصد، Precision برابر با 49.46 درصد، Recall برابر با 82.50 درصد، F1 برابر با 61.85 درصد و ROC-AUC برابر با 0.4859 بود. F1 نسبتا زیاد این حمله بیشتر به دلیل Recall بالا و پیش بینی تعداد زیادی از رکورد ها به عنوان Member است. نزدیک بودن Accuracy به 50 درصد و ROC-AUC به 0.5 نشان می دهد که قدرت تفکیک واقعی حمله تقریبا در حد تصادفی بوده است.





دفاع پیشرفته (Subject-Level DP)

در Record-Level DP، واحد حفاظت یک نمونه تکی است. پس اگر یک Subject تعداد زیادی نمونه داشته باشد، هر نمونه به صورت جداگانه در آموزش مشارکت می کند و اثر کلی Subject می تواند از طریق ترکیب تاثیر نمونه های مختلف آشکار شود. این موضوع برای حمله Subject Membership مناسب نیست زیرا مهاجم به دنبال تشخیص حضور کل یک فرد است، نه فقط یک رکورد مشخص.

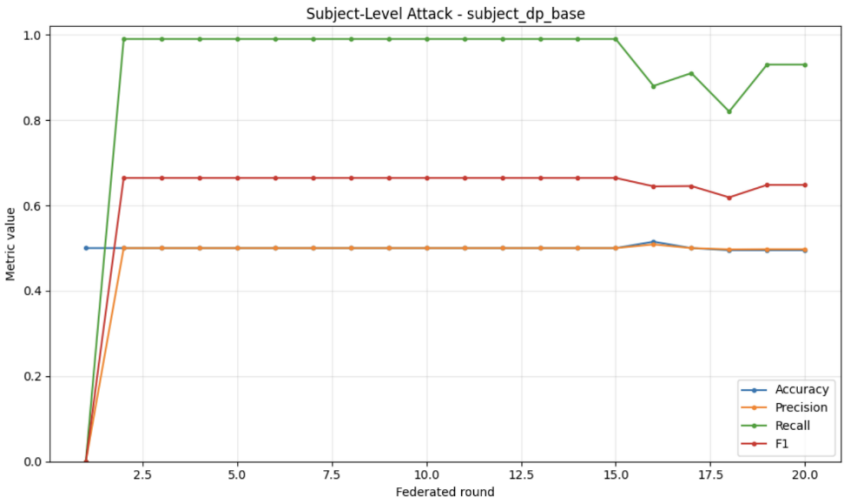
در دفاع Subject-Level DP، ابتدا چند رکورد از هر Subject انتخاب شد و میانگین گرادیان رکوردهای آن Subject محاسبه شد. سپس کل گرادیان مربوط به Subject یک بار clip شد. در نهایت نویز گاوسی به مجموع گرادیان های Subject ها اضافه شد. در نتیجه، صرف نظر از تعداد رکورد های یک Subject، اثر کلی آن فرد در هر مرحله آموزشی محدود باقی می ماند. پارامتر های دفاع Subject-Level به صورت زیر بودند:

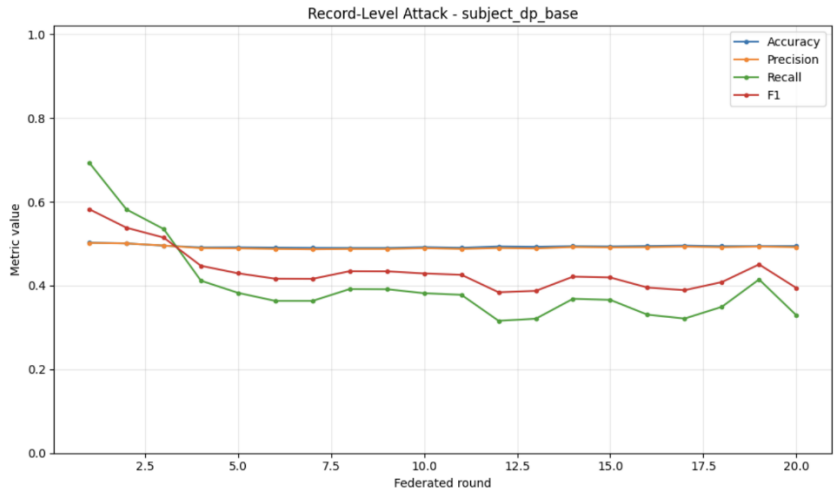
- بودجه محلی بیشینه: 0.9992
- بودجه بدترین حالت کل: 3.9969
- $\delta = 10$
- میانگین ضریب نویز: $\sigma = 1.5015$
- clipping norm برابر با 1
- 8 Subject در هر مرحله
- 8 رکورد برای هر Subject
- 12 مرحله محلی در هر Round

دقت نهایی مدل در این آزمایش 5.48 درصد و loss نهایی برابر با 3.7563 شد. اگرچه loss مدل به تدریج کاهش یافت، دقت تقریبا در محدوده 5 تا 6 درصد باقی ماند. این نتیجه نشان می دهد تنظیم فعلی Subject-Level DP بیش از حد محافظه کارانه بوده و سیگنال گرادیان در مقایسه با نویز بسیار ضعیف شده است.

پس از اجرای حملات، حمله Subject-Level دارای Accuracy برابر با 49.50 درصد، Precision برابر با 49.73 درصد، Recall برابر با 93 درصد، F1 برابر با 64.81 درصد و ROC-AUC برابر با 0.5228 بود.

حمله Record-Level هم دارای Accuracy برابر با 49.44 درصد، F1 برابر با 39.43 درصد و ROC-AUC برابر با 0.4914 بود. بنابراین هیچ یک از دو حمله جدایی قابل توجهی میان Member و Non-Member ایجاد نکردند.





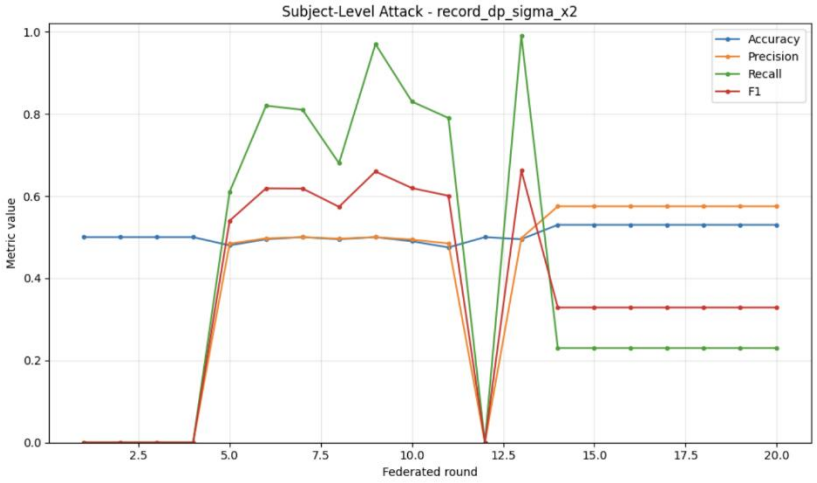
این دفاع از نظر تعریف حریم خصوصی برای مسئله Subject Membership مناسب تر است. در این روش، کل تاثیر یک فرد، شامل تمام نمونه های او، به عنوان یک واحد حفاظت در نظر گرفته می شود. در مقابل،

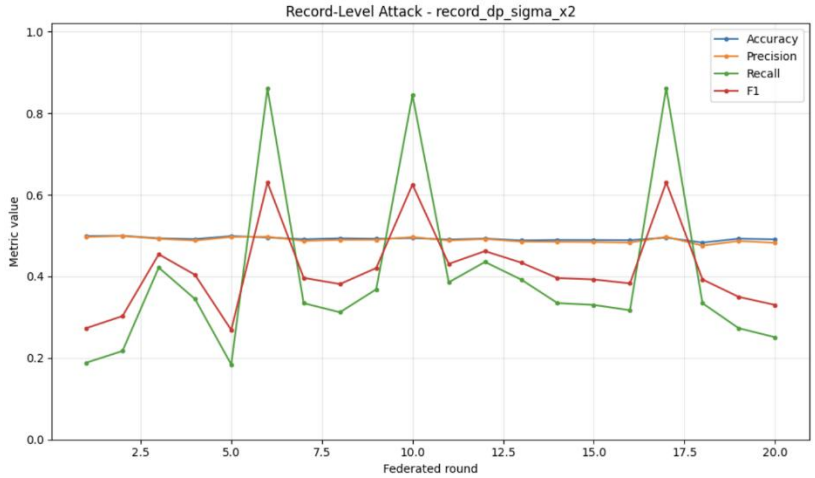
Record-Level DP فقط تاثیر هر نمونه منفرد را محدود می کند و حفاظت کل Subject تنها پس از ترکیب بودجه تمام نمونه های او به دست می آید.

آزمایش حساسیت

1- دو برابر کردن نویز

در آزمایش اول، مقدار σ از 1.6895 به 3.3789 افزایش یافت و سایر پارامترها ثابت باقی ماندند. در نتیجه، ϵ از 3.9908 به 1.6401 کاهش یافت. بنابراین حفاظت رسمی حریم خصوصی قوی تر شد. در مقابل، دقت مدل از 42.28 درصد به 31.38 درصد کاهش یافت که می تواند به دلیل افزایش نویز و سخت تر شدن یادگیری باشد. حمله Subject-Level دارای F1 برابر با 32.86 درصد و ROC-AUC برابر با 0.5150 شد. حمله Record-Level هم F1 برابر با 33 درصد و ROC-AUC برابر با 0.4865 داشت. در نتیجه، حملات همچنان تقریبا در سطح تصادفی باقی ماندند.





2- نصف کردن clipping norm

در آزمایش دوم، clipping norm از 1 به 0.5 کاهش یافت. از آنجا که ضریب نویز و تعداد مراحل ثابت بودند، epsilon تقریبا بدون تغییر و برابر با 3.9908 باقی ماند. با این حال، انحراف معیار مطلق نویز از 1.6895 به 0.8447 کاهش یافت، زیرا مقدار نویز واقعی برابر با σC است. دقت نهایی مدل برابر با 42.11 درصد شد که تقریبا با دقت 42.28 درصدی حالت پایه برابر است. بنابراین نصف کردن clipping norm در این محدوده تاثیر محسوسی بر Utility نداشت. این نتیجه می تواند نشان دهد که بخش زیادی از گرادیان ها از ابتدا در همین محدوده قرار داشته اند و یا کاهش اندازه سیگنال و کاهش اندازه نویز تا حدی یکدیگر را خنثی کرده اند.

حمله Subject-Level دارای F1 برابر با صفر و ROC-AUC برابر با 0.4558 بود. حمله Record-Level نیز F1 برابر با 57.08 درصد و ROC-AUC برابر با 0.4863 داشت.

3- دو برابر کردن تعداد Round ها

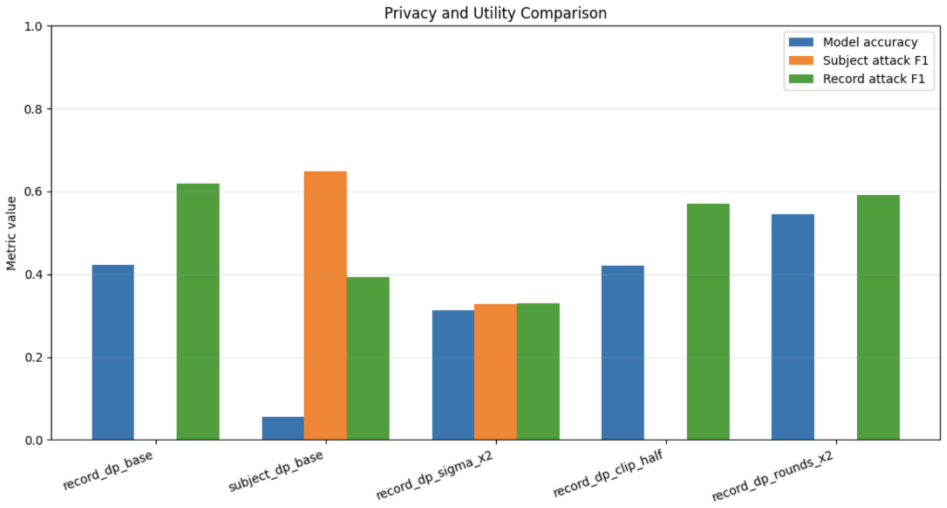
در آزمایش سوم، تعداد Roundها از 20 به 40 افزایش یافت و مقادیر σ و clipping norm ثابت باقی ماندند. دقت مدل از 42.28 درصد به 54.55 درصد افزایش یافت و زیان نهایی به 1.9461 کاهش پیدا کرد. بنابراین افزایش زمان آموزش باعث بهبود قابل توجه Utility شد. در مقابل، epsilon از 3.9908 به 5.7761 افزایش یافت. این افزایش به دلیل قانون Composition است زیرا با اجرای مراحل خصوصی بیشتر، بودجه حریم خصوصی بیشتری مصرف می شود. بنابراین نتیجه مشاهده شده با انتظار نظری سازگار است که تعداد Round بیشتر، دقت بالاتر و حفاظت رسمی ضعیف تر.

حمله Subject-Level دارای F1 برابر با صفر و ROC-AUC برابر با 0.5002 بود. حمله Record-Level هم F1 برابر با 59.16 درصد و ROC-AUC برابر با 0.4849 داشت.

مقایسه و تحلیل Trade-off

در تمام آزمایش ها مقدار $\delta=10^{-5}$ در نظر گرفته شد. جدول و نمودار نتایج به صورت زیر است:

experiment	defense	rounds	epsilon	delta	sigma_mean	clipping_norm	noise_std_mean	model_accuracy	subject_attack_f1	record_attack_f1	subject_attack_auc	record_attack_auc
record_dp_base	record_level_dp_sgd	20	3.9908	0.0	1.6895	1.0	1.6895	0.4228	0.0000	0.6185	0.4995	0.4859
subject_dp_base	subject_level_higradavgdp	20	3.9969	0.0	1.5015	1.0	1.5015	0.0548	0.6481	0.3943	0.5228	0.4914
record_dp_sigma_x2	record_level_dp_sgd	20	1.6401	0.0	3.3789	1.0	3.3789	0.3138	0.3286	0.3300	0.5150	0.4865
record_dp_clip_half	record_level_dp_sgd	20	3.9908	0.0	1.6895	0.5	0.8447	0.4211	.0000	0.5708	0.4558	0.4863
record_dp_rounds_x2	record_level_dp_sgd	40	5.7761	0.0	1.6895	1.0	1.6895	0.5455	.0000	0.5916	0.5002	0.4849



از میان آزمایش هایی که بودجه آن ها نزدیک به ϵ=4 بود، دفاع record_dp_clip_half بهترین تعادل عملی را ایجاد کرد. دقت آن 42.11 درصد بود که تقریبا با حالت پایه برابر است و حملات هم همچنان ROC-AUC نزدیک به 0.5 داشتند. دفاع record_dp_rounds_x2 بیشترین دقت را با مقدار 54.55 درصد ایجاد کرد، اما epsilon آن به 5.7761 افزایش یافت و در نتیجه حفاظت رسمی ضعیف تر شد. دو برابر کردن نویز قوی ترین حفاظت رسمی را با ϵ = 1.6401 ایجاد کرد، اما دقت مدل به 31.38 درصد کاهش یافت. بنابراین این آزمایش نمونه روشنی از Trade-off میان Privacy و Utility است.

دفاع Subject-Level DP از نظر تعریف حفاظت، مناسب ترین روش برای مسئله Subject Membership است چون کل تاثیر یک فرد را به صورت یک واحد محدود می کند. این دفاع مانع می شود Subject هایی که تعداد نمونه های بیشتری دارند یا در چند Silo حضور دارند، تاثیر نامحدودی بر مدل بگذارند. با این حال، در تنظیم فعلی، دقت 5.48 درصدی آن برای استفاده عملی کافی نیست. برای بهبود آن می توان تعداد Subjectهای هر مرحله، تعداد رکوردهای هر Subject، تعداد مراحل محلی یا روش تخصیص بودجه میان Silo ها را تنظیم کرد.

اظهارنامه استفاده از هوش مصنوعی

اعلام می کنم که اثبات ها، استدلال های مفهومی، تفسیرها و متن گزارش این تمرین، کار خودم است. از کمک هوش مصنوعی فقط در همان حدی استفاده کرده ام که سیاست صفحه نخست اجازه می دهد؛ جزئیاتش هم در جدول زیر آمده است.

ابزار	برای چه کاری استفاده شد	پرسش و شرح استفاده
chatgpt	سوال اول پرسش 2 قسمت ب	حالت تباهیده چیست و چه شروطی باید برای آن برقرار باشد؟
chatgpt	سوال اول پرسش 2 قسمت ج	مناقشه COMPAS چیست و روزنامه نگاران چه چیزی درباره آن می گفتند؟ (کلا سوال از LLM برای توضیح بیشتر این بخش)
chatgpt	سوال اول پرسش 2 قسمت د	منظور از آماری و بنیادی بودن بده بستان چیست؟ هر کدام چه معنایی دارند ؟ (توضیح با مثال)
chatgpt	سوال اول پرسش 3	توضیح کلی مقاله و نکات مهم آن
chatgpt	سوال اول پرسش 3 قسمت ب	مسیر پراکسی و مسیر تبیین کننده چیست ؟ (توضیح با مثال)
chatgpt	سوال اول پرسش 3 قسمت ج	توضیح منظور سوال (عینی بودن یعنی چه دقیقا و سوال چه می خواهد؟)
chatgpt	سوال اول پرسش 7	توضیح کلی دو مقاله درون سوال و نکات مهم و کلیدی آنها و کمک گرفتن در مثال آوردن برای قسمت الف و ب

chatgpt	سوال اول بخش پیاده سازی	برای پالایش استاندارد ProPublica چه کار هایی می توان کرد؟
chatgpt	سوال اول بخش پیاده سازی	کمک در رسم نمودار مرحله 1
chatgpt	سوال اول بخش پیاده سازی	کدام ویژگی ها باید نگه داشته شوند و کدام ها حفظ شوند که تحلیل درست تری انجام شود (در تمام بخش ها بسته به صورت سوال این را کمک گرفتم و برای همین متغیر drop_cols در هر بخشی متفاوت شده و تکرار شده)
chatgpt	سوال اول بخش پیاده سازی	از چه تحلیلی برای قسمت ج استفاده کنم و چه پیش پردازشی انجام بدم قبل از دادن به مدل (پایپ لاین چگونه باشد تا تحلیل بهتری صورت بگیرد؟) . همچنین کمک در رسم نمودار این قسمت
chatgpt	سوال اول بخش پیاده سازی	کمک گرفتن به ارتباط نتیجه مرحله 3 با پرسش 3 (ب)
chatgpt	سوال اول بخش پیاده سازی	توضیح درباره روش های تعدیل مختلف و کمک در نحوه پیاده سازی آنها (مرحله 4) و همچنین کمک در کد تجمیع جداول
chatgpt	سوال اول بخش پیاده سازی	مرز پارتو چیست (مرحله 5) و کمک در کشیدن نمودار و این مرز
chatgpt	سوال دوم بخش دوم	توضیح مقاله و نکات مهم آن

chatgpt	سوال دوم بخش دوم زیر بخش دوم	کمک در فرمول های حمله بخش ج
chatgpt	سوال دوم بخش دوم زیربخش سوم	توضیح دو روش baseline
chatgpt	سوال دوم بخش پیاده سازی	توضیح مقاله و نکات مهم آن
chatgpt	سوال دوم بخش پیاده سازی	کمک گرفتن برای پیاده سازی مدل برای آموزش مطابق مقاله
chatgpt	سوال دوم بخش پیاده سازی	کمک گرفتن در پیاده سازی زیر بخش سوم
chatgpt	سوال دوم بخش پیاده سازی	کمک گرفتن برای کد استفاده از cache برای سریع تر شدن روند آموزش
chatgpt	سوال دوم بخش پیاده سازی	دقیق نبودن گزارش f1 در اینجا (که gpt معیار youden's j را پیشنهاد داد)
chatgpt	سوال دوم بخش پیاده سازی	کمک در تحلیل نتایج زیربخش سوم
chatgpt	سوال دوم بخش پیاده سازی	کمک در پیاده سازی دفاع های بخش چهارم و همچنین تسریع فرایند با کش
chatgpt	سوال دوم بخش پیاده سازی	کمک در تحلیل گزارش بخش چهارم
chatgpt	سوال دوم بخش پیاده سازی	کمک در استفاده از کتابخانه برای پیاده سازی بخش چهارم

امضا و تاریخ:



مراجع

[1]M. J. Kusner, J. R. Loftus, C. Russell, and R. Silva, “Counterfactual fairness,” in Advances in Neural Information Processing Systems 30 (NIPS 2017), pp. 4066–4076, 2017.

[2]L. T. Liu, S. Dean, E. Rolf, M. Simchowitz, and M. Hardt, “Delayed impact of fair machine learning,” in Proceedings of the 35th International Conference on Machine Learning (ICML), vol. 80, pp. 3150–3158, 2018.

[3]M. Naseri, J. Hayes, and E. De Cristofaro, “Local and central differential privacy for robustness and privacy in federated learning,” in Proceedings of the 29th Network and Distributed System Security Symposium (NDSS), 2022.

[4]M. Kearns, S. Neel, A. Roth, and Z. S. Wu, “Preventing fairness gerrymandering: Auditing and learning for subgroup fairness,” in Proceedings of the 35th International Conference on Machine Learning (ICML), vol. 80, pp. 2564–2572, 2018.

[5]A. Suri, P. Kanani, V. J. Marathe, and D. W. Peterson, “Subject membership inference attacks in federated learning,” arXiv preprint arXiv:2206.03317, 2022.

[6]N. Kilbertus, M. Rojas-Carulla, G. Parascandolo, M. Hardt, D. Janzing, and B. Schölkopf, “Avoiding discrimination through causal reasoning,” in Advances in Neural Information Processing Systems 30 (NIPS 2017), pp. 656–666, 2017.